KingbaseES RAC 共享存储集群使用手册

金仓数据库管理系统 KingbaseES

文档版本：V9（V009R001C010）

发布日期：2025 年 12 月 3 日

中电科金仓（北京）科技股份有限公司

目　录

第 1 章　集群概述 1
1.1 KingbaseES RAC 共享存储集群介绍 1
1.1.1 概述 1
1.2 KingbaseES RAC 共享存储集群方案能力 2
1.2.1 可用性 2
1.2.2 性能 2
1.2.3 成本 3
1.2.4 限制与约束 3
1.3 KingbaseES RAC 方案架构简介 3
1.3.1 逻辑架构 4
1.3.2 运行架构 5
1.3.3 数据架构 6
1.3.4 物理架构 7
1.4 KingbaseES RAC 集群依赖组件介绍 7
1.4.1 Clusterware 概述 7
1.4.2 Clusterware 的作用 8

第 2 章　快速安装 KingbaseES RAC 集群 9
2.1 环境准备 9
2.1.1 部署规划 9
2.1.2 服务器需求 10
2.1.3 集群网络需求 12
2.1.4 对外控制权限需求 12
2.2 获取集群软件包 12
2.3 安装集群 13
2.3.1 参数配置 13
2.3.2 节点间互信配置 15
2.3.3 集群搭建 16
2.3.4 集群状态查看 16

第 3 章　命令行安装 17

3.1 KingbaseES RAC 部署资源需求 . . . 17
3.1.1 部署规划 . . . 17
3.1.2 服务器需求 . . . 18
3.1.3 集群网络需求 . . . 20
3.1.4 对外控制权限需求 . . . 20
3.2 环境配置 . . . 20
3.2.1 操作系统配置 . . . 21
3.2.1.1 创建数据库用户 . . . 21
3.2.1.2 操作系统参数配置 . . . 21
3.2.1.3 网络与防火墙配置 . . . 21
3.2.1.4 配置时间同步 . . . 22
3.2.2 RAC 数据库和 Clusterware 组件配置 . . . 22
3.2.2.1 采用安装包安装 . . . 22
3.2.2.2 采用绿色版安装 . . . 23
3.2.3 共享存储配置 . . . 23
3.2.4 开机自启 . . . 24
3.2.5 系统配置检查 . . . 25
3.2.5.1 检查环境变量 . . . 25
3.2.5.2 检查 hosts . . . 26
3.3 KingbaseES RAC 集群的安装 . . . 26
3.3.1 基于 CLI 搭建集群 . . . 26
3.3.1.1 基于 SAN 设备搭建 . . . 26
3.3.1.1.1 配置参数 . . . 26
3.3.1.1.2 集群免密部署 . . . 29
3.3.1.1.3 集群非免密部署 . . . 29
3.3.1.2 基于 NAS 设备搭建 . . . 30
3.3.1.2.1 配置约束 . . . 30
3.3.1.2.2 参数配置 . . . 30
3.3.1.2.3 集群部署 . . . 31
3.3.1.3 搭建时错误处理 . . . 32
3.3.1.4 卸载安装程序 . . . 32
3.3.2 基于命令行搭建集群 . . . 32
3.3.2.1 环境准备 . . . 32
3.3.2.2 搭建 gfs2 文件系统 . . . 33
3.3.2.3 配置 DB 资源 . . . 36
3.3.2.4 手动管理数据库 . . . 38

第 4 章 运维指南 40
4.1 KingbaseES RAC 集群监控 . . . 40
4.1.1 监控指标 . . . 40
4.2 KingbaseES RAC 扩缩容 . . . 41
4.2.1 节点扩容 . . . 41

4.2.1.1 免密扩容 41
4.2.1.2 非免密扩容 42
4.2.2 节点缩容 42
4.2.2.1 免密缩容 42
4.2.2.2 非免密缩容 43
4.2.3 扩缩容失败恢复 44
4.3 KingbaseES RAC 运维操作 44
4.3.1 集群查看 44
4.3.2 集群启停 44
4.3.3 计划内停机运维 45
4.3.3.1 资源补丁、升级 45
4.3.3.2 clusterware 补丁、升级 45
4.3.3.2.1 脱管资源方式 46
4.3.3.2.2 滚动方式 46
4.3.3.3 系统或硬件补丁、升级 47

第 5 章 其它集群结构 48
5.1 Clusterware 共享存储集群概述 48
5.1.1 方案简介 48
5.1.2 组网配置 50
5.1.3 运行架构 51
5.2 集群搭建前置操作 51
5.2.1 采用安装包部署 52
5.2.2 绿色版安装部署 52
5.2.3 配置 NTP 时间同步 52
5.2.3.1 配置 NTP 时间服务器 52
5.2.3.2 其他要时间同步的机器 53
5.2.3.3 验证 54
5.2.4 配置 terminfo 54
5.2.5 hostnamed 服务配置 55
5.2.6 采用 iSCSI 设备作为共享磁盘 55
5.2.6.1 iSCSI 设备的配置 55
5.2.6.2 iSCSI 设备的初始化 56
5.2.7 采用多点可见存储设备作为共享磁盘 57
5.2.7.1 多点可见存储设备的配置 57
5.2.7.2 多点可见存储设备初始化 57
5.2.8 系统配置检查 57
5.2.8.1 检查环境变量 58
5.2.8.2 检查 hosts 58
5.3 集群搭建方案 58
5.3.1 使用 CLI 搭建集群 59
5.3.1.1 搭建集群 64

5.3.1.2 管理进程 66
5.3.1.3 开机自启 66
5.3.2 使用命令行搭建集群 67
5.3.2.1 配置主机名称 67
5.3.2.2 配置投票盘 67
5.3.2.3 配置并启动 corosync 69
5.3.2.4 配置并启动 pacemaker 72
5.3.2.5 启动 corosync-qdevice 73
5.3.2.6 配置 crmsh 74
5.3.2.7 crm 配置资源 74
5.4 应急预案 80
5.4.1 故障处理行为 80
5.4.1.1 网络类故障 80
5.4.1.2 状态变化类故障 81
5.4.1.3 资源耗尽类故障 84
5.4.2 从计划外停机中恢复 86
5.4.2.1 实例故障、主机/网络故障但存储可用 86
5.4.2.2 存储故障/数据损坏的恢复 86
5.4.2.3 集群故障或站点故障的恢复 86
5.4.2.4 FENCE 设备故障的恢复 86
5.4.2.5 clusterware 备份和恢复方式 87

第 6 章 附录 88
6.1 Kingbase Clusterware 集群管理脚本 88
6.1.1 cluster_manager.sh 脚本 88
6.1.1.1 cluster_manager.sh 脚本的功能 88
6.1.2 cluster_manager.conf 配置项 90
6.2 Kingbase Clusterware Corosync 配置 94
6.2.1 投票盘（qdevice-disk）配置 94
6.2.2 成员管理（corosync）配置 94
6.2.2.1 说明 94
6.2.2.2 totem 段 94
6.2.2.3 totem.interface 段 95
6.2.2.4 nodelist 段 95
6.2.2.5 quorum & quorum.device 段 95
6.2.2.6 quorum.device.disk 段 96
6.2.2.7 quorum.device.heuristics 段 97
6.2.2.8 logging 段 97
6.2.2.9 配置间关系 98
6.2.2.10 两节点推荐配置 98
6.2.2.11 配置调整 100
6.3 Kingbase Clusterware Pacemarker 配置 100

6.3.1 说明 100
6.3.2 集群选项 101
6.3.3 资源 operation 配置 101
6.3.4 资源 meta 配置 102
6.3.5 资源配置 104
6.3.6 资源约束配置 112
6.3.7 资源迁移分数配置 114
6.3.8 Group 资源与 CLONE 资源 {#group-resource} 114
6.3.9 两节点双库推荐配置 116
6.3.10 配置调整 121

版权声明 123

服务周期承诺 124

第1章　集群概述

1.1　KingbaseES RAC 共享存储集群介绍

本章节包含以下内容：

- 概述

1.1.1　概述

KingbaseES RAC 是电科金仓推出的、完全自主研发的国产共享存储数据库集群，具备稳定、高可用、高性能、高扩展特性。KingbaseES RAC 共享存储集群方案可以提供性能扩展和可用性，同时保持低存储成本和中等维护成本，适用于大部分业务的需求。

下表从性能、可用性和成本角度详细描述了共享存储集群方案和 KingbaseES 的其他方案的差异。

表 1.1.1: 方案对比

		单机	KingbaseES ClusterWare 集群	KingbaseES RWC	KingbaseES RAC
性能	单节点资源满足需求	读写基准响应时间读写基准吞吐量	等同于单机	写响应时间约为 120%（取决于 WAL 使用的存储设备写入响应时间和吞吐量）其他等同于单机	普通操作响应时间约为 120% 跨节点冲突操作响应时间约为 200%
	单节点资源不满足需求	随瓶颈资源的竞争严重程度下降	随瓶颈资源的竞争严重程度下降	可扩展事务中第一个写之前的读请求，增加吞吐量。降低因资源不足造成的读写响应时间增加	跨节点冲突操作少且存储设备不是瓶颈时可实现对读写操作的扩展，增加吞吐量。降低因资源不足造成的读写响应时间增加
可用性	网络、节点、实例故障	RTO > 10 分钟，RPO = 0	RTO > 1 分钟，RPO = 0	RTO < 1 分钟，RPO = 0	RTO < 1 分钟，RPO = 0

-续表-

		单机	KingbaseES ClusterWare 集群	KingbaseES RWC	KingbaseES RAC
	存储故障、数据损坏	RTO > 30 分钟，RPO = 0	RTO > 30 分钟，RPO = 0	RTO < 1 分钟，RPO = 0	RTO > 30 分钟，RPO = 0 使用存储的可靠和可用性方案可以降低故障概率和切换时间
成本	存储成本	单副本，低	单副本，低	容量随节点数增加，高	单副本，低
	应用改造成本	无	无	无	无
	维护成本	极低	低	低	中
	总体成本	极低	低	中	中

1.2　KingbaseES RAC 共享存储集群方案能力

本章节包含以下内容：

- 可用性
- 性能
- 成本
- 限制与约束

1.2.1　可用性

方案支持在发生计划外实例、节点、存储、网络故障时 RPO=0，RTO 时长取决于数据库的检查点配置和故障时的压力大小，通常为 1 分钟。

1.2.2　性能

方案可以提供对读写操作的扩展能力，从而提供更大的吞吐量，但对比单机方案会增加操作的响应时间，总体性能和使用时节点间访问冲突量相关，最佳实践推荐不同业务模块访问不同的节点以获得最佳性能。

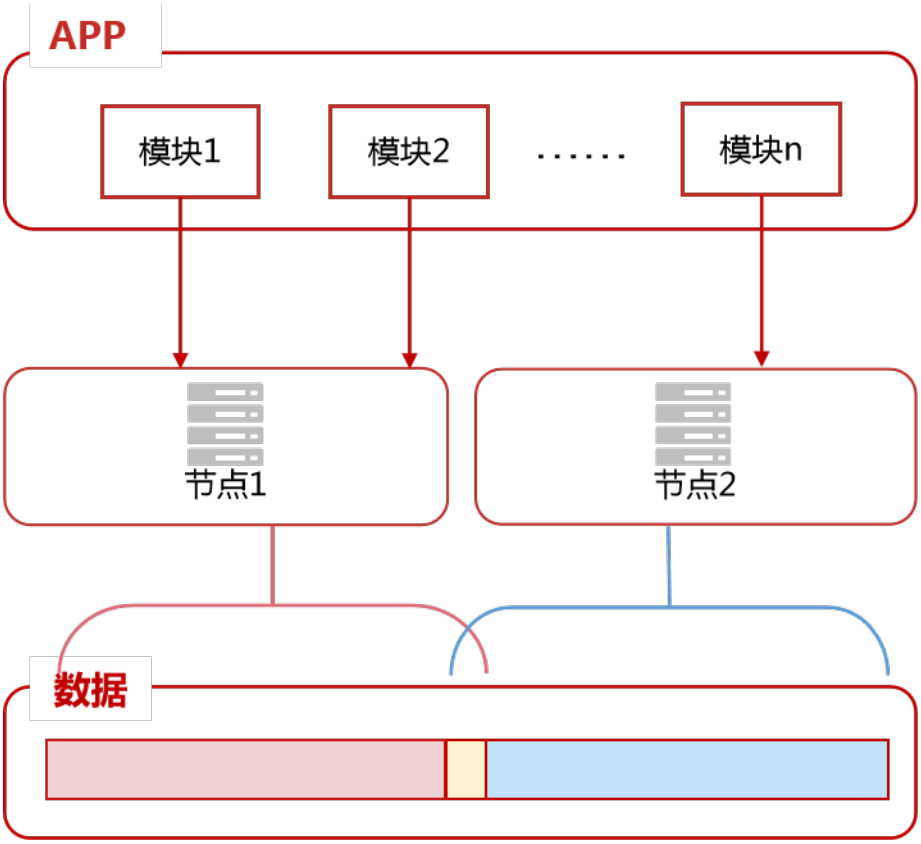

业务的多个模块访问的数据相对独立，模块的访问发生在不同节点。

例如模块 1（人力资源）、模块 2（销售管理）、模块 N（电话中心）访问的数据大部分独立（红色、蓝色部分），少量数据例如组织结构、人员信息等共享（橙色）

1.2.3　成本

方案使用的存储容量不随节点数增加而增加，只需要存储级冗余作为存储可用性方案，通常使用 2 倍存储容量。

方案的应用开发能力继承单机方案，无需额外应用改造。方案的集群维护管理对比单机方案需要额外的管理成本。

1.2.4　限制与约束

当前版本不支持 SSI 隔离级别，不支持 LISTEN/NOTIFY 异步通知。

1.3　KingbaseES RAC 方案架构简介

本章节包含以下内容：

- 逻辑架构
- 运行架构
- 数据架构
- 物理架构

以两节点集群架构为例描述方案架构。

1.3.1　逻辑架构

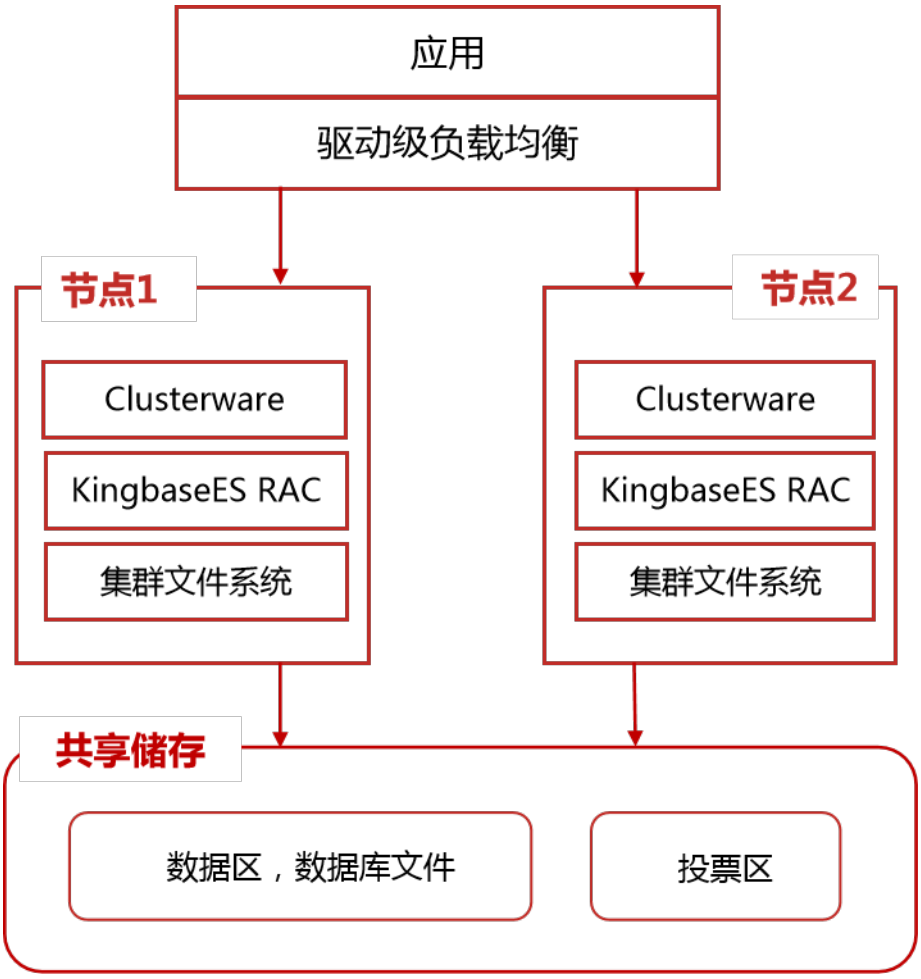

KingbaseES 提供了数据库的连接驱动，实现了客户端的负载均衡，并且支持连接级，在每个节点上提供了 Clusterware 软件，管理集群中的成员，进行故障检测，处理数据库的调度问题，新增的 KingbaseES RAC 数据库提供跨节点一致的读写服务，集群的文件系统支持各节点对共享存储的一致性访问。

1.3.2　运行架构

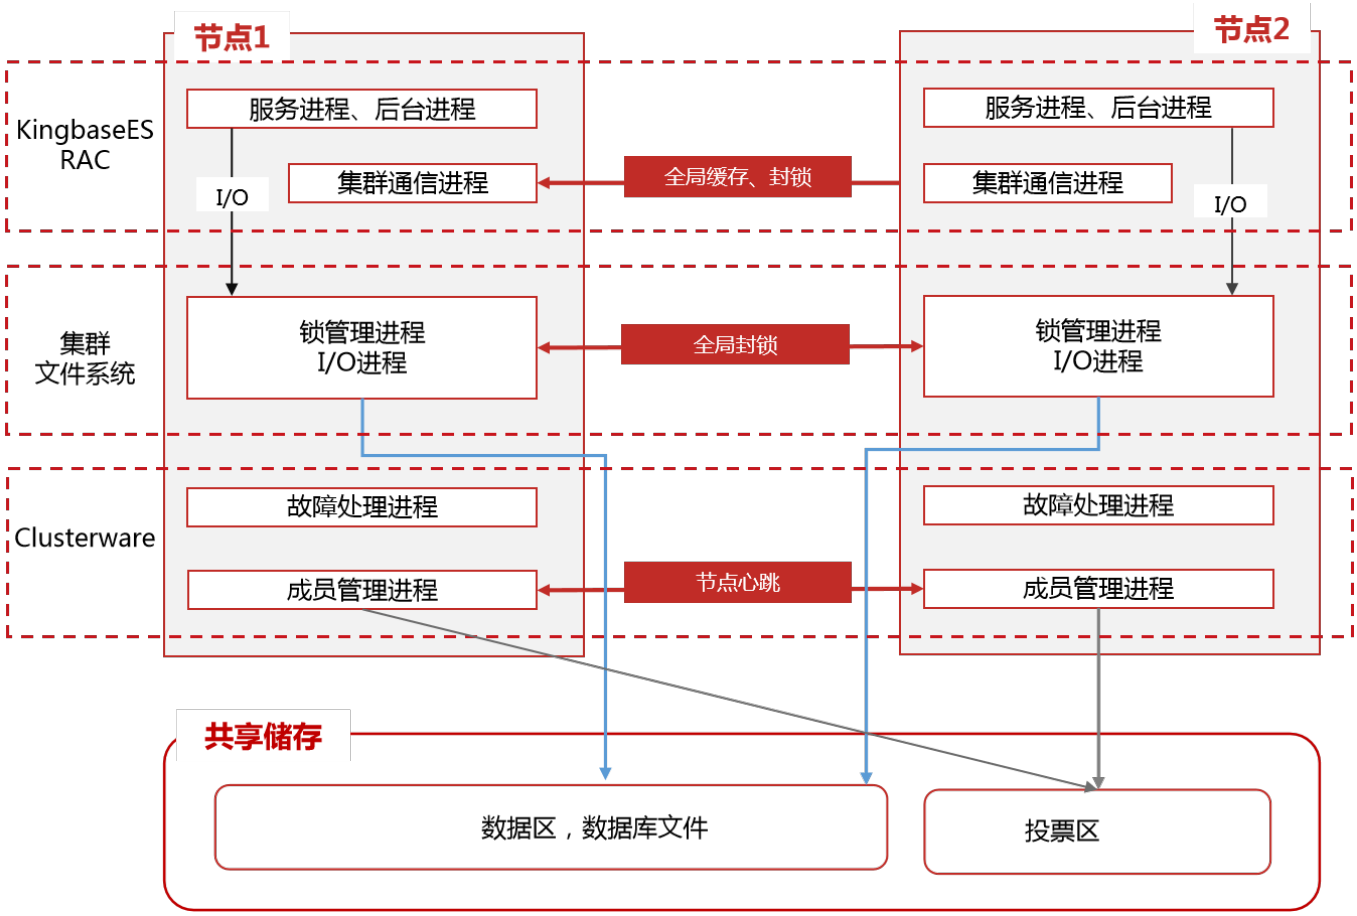

KingbaseES RAC 集群进程支撑维护全局一致性，提供节点管理、封锁、缓存交换等功能。

集群文件系统提供锁管理进程，进行跨节点并发控制，提供 I/O 进程完成数据存取。

Clusterware 故障检测处理进程提供故障检测以及自动处理，成员管理进程提供全局一致的成员列表。

1.3.3　数据架构

节点1
节点2
节点数据
WAL日志、归档
节点控制文件
临时文件……
节点数据
WAL日志、归档
节点控制文件
临时文件……
全局数据
数据文件、配置文件
事务日志、全局控制文件

1.3.4　物理架构

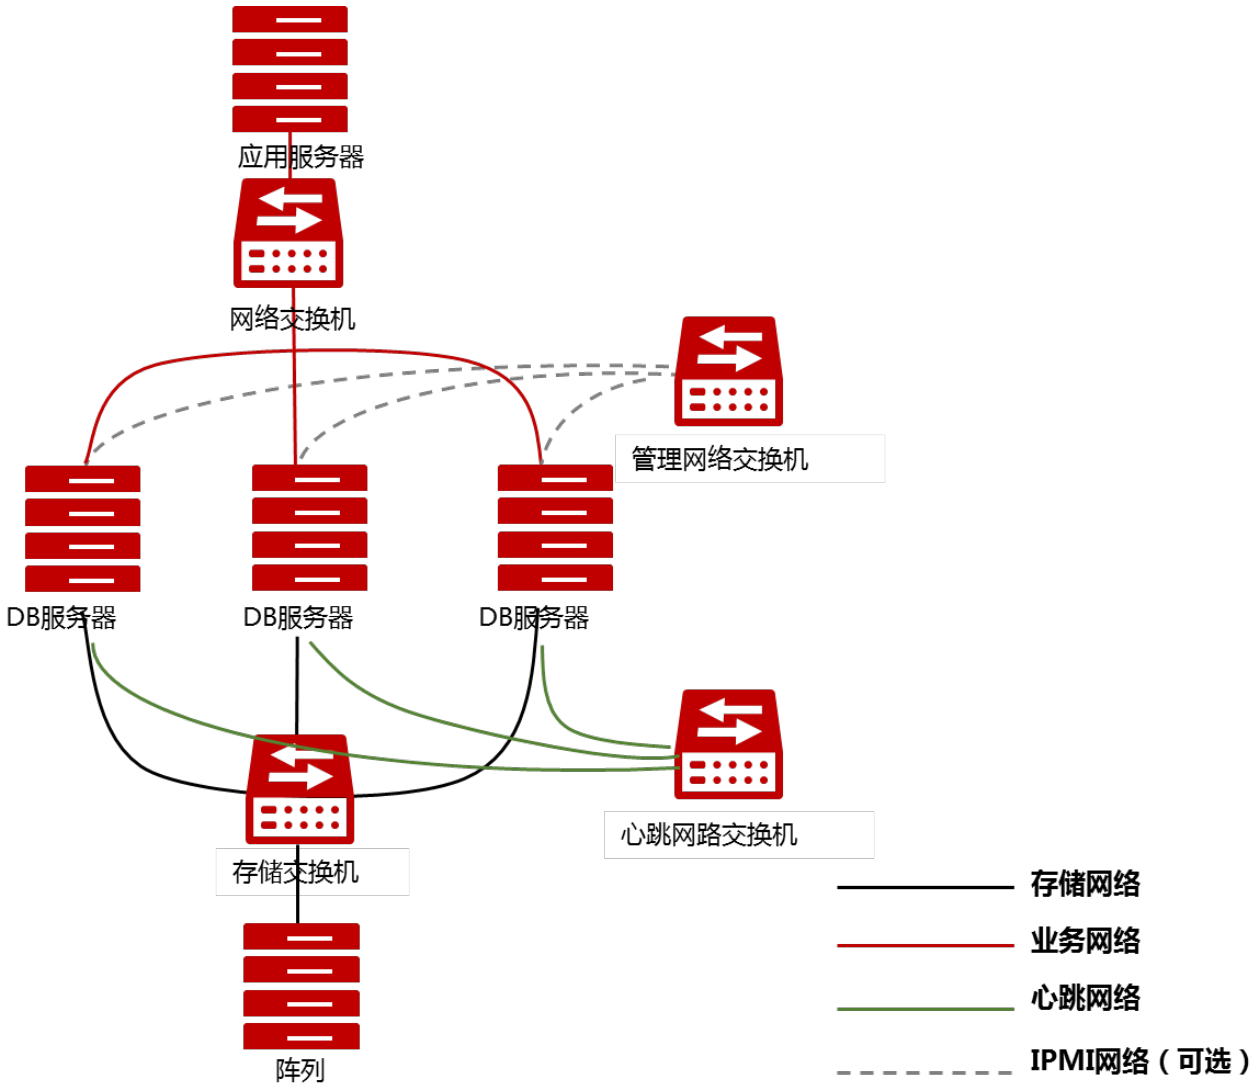

1.4　KingbaseES RAC 集群依赖组件介绍

本章节包含以下内容：

- Kingbase Clusterware 概述
- Kingbase Clusterware 的作用

1.4.1　Clusterware 概述

金仓集群资源管理软件（简称：Kingbase Clusterware）可提供集群成员管理、故障检测、处置调度等功能。可用于构建共享存储集群冷备方案，在单机已经满足性能需求的情况下，低成本的增加 KingbaseES 数据库的可用性。

同时，也是金仓 KingbaseES RAC 集群数据库软件所依赖的集群管理组件。

Kingbase Clusterware 作为全局资源管理的系统，可以解决大部分分布式系统中出现的问题，如脑裂、集群节点的增减等问题。作为去中心化的系统，避免了中心节点由于集群过大带来的过多负载压力的问题，在大集群应用的情况能够很好的提供集群系统的高吞吐、高压力、高负载的承载。

1.4.2　Clusterware 的作用

Kingbase Clusterware 主要提供集群管理服务功能，在部署时，需要将 Clusterware 部署在集群中的每个节点上。

为了实现多节点数据共享的功能，需要提供多节点共享的存储设备，通常需要两块 SAN 设备分别作为数据存储及投票存储。

基于共享存储中的投票存储，Corosync-qdevice 进程会进行选举，实现分区 quorum 的判定，从而避免集群脑裂的发生。

在选举中赢得选举的分区，分区内各个节点上的 Corosync 之间会达成共识，并形成通信网络。这样当我们通过 crmsh（Kingbase Clusterware 提供的服务管理工具）配置 Pacemaker 管理的资源时，配置信息会通过 Corosync 广播到整个集群。

除了配置的广播，Corosync 还会实现运行中各种状态和数据的通信，是 Clusterware 的通信子系统。同时由于 corosync-qdevice 也会通过 corosync 实现各节点配置读取和通信，因此在启动时，需要先启动 corosync 服务。

在 Corosync 服务（包括 qdevice）启动后，需要拉起 Pacemaker 服务。Pacemaker 主要负责管理外部资源，包括 VIP、Filesystem 以及分库资源。通过 crmsh 可以有效的操作 Pacemaker 按照各种规则和约束去管理各类资源。

实际上，crmsh 是管理员（DBA）最常用的 Clusterware 工具，是管理员配置和管理 Pacemaker 以及 Pacemaker 管理的资源的重要手段。

备注:

最重要的是，Kingbase Clusterware 能够自动快速地完成数据库及数据库所需依赖的部署，这能在部署时极大的减少需要执行的操作及学习成本

第2章　快速安装 KingbaseES RAC 集群

本章节包含以下内容：

- 环境准备
- 获取集群软件包
- 安装集群
- 对外控制权限需求

2.1　环境准备

2.1.1　部署规划

下图为组网示意图

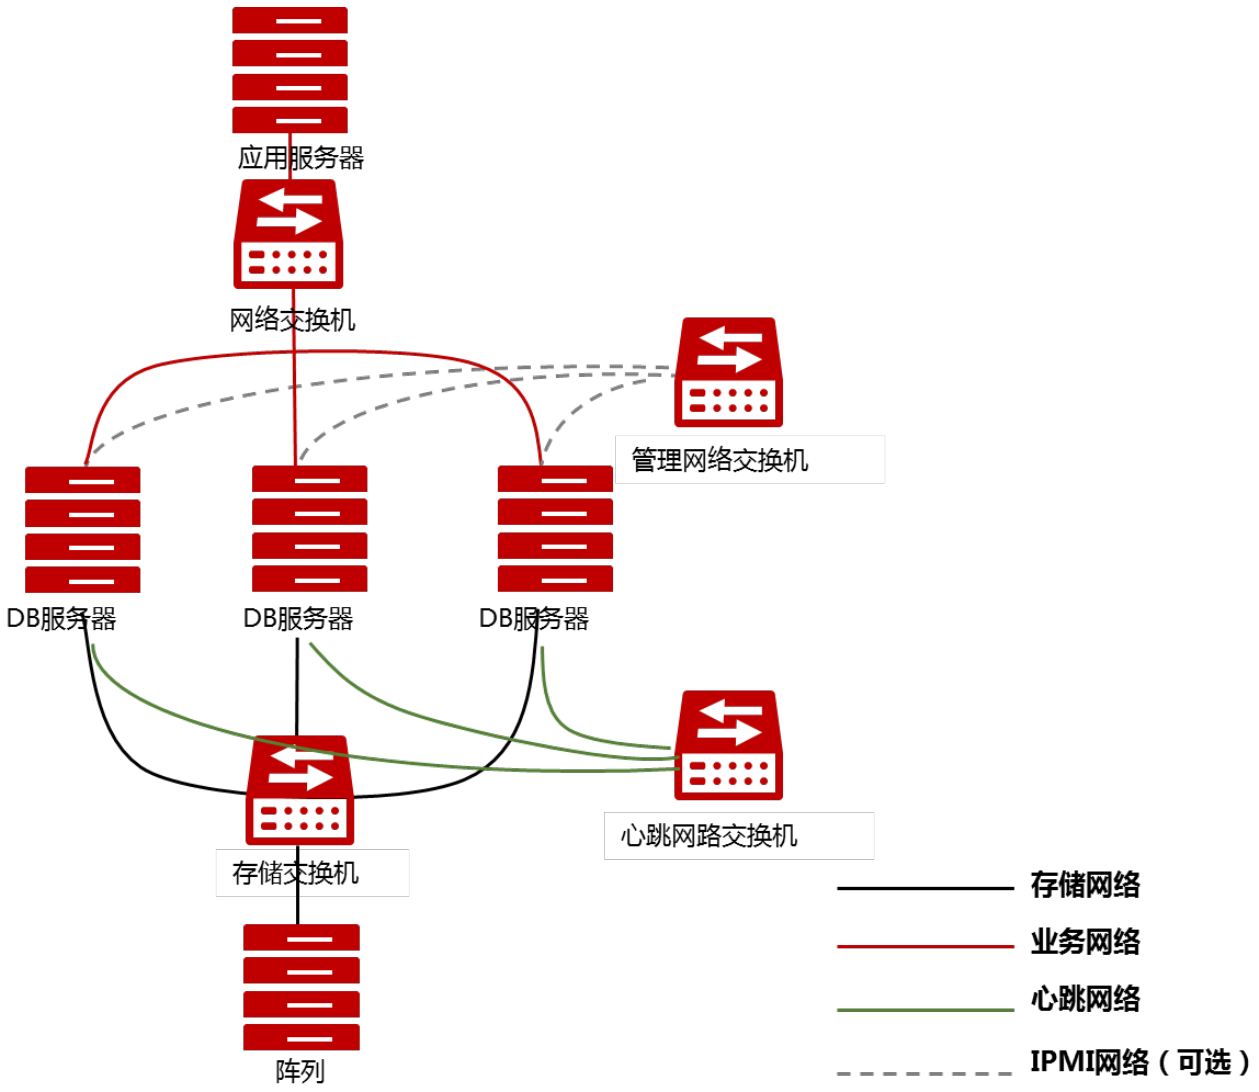
应用服务器
网络交换机
管理网络交换机
DB服务器
DB服务器
DB服务器
心跳网路交换机
存储交换机
阵列
存储网络
业务网络
心跳网络
IPMI网络（可选）

2.1.2　服务器需求

表 2.1.1: 服务器需求

序号	设备类型	设备型号	数量	硬件配置	备注
1	服务器	数据库服务器	2 ~ 8	CPU：建议 16 核以上 X64 CPU，支持 ARM CPU，可根据实际环境调整 内存：建议 32GB 以上内存容量，可根据实际环境调整 网络：1000Mb 带宽以上网卡，可根据实际环境调整 本地存储：200GB 以上容量，可根据实际环境调整 操作系统版本：UOS 20 以上、Kylin V10 以上或 CentOS 7.6 以上，可根据实际环境调整 管理网络接口（可选）： 物理机：具备 IPMI 类管理接口，网络独立于数据库服务网络虚拟机/容器：提供远程电源控制接口和认证方式	
2	共享存储	数据库共享存储	1	存储可靠性：具备容错能力（RAID 或副本形式），可根据实际环境调整 存储容量：2 个 LUN： 数据存储 LUN：适应数据容量的容量，推荐 500GB 以上，可根据实际环境调整 投票盘 LUN：100MB 存储网络：FC SAN 或 IP SAN 网络，可根据实际环境调整	存储网络支持数据库节点同时以块设备形式挂载共享存储

2.1.3　集群网络需求

表 2.1.2: 集群网络需求

细项	服务器	数量 (IP)	容量	备注
集群服务网络	数据库服务器	同服务器数	1000Mb 以上	数据库服务网络，业务访问使用，建议提供网络级冗余
集群心跳网络	数据库服务器	同服务器数	1000Mb 以上	数据库心跳网络，集群内部通信及心跳使用，建议提供网络级冗余
集群存储网络（IP SAN）	数据库服务器	同服务器数	1000Mb 以上	数据库存储网络，若采用 IP SAN 存储网络时，数据库与存储设备通信使用，建议提供网络级冗余。采用 FC SAN 存储网络时，不需要此项
集群带外控制网络（可选）	数据库服务器	同服务器数	100Mb 以上	可选项，用于连接裸金属服务器带外控制网络。

2.1.4　对外控制权限需求

提供对数据库服务器电源带外控制接口、接口鉴权方法及对应的权限。

2.2　获取集群软件包

请在安装过程中选择 KingbaseES RAC 模式，安装完成之后，确认 KingbaseES RAC 数据库已经被成功装载在数据库安装目录下，例如/home/kingbase/KingbaseRAC/Server。

在安装目录下，找到 install/script 子目录，使用 root 用户执行 rootDeployClusterware.sh。然后确认 clusterware 的相关组件已经被成功装载在/opt/KingbaseHA 目录下。

2.3　安装集群

2.3.1　参数配置

下面是两节点 KingbaseES RAC 在部署时参数示例，可根据实际环境对参数配置文件进行修改。模板信息如下：

选项	值
节点 1 IP	192.168.5.1
节点 2 IP	192.168.5.2
网卡名称	ens192
VIP IP	10.12.11.200/24
网关	10.12.11.254
投票盘	/dev/sde
数据盘	/dev/sdb
分布式文件系统挂载点	/sharedata

参数示例

上述示例的 cluster_manager.conf 参数文件内容如下:

```
cluster_name=kcluster
node_name=(H-10-10-9-1 H-10-10-9-2)
node_ip=(192.168.5.1 192.168.5.2)

enable_qdisk=1
votingdisk=/dev/sde

enable_gfs2=1
sharedata_disk=/dev/sdb

enable_nfs=0
nfs_server=192.168.4.5
nfs_server_dir=/volume1/nfs_server

sharedata_dir=/sharedata

init_disk=1
```

```
enable_initdb=1

install_dir=/opt/KingbaseHA
env_bash_file=/root/.bashrc

keep_cluster_alive=0

pacemaker_daemon_group=haclient
pacemaker_daemon_user=hacluster

kingbaseowner=kingbase
kingbasegroup=kingbase

kingbase_install_dir=/home/kingbase/KingbaseRAC/Server

database="test"
db_user="system"
db_port=54321
db_mode="oracle"
db_auth="scram-sha-256"
password="123456"
initdb_options="-A $db_auth -U $db_user -m $db_mode"

enable_fence=1

enable_esxi=1
esxi_server=192.168.4.5
esxi_user=root
esxi_passwd="Kingbase@99"

enable_ipmi=0
ipmi_server=(192.168.2.100 192.168.2.101)
ipmi_user=(Administrator Administrator)
ipmi_passwd=("Admin@9000" "Admin@9000")

enable_qdisk_fence=0
qdisk_watchdog_dev=/dev/watchdog
qdisk_watchdog_timeout=30
enable_vip=1
virtual_ip=(10.12.11.200/24)
net_device=(ens192)
net_device_ip=(192.168.5.1 192.168.5.2)

enable_heuristics=1
```

```
heuristics_interval=1000
heuristics_timeout=10000
heuristics_ping_gateway="10.12.11.254"
heuristics_reskey_attempts=1
heuristics_exec="exec_ping: /bin/ping -q -c $heuristics_reskey_attempts $heuristics_ping_gateway"

install_rac=1

rac_lms_port=53444
rac_lms_count=7
rac_data=data

install_ssma=0

ssma_data_disk=("-U f0c8f59d-0cc8-473c-970d-d19b30d87f5e" "-U 7075f361-f3ad-48cf-87cc-ecc3db4a063a")
ssma_data_dir=(/sharedata/data1 /sharedata/data2)
ssma_port=(36321 36322)
ssma_fstype=ext4

connection_timeout="10"

ssh_port="22"

use_scmd=0

scmd_port="8890"
scmd_install_dir=/home/kingbase/KingbaseRAC/securecmdd
```

2.3.2　节点间互信配置

1. 安装数据库成功后，在 $ {install_dir}/ ClientTools/ guitools/ DeployTools/ zip/目录下获取 install.conf、trust_cluster.sh 和 securecmdd.zip；

对于通过 sshd 服务进行 RAC 一键部署：

2. 编辑 install.conf 配置文件，在选项 all_ip 后填写所有节点 ip；
3. 使用 trust_cluster.sh 进行 ssh 免密配置，在配置过程中，由于脚本是交互式的，因此需要用户输入必要信息；

对于启动 sys_securecmdd 工具进行 RAC 一键部署：

2. 将 securecmdd.zip 解压到合适的目录下；
3. 可选择的编辑 share 目录下的 sys_HAscmdd.conf，以更改 securecmdd 的配置；
4. 在每个节点的 securecmdd/bin 目录下执行 sh sys_HAscmdd.sh init 以初始化 securecmdd；
5. 在每个节点的 securecmdd/bin 目录下执行 sh sys_HAscmdd.sh start 以启动 securecmdd。

信息:

本示例采用了 ssh 部署

2.3.3 集群搭建

使用 root 用户登录集群任意节点执行：

```
cd /opt/KingbaseHA
./cluster_manager.sh --deploy
```

2.3.4 集群状态查看

使用 root 用户登录集群任意节点执行：

```
[root@H-10-10-9-1 KingbaseHA]# cd /opt/KingbaseHA
[root@H-10-10-9-1 KingbaseHA]# ./cluster_manager.sh --deploy
[root@H-10-10-9-1 KingbaseHA]# crm status
Cluster Summary:
  * Stack: corosync
  * Current DC: H-10-10-9-1 Pacemaker (Kingbase) V009R001C010 (2.0.3.0.0 4b1f869f0f:126ade653d0b) -
partition with quorum
  * Last updated: Thu Feb 20 05:33:06 2025
  * Last change:  Thu Feb 20 01:51:24 2025 by root via cibadmin on H-10-10-9-2
  * 2 nodes configured
  * 6 resource instances configured

Node List:
  * Online: [ H-10-10-9-1 H-10-10-9-2 ]

Full List of Resources:
  * esxi_fence  (stonith:fence_vmware_soap):     Started H-10-10-9-1
  * Clone Set: clone-gfs2 [gfs2]:
    * Started: [ H-10-10-9-1 H-10-10-9-2 ]
  * VIP0        (ocf::heartbeat:IPaddr2):        Started H-10-10-9-1
  * Clone Set: clone-DB [DB]:
    * Started: [ H-10-10-9-1 H-10-10-9-2 ]
```

第3章　命令行安装

3.1　KingbaseES RAC 部署资源需求

本章节包含以下内容：

- 部署规划
- 服务器需求
- 集群网络需求
- 对外控制权限需求

3.1.1　部署规划

下图为组网示意图

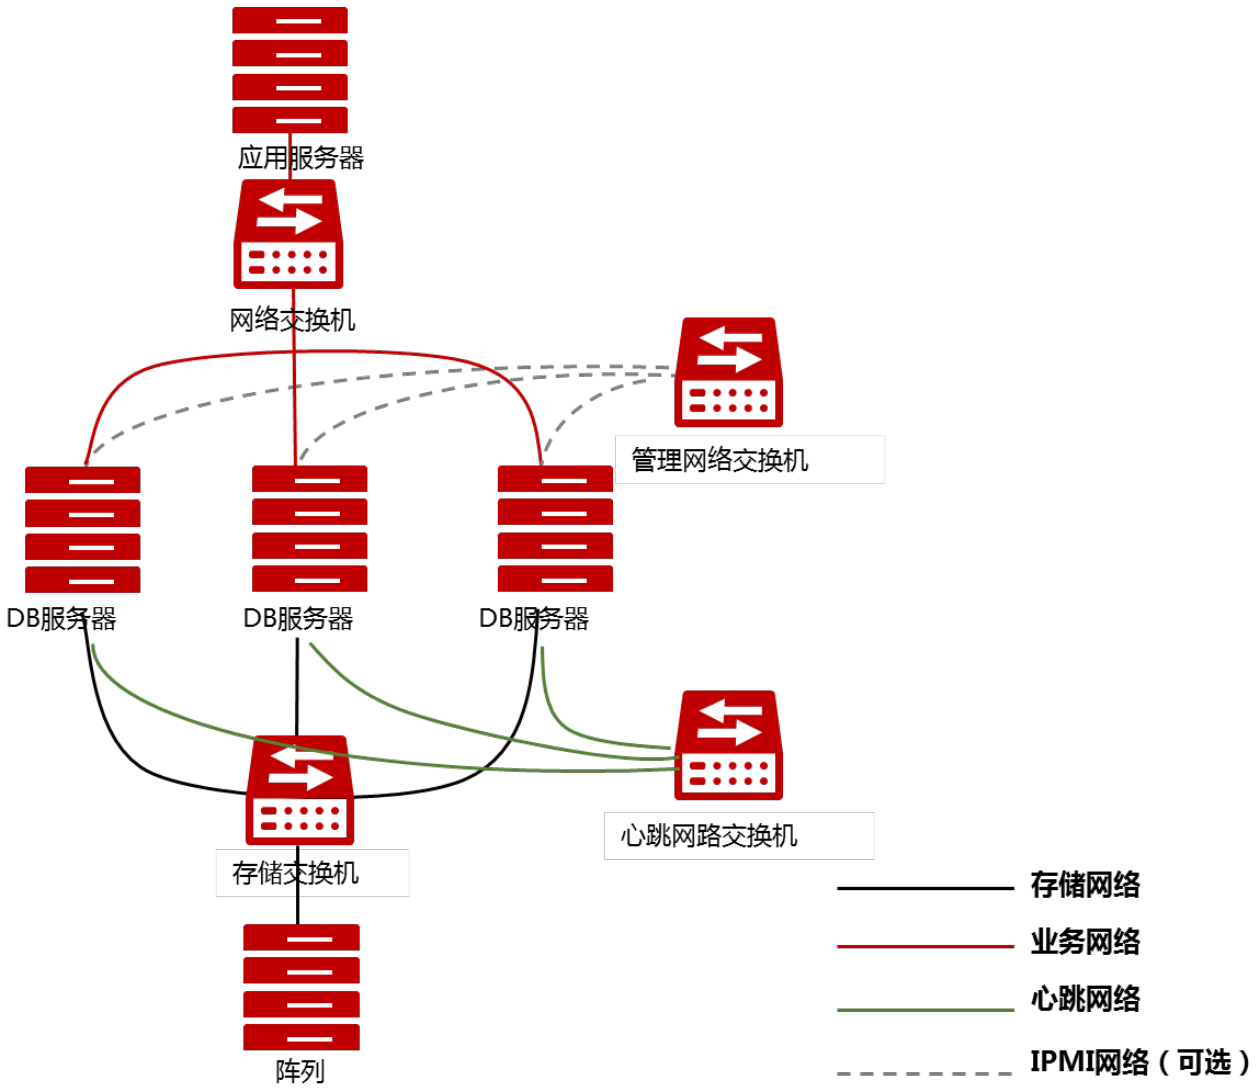
应用服务器
网络交换机
管理网络交换机
DB服务器
DB服务器
DB服务器
心跳网路交换机
存储交换机
阵列
存储网络
业务网络
心跳网络
IPMI网络（可选）

3.1.2　服务器需求

表 3.1.1: 服务器需求

序号	设备类型	设备型号	数量	硬件配置	备注
1	服务器	数据库服务器	2 ~ 8	CPU：建议 16 核以上 X64 CPU，支持 ARM CPU，可根据实际环境调整 内存：建议 32GB 以上内存容量，可根据实际环境调整 网络：1000Mb 带宽以上网卡，可根据实际环境调整 本地存储：200GB 以上容量，可根据实际环境调整 操作系统版本：UOS 20 以上、Kylin V10 以上或 CentOS 7.6 以上，可根据实际环境调整 管理网络接口（可选）： 物理机：具备 IPMI 类管理接口，网络独立于数据库服务网络虚拟机/容器：提供远程电源控制接口和认证方式	
2	共享存储	数据库共享存储	1	存储可靠性：具备容错能力（RAID 或副本形式），可根据实际环境调整 存储容量：2 个 LUN： 数据存储 LUN：适应数据容量的容量，推荐 500GB 以上，可根据实际环境调整 投票盘 LUN：100MB 存储网络：FC SAN 或 IP SAN 网络，可根据实际环境调整	存储网络支持数据库节点同时以块设备形式挂载共享存储

3.1.3　集群网络需求

表 3.1.2: 集群网络需求

细项	服务器	数量 (IP)	容量	备注
集群服务网络	数据库服务器	同服务器数	1000Mb 以上	数据库服务网络，业务访问使用，建议提供网络级冗余
集群心跳网络	数据库服务器	同服务器数	1000Mb 以上	数据库心跳网络，集群内部通信及心跳使用，建议提供网络级冗余
集群存储网络（IP SAN）	数据库服务器	同服务器数	1000Mb 以上	数据库存储网络，若采用 IP SAN 存储网络时，数据库与存储设备通信使用，建议提供网络级冗余。采用 FC SAN 存储网络时，不需要此项
集群带外控制网络（可选）	数据库服务器	同服务器数	100Mb 以上	可选项，用于连接裸金属服务器带外控制网络。

3.1.4　对外控制权限需求

提供对数据库服务器电源带外控制接口、接口鉴权方法及对应的权限。

3.2　环境配置

本章节包含以下内容：

- 操作系统配置
- RAC 数据库和 Clusterware 组件配置
- 共享存储配置
- 开机自启
- 系统配置检查

3.2.1　操作系统配置

3.2.1.1　创建数据库用户

为了使共享磁盘在节点间迁移时不会因改变属主而失去访问权限，我们需要保证共享磁盘的属主（也就是拥有 KingbaseES 实例的用户）在每个节点上的 uid 和 gid 一致。

```
useradd -u2000 kingbase
```

备注:

用户 UID 不是必须为 2000，可以根据实际情况指定（如果不指定 UID 则操作系统会自动分配），建议集群所有节点 kingbase 用户的 UID 都相同。

查看当前用户的 uid 和 gid。

```
cat /etc/passwd
```

3.2.1.2　操作系统参数配置

和 KingbaseES 的操作系统配置要求相同。

3.2.1.3　网络与防火墙配置

如果对网络安全要求不高，可以关闭防火墙，使用 root 用户执行如下命令:

备注:

不同系统命令不同，以下命令以 CentOS7 为例

```
systemctl status firewalld  # 查看 firewalld 状态
systemctl stop firewalld
systemctl disable firewalld  # 禁用开机自启，可选
```

如果想保留防火墙，那么需要在防火墙添加数据库和集群件使用端口的白名单，需要添加的端口号如下：

集群软件默认采用 udp 协议，端口号是 5405、30865、5560、7630，而 dlm 采用 tcp 协议，端口号是 21064。

KingbaseES RAC 数据库默认采用 tcp 协议，数据库服务端口默认 54321，lms 进程端口默认为 53444 ~ 53450（7 个），请根据实际配置调整。

假设开放 54321 端口，使用 root 用户执行如下命令：

```
systemctl status firewalld  # 查看 firewalld 状态
firewall-cmd --zone=public --add-port=54321/tcp --permanent
firewall-cmd --reload
```

如果在拓扑环境中对网络端口有权限管理的，也可以参照上文所要求的端口对集群中的机器添加访问权限。

3.2.1.4　配置时间同步

可选的，在系统中配置 NTP 实现时间同步。

1. 环境中有时间服务器的情况下各节点同步时间服务器

   a）如果时间服务器端有客户端 IP 限制，加入各节点 IP

   b）各节点在 ntp.conf 中加入时间服务器配置

   ```
   server 时间服务器 IP prefer
   fudge 时间服务器 IP stratum 10
   ```

2. 环境中没有时间服务器的情况下设置集群中一个节点为 NTP 服务器，其他节点向此服务器同步时间。使用此种方式时要注意在 NTP 服务器节点故障修复后重新加入网络时需要手动检查系统时间，可以设置为比运行节点中时间最快的更快几秒。

   a）NTP 服务器节点在 ntp.conf 中加入向本地时间同步设置

   ```
   server 127.127.1.0 prefer
   fudge 127.127.1.0 stratum 10
   restrict [子网 IP] mask [子网掩码]
   ```

   b）NTP 客户端各节点在 ntp.conf 中加入时间服务器配置

   ```
   server 时间服务器 IP prefer
   fudge 时间服务器 IP stratum 10
   ```

KingbaseES RAC 不使用物理时钟，因此时间同步非必须配置项，但是仍建议进行配置，这可以增加集群的易管理性和易维护性。

3.2.2　RAC 数据库和 Clusterware 组件配置

3.2.2.1　采用安装包安装

请在安装过程中选择 KingbaseES RAC 模式，安装完成之后，确认 KingbaseES RAC 数据库已经被成功装载在数据库安装目录下，例如/home/kingbase/KingbaseRAC/Server。

在安装目录下，找到 install/script 子目录，使用 root 用户执行 rootDeployClusterware.sh。然后确认 clusterware 的相关组件已经被成功装载在/opt/KingbaseHA 目录下。

3.2.2.2　采用绿色版安装

1. 安装 KingbaseES RAC 数据库

下载 KingbaseES RAC 绿色版，名如 kingbase-rac-VXXXXXXXXXX-linux-x86_64.tar

将软件包放至新建用户（如 kingbase 用户）的家目录下，执行如下指令解压缩，在所有节点上解压 Kingbase RAC 包。

在新建用户（如 kingbase 用户）的家目录，执行如下命令：

```
tar -xvf kingbase-rac-VXXXXXXXXXX-linux-x86_64.tar
```

更改解压后文件（假设为 KingbaseES_RAC 目录）所有者及文件权限为新建用户（如 kingbase 用户），执行如下命令：

```
chown -R kingbase:kingbase KingbaseES_RAC
chmod -R 755 KingbaseES_RAC
```

2. 安装 clusterware

下载 clusterware 绿色版，名如 kingbase-clusterware-linux-x86_64.tar

将软件包放至系统安装目录下，执行如下命令解压缩，在所有节点上解压 KingbaseHA 包。

安装目录支持用户自定义路径，以/opt/目录为例，执行如下命令：

```
tar -xvf kingbase-clusterware-linux-x86_64.tar
```

备注:

1) clusterware 绿色版建议放至于/opt/目录下，并且解压后目录名为 KingbaseHA

2) 要求在集群所有节点上均完成 clusterware 绿色版的安装

3.2.3　共享存储配置

在执行下述安装操作前，需要准备好两块共享存储，一块作为投票盘，大小不小于 100MB，一块作为数据盘，大小可根据实际环境设置。

可采用 iSCSI 设备或其他多点可见存储设备作为共享存储。

如果只有一块共享存储，可采用分区方式来对投票盘和数据盘进行区分，可以采用 fdisk 或 parted 命令进行分区。

下面以 fdisk 命令为例，执行如下命令，列出可用的共享存储：

```
fdisk -l
```

假设共享存储为/dev/sdb，执行如下命令，启动 fdisk 工具：

```
fdisk /dev/sdb
```

在 fdisk 交互界面中，可以使用 n 命令创建新分区。

根据共享存储需求进行分区操作，例如投票盘 LUN 应不小于 100MB，数据存储 LUN 适应数据容量的容量，推荐 500GB 以上。

分区完成后，使用 w 命令保存并退出交互界面，即可区分投票盘和数据盘，并进行后续操作。

3.2.4 开机自启

KingbaseES RAC 集群的开机自启属于可选功能。

Clusterware 提供了开机自启功能，即集群节点故障后，重新启动时，可以自动地加入集群并继续提供服务。

下面的操作，仅对执行节点有效。

1) 功能开启需确保 cluster_manager.conf 中的 keep_cluster_alive 参数被配置为 1，该参数默认为 0 关闭。

   如果执行搭建集群前开启了 keep_cluster_alive 参数，则该功能会随着部署命令 base_configure_init 自动配置，无需手动执行 config_keep_cluster_alive 进行配置。

2) 使用如下命令，手动开启开机自启功能。

备注:

需要保证第一步 keep_cluster_alive 参数为 1 开启，否则命令执行不成功。

```
sh cluster_manager.sh --config_keep_cluster_alive
```

---

3) 使用如下命令，手动关闭开机自启功能。

备注:

彻底关闭开机自启功能需要保证第一步 keep_cluster_alive 参数为 0 关闭，否则调用“sh cluster_manager.sh --start”手动拉起集群会恢复开机自启功能。

```
sh cluster_manager.sh --clean_keep_cluster_alive
```

备注:

1) 开机自启功能依赖于操作系统的 crontab service 服务，使用前请确认系统 crontab service 服务是否正常运行。
2) 开机自启功能开启后，不支持停单一组件的命令（包含 stop_corosync、stop_pacemaker、stop_qdevice）。
3) 节点集群组件整体停止命令“sh cluster_manager.sh －stop”会自动关闭开启自启功能，同样地，彻底关闭开机自启功能仍需要保证 keep_cluster_alive 参数为 0 关闭。

3.2.5 系统配置检查

在部署集群前，需要检查/root/.bashrc 和/etc/hosts 是否存在残留配置。

3.2.5.1 检查环境变量

如果是重新部署 clusterware，部署前需要正确清理 clusterware 环境：

```
./cluster_manager.sh --clean_all
```

如果当前配置的安装目录跟之前的安装目录不相同，则该命令也不能保证环境的完整清理，/root/.bashrc 可能会有上次安装残留的环境变量，建议在安装前手动检查：

```
vi /root/.bashrc
```

以安装目录/opt/KingbaseHA 举例，跟 clusterware 相关的环境变量配置如下所示：

```
export install_dir=/opt/KingbaseHA
export PATH=/opt/KingbaseHA/python2.7/bin:/opt/KingbaseHA/pacemaker/sbin/:$PATH
export PATH=/opt/KingbaseHA/crmsh/bin:/opt/KingbaseHA/pacemaker/libexec/pacemaker/:$PATH
export PATH=/opt/KingbaseHA/corosync/sbin:/opt/KingbaseHA/corosync-qdevice/sbin:$PATH
export PYTHONPATH=/opt/KingbaseHA/python2.7/lib/python2.7/site-packages/:/opt/KingbaseHA/crmsh/lib/python2.
7/site-packages:$PYTHONPATH
export COROSYNC_MAIN_CONFIG_FILE=/opt/KingbaseHA/corosync/etc/corosync/corosync.conf
export CRM_CONFIG_FILE=/opt/KingbaseHA/crmsh/etc/crm/crm.conf
export OCF_ROOT=/opt/KingbaseHA/pacemaker/ocf
export HA_SBIN_DIR=/opt/KingbaseHA/pacemaker/sbin/
export QDEVICE_SBIN_DIR=/opt/KingbaseHA/corosync-qdevice/sbin/
export LD_LIBRARY_PATH=/opt/KingbaseHA/lib64/:$LD_LIBRARY_PATH
export HA_INSTALL_PATH=/opt/KingbaseHA
export PATH=/opt/KingbaseHA/dlm-dlm/sbin:/opt/KingbaseHA/gfs2-utils/sbin:$PATH
export LD_LIBRARY_PATH=/opt/KingbaseHA/corosync/lib/:$LD_LIBRARY_PATH
```

上述每项配置有且仅有一个，如果在安装前发现/root/.bashrc 中有类似的配置，请手动删除相关的配置。

3.2.5.2　检查 hosts

排查环境中 hosts 配置是否有冲突项：

```
vi /etc/hosts
```

检查 hosts 文件，删除冲突项，并确认当前要配置的节点 IP 和节点名是否已存在，如果存在则手动删除。

3.3　KingbaseES RAC 集群的安装

本章节包含以下内容：

- 基于 CLI 搭建集群
- 基于命令行搭建集群

3.3.1　基于 CLI 搭建集群

3.3.1.1　基于 SAN 设备搭建

备注:

1) 要求所有节点 KingbaseES RAC 数据库和 clusterware 已安装完成
2) 脚本部署过程需用 root 用户执行

3.3.1.1.1　配置参数

1. 进入 KingbaseHA 目录（以/opt 目录为例）：

   ```
   cd /opt/KingbaseHA
   ```

2. 执行如下命令，修改集群搭建必要参数：

   ```
   vim cluster_manager.conf
   ```

   如果安装目录不是 `/opt/KingbaseHA` , 则需要将配置文件 cluster_manager.conf 内的 `install_dir` 参数设置为用户自定义的路径。例如：`install_dir=/home/test/KingbaseHA` 。

   重要参数如下：

表 3.3.1: 配置参数

变量名称	默认值	意义
cluster_name	kcluster	集群的名字，用于生成 corosync.conf 中的 cluster_name 以及 devicedisk 模型中的 label，用于基于 label 查找投票盘
node_name	(node1 node2)	节点名称，用于配置 corosync.conf 中的 ring0_addr 以及 hosts 中的节点主机名
node_ip	(192.168.5.1 192.168.5.2)	host 中的节点 IP 地址，一般使用内网 IP 地址
enable_qdisk	1	是否启用 qdisk
votingdisk	/dev/sdc	投票盘，需要物理存在，用于 qdevice 共享磁盘心跳
enable_gfs2	1	是否启用 gfs2 集群文件系统
sharedata_disk	/dev/sdb	共享数据盘
enable_nfs	0	是否启用 nfs 文件系统
nfs_server	192.168.4.5	用于配置 nfs 服务端 IP 地址
nfs_server_dir	/volume1/nfs_server	nfs 服务端的共享目录
sharedata_dir	/sharedata	集群文件系统挂载目录
init_disk	1	是否初始化投票盘和共享数据盘
enable_initdb	1	是否执行 initdb 初始化数据库
install_dir	/opt/KingbaseHA	KingbaseHA 安装目录，注意与 kingbase_install_dir 区分
kingbaseowner	kingbase	Kingbase 数据库的属主
kingbasegroup	kingbase	Kingbase 数据库用户所在的用户组
kingbase_install _dir	/home/kingbase/ KingbaseRAC/Server	Kingbase 服务器安装的路径
database	”test”	数据库名
username	”system”	数据库用户名
password	”123456”	密码（如果没有密码登录数据库，则无法提供密码项）
enable_fence	1	是否启用故障隔离
enable_qdisk_fence	1	是否启用基于 qdisk 的故障隔离

-续表-

变量名称	默认值	意义
qdisk_watchdog_dev	/dev/watchdog	用于配置 fence_qdisk 的 watchdog 的设备文件，目前仅支持默认值/dev/watchdog，无需修改
qdisk_watchdog_timeout	30	用于配置 fence_qdisk 的 watchdog 的超时时间，单位为秒
enable_vip	0	是否启用 VIP
virtual_ip	(192.168.4.1/24 192.168.4.2/24)	虚拟 IP 地址，其配置数量应小于等于节点个数，配置格式为 IPv4,v6/NETMASK
net_device	(bond0 bond0)	与虚拟 IP 绑定的网卡，其配置数量等于节点个数或只配一个（各个节点网卡一致）
net_device_ip	(10.12.2.125 10.12.2.127)	指定网卡上的实 IP，其配置数量必须等于节点个数
install_rac	1	是否采用 KingbaseES RAC 方案安装数据库
rac_port	54321	KingbaseES RAC 数据库端口号
rac_lms_port	53444	KingbaseES RAC lms 端口号的起始位置，其后 rac_lms_count 个端口需空闲
rac_lms_count	7	KingbaseES RAC 数据库启动时 lms 进程的数量，默认为 7 个
rac_data	data	KingbaseES RAC 数据库的数据集簇
connection_timeout	10	用于配置 sshd 或者 scmd 的超时时间，单位为秒
ssh_port	22	sshd 的端口号
use_scmd	0	是否使用 scmd 搭建节点间免密，‘1’表示使用 scmd，‘0’表示使用 sshd
scmd_port	8890	scmd 的端口号
scmd_install_dir	/home/kingbase/KingbaseRAC/securecmdd	scmd 安装目录

所有可配置的参数可以参照《Clusterware 安装和运维指南》中“cluster_manager.conf 配置文件中的可配置项”章节。

3.3.1.1.2　集群免密部署

节点间免密配置：

1. 安装数据库成功后，在 $ {install_dir}/ ClientTools/ guitools/ DeployTools/ zip/目录下获取 install.conf、trust_cluster.sh 和 securecmdd.zip；

对于通过 sshd 服务进行 RAC 一键部署：

2. 编辑 install.conf 配置文件，在选项 all_ip 后填写所有节点 ip；
3. 使用 trust_cluster.sh 进行 ssh 免密配置，在配置过程中，由于脚本是交互式的，因此需要用户输入必要信息；

对于启动 sys_securecmdd 工具进行 RAC 一键部署：

2. 将 securecmdd.zip 解压到合适的目录下；
3. 可选择的编辑 share 目录下的 sys_HAscmdd.conf，以更改 securecmdd 的配置；
4. 在每个节点的 securecmdd/bin 目录下执行 sh sys_HAscmdd.sh init 以初始化 securecmdd；
5. 在每个节点的 securecmdd/bin 目录下执行 sh sys_HAscmdd.sh start 以启动 securecmdd。

免密部署：

首先请保证节点间完成免密，随后在在集群任一节点上按需配置 cluster_manager.conf，并在该节点上执行如下命令：

```
./cluster_manager.sh --deploy
```

最后在运行终端执行：

```
source /root/.bashrc
```

以使得该终端环境变量生效。

3.3.1.1.3　集群非免密部署

1. 同步配置文件（将配置文件拷贝到各个节点）：

```
scp cluster_manager.conf root@rac04:/opt/KingbaseHA/
```

2. 初始化投票盘

任选一节点执行如下命令（以下命令支持免交互执行，详见 - help 中的帮助说明）：

```
./cluster_manager.sh --qdisk_init
```

3. 初始化数据盘

任选一节点执行如下命令（以下命令支持免交互执行，详见 - help 中的帮助说明）：

```
./cluster_manager.sh --cluster_disk_init
```

4. 基础组件初始化

在所有节点执行如下命令，更新操作系统内核的 gfs2 模块（以下命令支持免交互执行，详见 - help 中的帮助说明）：

```
./cluster_manager.sh --init_gfs2
```

在所有节点执行如下命令，初始化所有基础组件，如 corosync，pacemaker，corosync-qdevice：

```
./cluster_manager.sh --base_configure_init
```

5. 集群相关资源初始化

任选一节点执行如下命令，配置 fence、dlm、gfs2 和 db 资源：

```
source /root/.bashrc
./cluster_manager.sh --config_resource
```

3.3.1.2　基于 NAS 设备搭建

3.3.1.2.1　配置约束

在执行下述安装操作前，需要准备好共享存储或文件系统，保证其正常运行。

假设 NFS 服务端 ip 为 192.168.5.1，共享目录为/sharedata/nfs_data

NFS 的客户端将挂载服务端的共享目录并运行 KingbaseES RAC 集群

注意:

```
为避免数据不一致的问题请确保 NFS 客户端和服务端操作系统内核版本的一致

执行如下命令查看操作系统内核版本：
```

```
    uname -a | awk '{print $3}'
```

3.3.1.2.2　参数配置

首先，进入 KingbaseHA 目录：

```
cd /opt/KingbaseHA
```

执行如下命令，修改集群搭建必要参数：

```
vim cluster_manager.conf
```

信息:

1) 要求 enbale_gfs2 配置项为 0
2) 要求 enable_nfs 配置项为 1
3) NAS 设备不可以作为投票盘，如果需要投票盘必须额外提供一块 SAN 设备
4) 启用 NAS 设备需要配置 nfs_server 以及 nfs_server_dir

   在本例中 NAS 设备相关参数可以配置为:

```
enbale_gfs2=0

enable_nfs=1

nfs_server=192.168.5.1

nfs_server_dir=/sharedata/nfs_data

sharedata_dir=/sharedata
```

这代表客户端将在 `sharedata_dir` 目录上使用 `NFS` 文件系统挂载远程服务器 `nfs_server` 的 `nfs_server_dir` 目录

具体参数参见“配置参数”章节。

3.3.1.2.3　集群部署

1. 初始化基础组件

在所有节点执行如下命令，初始化并运行 corosync、pacemaker 等基础组件：

```
./cluster_manager.sh --base_configure_init
```

2. 初始化 KingbaseES RAC 所需要的资源

任选一节点执行本节操作。

执行如下命令，初始化 fence、vip、集群文件系统、DB 等资源：

```
./cluster_manager.sh --config_resource
```

注意:

1) 不建议 NFS 服务端和客户端部署在一台机器上

2) 使用 NAS 设备如涉及多个节点之间的并发请启用 KingbaseES RAC 的 Direct I/O 功能

3.3.1.3 搭建时错误处理

若在环境搭建过程中出现不可恢复故障，可在所有节点执行如下命令，清除所有组件配置信息。

```
./cluster_manager.sh --clean_all
```

然后 **仔细检查环境依赖是否正确以及配置文件是否出错**, 并重新执行安装步骤。

备注:

执行 clean_all 命令将会删除集群的已修改的配置，包括集群软件和系统上的配置文件, 环境变量, 集群资源配置等，将集群还原到配置前的初始状态。该命令不会清除已经初始化的 kingbase 的 data 目录，如果需要清除数据目录，需要手动挂载目录，并清除。

3.3.1.4 卸载安装程序

如果要一键卸载安装的程序，每个节点执行如下命令：

```
./cluster_manager.sh --uninstall
```

备注:

执行 uninstall 命令，将会删除整个集群安装的目录，即 install_dir 变量指定的路径。该命令不会清除已经初始化的 kingbase 的 data 目录，如果需要清除数据目录，需要手动挂载目录，并清除。

3.3.2 基于命令行搭建集群

3.3.2.1 环境准备

1. 安装 Clusterware 集群软件

参考前一节安装 Clusterware 集群软件，包括 pacemaker、corosync、crmsh 等，启动对应服务。

2. 格式化文件系统

执行如下命令，格式化设备为 gfs2 文件系统。

```
/opt/KingbaseHA/gfs2-utils/sbin/mkfs.gfs2 -p lock_dlm -t clusterware:gfs2 -j 3 /dev/sdg
```

其中 Clusterware 需要和 corosync.conf 中的 cluster_name 保持一致，lock_dlm 不可以改变。

3. 添加环境变量

执行如下命令，添加环境变量。

```
vi /root/.bashrc
export PATH=/opt/KingbaseHA/dlm-dlm/sbin:/opt/KingbaseHA/gfs2-utils/sbin:$PATH
```

4. 配置 udev 规则

执行如下命令，复制 udev 脚本。

```
cp /opt/KingbaseHA/dlm-dlm/usr/lib/udev/rules.d/51-dlm.rules /etc/udev/rules.d
cp /opt/KingbaseHA/gfs2-utils/lib/udev/rules.d/82-gfs2-withdraw.rules /etc/udev/rules.d
```

3.3.2.2　搭建 gfs2 文件系统

以下操作，只需在某一台机器上执行。

资源：

- 一个 dlm 的 clone 资源
- 一个 gfs2 的 clone 资源

注意:

1) 在凝思操作系统 Rocky 6.0.60.4-696（2.6.32-696-linx-amd64），模块 linx-security-module 会导致 gfs2 文件系统在创建文件时，操作系统崩溃掉（crash），目前的解决方法如下（不建议卸载，建议升级凝思操作系统内核）。

```
apt-get remove --purge linx-security-module
rmmod linx-sec
```

2) 为防止一节点异常，其他正常节点短暂丢失 quorum，导致其文件系统重挂，可增加 no-quorum-policy=freeze 参数，命令如下。

```
crm configure property no-quorum-policy=freeze
```

3) 在安装 clusterware 时，配置脚本会自动检查创建/dev/misc 目录，并建立相关软连接。如果手动配置或者此目录被误删除，需要手动创建，命令如下。

```
mkdir /dev/misc
cd /dev/misc
```

```
ln -s ../dlm-control dlm-control
ln -s ../dlm-monitor dlm-monitor
ln -s ../dlm_plock dlm_plock
```

1. 配置 dlm 资源

配置 dlm 主资源

执行如下命令，配置 dlm primitive 资源。其中，如果操作系统自带 dlm_controld 和 dlm-tool，也可不指定 daemon 和 dlm_tool 参数，使用系统自带的进程。其中 meta target-role=Stopped，是为了保证 dlm 和 gfs2 同时启动和关闭，防止 dlm 模块产生 fence。

```
crm configure primitive dlm ocf:pacemaker:controld \
        params daemon="/opt/KingbaseHA/dlm-dlm/sbin/dlm_controld" dlm_tool="/opt/KingbaseHA/dlm-dlm/sbin/
dlm_tool" args="-s 0 -f 0" \
        op start interval=0 \
        op stop interval=0 \
        op monitor interval=60 timeout=60 \
        meta target-role=Stopped
```

2. 克隆 dlm 资源

执行如下命令，将 dlm 资源变成 clone 资源。

```
crm configure clone clone-dlm dlm
```

3. 配置 gfs2 资源

由于 gfs2 在不同操作系统需要不同的配置，这里分为两部分，先介绍适配 linux2.6.32 的配置，然后介绍适配 linux3.10.0 的配置。配置中，需要确保每个节点/sharedata 目录存在。其中 meta target-role=Stopped，是为了保证 dlm 和 gfs2 同时启动和关闭，防止 dlm 模块产生 fence。

适配 Linux2.6.32 的 gfs2 配置 和适配 linux3.10.0 的 gfs2 配置 仅需按操作系统，执行其中一个步骤即可。

4. 查看 uuid

```
blkid /dev/sdd
/dev/sdd: LABEL="2nodes:gfs2" UUID="4b09b720-5ef0-41ea-a640-1a7d05017b1e" TYPE="gfs2"
```

5. 适配 Linux2.6.32 的 gfs2 配置

执行如下命令，配置 gfs2(Filesystem) 资源。需其中 options 中 hostdata 是给 gfs2 指定 journal，目的是兼容低版本 linux（2.6.32.700-Rocky4.2-x86_64）。其中启动的超时时间和 journal 的数量成线性关系，journal 为 2 时，建议为 180s，journal 为 3 时，建议为 240s。如果存在故障，那么需要手动调用 fsck，否则启动时自行修复，时间会更长。注意，“hostdata=jid”进行了匹配和变更操作，mount 时会按照 hostdata=jid=$((nodeid-1)) 方式来配置 options。

```
crm configure primitive gfs2 ocf:heartbeat:Filesystem \
     params device="-U 4b09b720-5ef0-41ea-a640-1a7d05017b1e" \
     directory="/sharedata" fstype="gfs2" options="hostdata=jid" \
     op start interval="0" timeout="240" \
     op stop interval="0" timeout="60" \
     op monitor interval="30s" timeout="60" OCF_CHECK_LEVEL="20" \
     meta failure-timeout=5min target-role=Stopped
```

6. 适配 linux3.10.0 的 gfs2 配置

执行如下命令，配置 gfs2(Filesystem) 资源。需确保每个节点/ sharedata 目录存在。其中 meta target-role=Stopped，是为了保证 dlm 和 gfs2 同时启动和关闭，防止 dlm 模块产生 fence。

```
crm configure primitive gfs2 ocf:heartbeat:Filesystem \
     params device="-U 4b09b720-5ef0-41ea-a640-1a7d05017b1e" \
     directory="/sharedata" fstype="gfs2" \
     op start interval="0" timeout="60" \
     op stop interval="0" timeout="60" \
     op monitor interval="30s" timeout="60" OCF_CHECK_LEVEL="20" \
     meta failure-timeout=5min target-role=Stopped
```

7. 克隆 gfs2 资源

执行如下命令，将 gfs2 资源变成 clone 资源。其中 interleave=true，使 gfs2 资源无需等待整个系统的 dlm 资源启动，只需本节点的启动即可。

```
crm configure clone clone-gfs2 gfs2 meta interleave=true
```

8. 创建 gfs2 和 dlm 的约束关系

配置启动关系

执行如下命令，配置 gfs2 和 dlm 的启动关系。因为 gfs2 依赖 dlm，所以需要先启动 dlm。

```
crm configure order cluster-order1 clone-dlm clone-gfs2
```

配置绑定关系

执行如下命令，配置 gfs2 和 dlm 的绑定关系。由于 dlm 也可能因 gfs2 非预期启停产生 fence，因此需要保证二者同时启动和关闭。

```
crm configure colocation cluster-colo1 inf: clone-gfs2 clone-dlm
```

9. 启动资源

执行如下命令，启动相关资源。

```
crm resource start clone-dlm clone-gfs2
```

3.3.2.3　配置 DB 资源

1. 生成新的数据库集簇

如果需要在集群中配置新的数据库实例，首先需要生成数据库集簇。

2. 初始化数据库 data

首先，进入共享文件系统目录/sharedata。

创建数据存放目录（目录名为当前用户名），并修改所有者为当前用户。

切换到 bin 目录下，执行如下命令：

```
./initdb -A trust -D /sharedata/kingbase/data -U system
```

若打印结果显示如下内容：

```
成功。您现在可以用下面的命令开启数据库服务器：

  ./sys_ctl -D /sharedata/kingbase/data -l logfile start
```

则代表执行成功。

3. 配置数据库服务器

执行以下命令：

```
cd /sharedata/kingbase/data
vim kingbase.conf
```

修改如下配置：

(1) 修改必要配置。

```
port = 54321（根据需要设置）
lms_port=53444  /* 应保证从 53444 开始到 53463，这些端口均未被占用，（假设 20 个 lms）*/
```

(2) 修改非必要配置。

```
shared_buffers= 匹配环境的适当值，建议大于 20GB
lms_count = 20  /* 即 KingbaseES RAC 启动时 lms 的数量 */
```

4. 托管数据库

如果需要由 pacemaker 管理数据库的启动和停止，你可以按照本章节说明配置 DB 资源。

托管数据库是推荐的做法，这样可以获得更好的可用性。

以下操作均需要使用 root 用户。

5. 配置 primitive 资源

执行如下命令：

```
crm configure primitive DB ocf:kingbase:kingbase \
     params sys_ctl="/home/kingbase/KingbaseES/bin/sys_ctl" \
     ksql="/home/kingbase/KingbaseES/bin/ksql" \
     sys_isready="/home/kingbase/KingbaseES/bin/sys_isready" \
     kb_data="/sharedata/kingbase/data" \
     kb_dba="kingbase" kb_host="0.0.0.0" \
     kb_user="system" \
     kb_port="54321" \
     kb_db="template1" \
     logfile="/home/kingbase/KingbaseES/log/kingbase1.log" \
     op start interval="0" timeout="120" \
     op stop interval="0" timeout="120" \
     op monitor interval="9s" timeout="30" on-fail=stop \
     meta failure-timeout=5min target-role=Stopped
```

6. 配置 clone 资源及顺序

（1）执行如下命令，将 DB 资源变成 clone 资源。

```
crm configure clone clone-DB DB
```

（2）执行如下命令，配置 DB 和 gfs2 的启动关系。

因为 DB 依赖 gfs2，所以需要先启动 gfs2。同时 gfs2 也依赖 dlm，因此需配置 dlm、gfs2、DB 的启动顺序。

```
crm configure order cluster-order2 clone-dlm clone-gfs2 clone-DB
```

7. 启动资源

执行如下命令，启动数据库资源。

```
crm resource start clone-DB
```

8. 关闭资源

执行如下命令，关闭数据库资源。

```
crm resource stop clone-DB
```

3.3.2.4　手动管理数据库

如果出于调试目的或其他定制化需求目的，不希望通过 pacemaker 管理数据库的启动和停止，你可以取消托管数据库资源。然后，你可以采用下述命令来控制数据库的状态。

1. 取消托管数据库

执行如下命令，取消托管数据库资源。

```
crm resource unmanage clone-DB
```

2. 托管数据库

执行如下命令，托管数据库资源。

```
crm resource manage clone-DB
```

3. 启动数据库

在取消托管状态下，在所有节点上依次启动数据库，以两节点为例。

1) node1

```
./sys_ctl -D /sharedata/kingbase/data/ start
```

2) node2

```
./sys_ctl -D /sharedata/kingbase/data/ start
```

4. 停止数据库

在取消托管状态下，在所有节点上依次停止数据库，以两节点为例，在每个节点上依次分别执行。

1) node1

```
./sys_ctl -D /sharedata/kingbase/data/ stop
```

2) node2

```
./sys_ctl -D /sharedata/kingbase/data/ stop
```

5. 重启数据库

在取消托管状态下，在所有节点上依次重启数据库，以两节点为例，在每个节点上依次分别执行。

1) node1

```
./sys_ctl -D /sharedata/kingbase/data/ restart
```

2) node2

```
./sys_ctl -D /sharedata/kingbase/data/ restart
```

第4章　运维指南

4.1　KingbaseES RAC 集群监控

本章节包含以下内容：

- 监控指标

4.1.1　监控指标

表 4.1.1: 监控指标

参数指标	取值范围	异常范围/级别	获取方式
Pacemaker 进程状态	stopped/runing	stopped/错误	/etc/init.d/pacemaker status
Corosync 进程状态	stopped/runing	stopped/错误	/etc/init.d/corosync status
Corosync-qdevice 进程状态	stopped/running	stopped/错误	/etc/init.d/corosync-qdevice status
节点状态	offline,online,standby	offline,standby/错误	crm_mon -1|grep -E ”offline|standby|Online”
资源状态	Failed,Started,Starting,Stopped	Failed/错误	crm resource show|grep failed
查看集群是否有quorum	yes/no	no/错误	corosync-quorumtool -s|grep Quorate

-续表-

参数指标	取值范围	异常范围/级别	获取方式
disk 模式 master_id	1 ~ n nodes(节点总数)	0/错误	./corosync-qdevice/sbin/corosync-qdevice-tool -sv -p/opt/KingbaseHA/corosync-qdevice/var/run/corosync-qdevice/corosync-qdevice.sock awk-F':' '{print $2}'
存储 STATE	0(已挂载),>0(未挂载)	>0/错误	crm storage|grep UNMOUNT|wc -l
存储容量	0/1	>0/告警	crm storage|grep -v -E " VOTEDISK|PATH" | awk '{print (($4 / $5) > 0.8)}' | grep 1|wc -l wc -l

本章节介绍部分常见的异常，对于监控指标异常的恢复请参考“应急预案”一章的内容。

4.2　KingbaseES RAC 扩缩容

本章节包含以下内容：

- 节点扩容
- 节点缩容
- 扩缩容失败恢复

备注:

节点扩缩容只允许 KingbaseES RAC 方案执行

4.2.1　节点扩容

4.2.1.1　免密扩容

备注:

(1) 要求所有节点完成节点间免密配置

(2) 要求在待扩容节点上安装完毕 KingbaseES RAC 数据库和 clusterware 组件，并保证相关的环境配置正确

选择运行中的任一节点更新配置文件 cluster_manager.conf，添加扩容节点的 node_ip 和 node_name，在更新配置文件的节点执行脚本执行扩容：

```
./cluster_manager.sh  --add_node
```

在扩容的节点上执行启动：

```
./cluster_manager.sh  --start
```

4.2.1.2　非免密扩容

在运行中的任一节点更新配置文件 cluster_manager.conf，添加扩容节点的 node_ip 和 node_name，将配置文件拷贝到所有节点：

```
scp cluster_manager.conf root@rac04:/opt/KingbaseHA/
```

在所有节点执行：

```
./cluster_manager.sh  --corosync_configure_update
```

在运行中的任一节点执行：

```
./cluster_manager.sh  --add_node_configure
```

在扩容节点启动集群管理组件：

```
./cluster_manager.sh  --init_gfs2
./cluster_manager.sh  --base_configure_init
./cluster_manager.sh  --start
```

4.2.2　节点缩容

4.2.2.1　免密缩容

备注:

(1) 要求所有节点完成节点间免密配置

(2) 要求缩容节点必须依次从后向前缩容，例如 (node1,node2,node3)，请保证缩容从 node3 开始

停止需要缩容节点的集群管理组件：

```
./cluster_manager.sh  --stop
```

选择运行中的任一节点更新配置文件 cluster_manager.conf，删除缩容节点的 node_ip 和 node_name，在该节点执行脚本进行缩容：

```
./cluster_manager.sh  --delete_node
```

4.2.2.2　非免密缩容

停止需要缩容节点的集群管理组件：

```
./cluster_manager.sh  --stop
```

选择运行中的任一节点更新配置文件 cluster_manager.conf，删除缩容节点的 node_ip 和 node_name，将配置文件拷贝到所有节点：

```
scp cluster_manager.conf root@rac03:/opt/KingbaseHA/
```

在所有节点执行：

```
./cluster_manager.sh  --corosync_configure_update

corosync-cmapctl -b | grep runtime.members        # 查看各个节点 ip
corosync-cmapctl -d runtime.members.$node_id.ip   # 选择需要缩容的 node_id 进行删除
```

在运行中的任一节点执行：

```
./cluster_manager.sh  --delete_node_configure
crm node -R $delete_node_name --force
```

将执行节点的 host 拷贝到其它运行节点，或者自行在 host 中删除缩容节点的信息：

```
scp /etc/hosts root@rac04:/etc/hosts
```

在已删除节点执行清理：

```
./cluster_manager.sh  --clean_all
```

4.2.3 扩缩容失败恢复

备注:

(1) 扩缩容失败恢复功能仅支持自动恢复，要求所有节点完成节点间免密配置

(2) 缩容失败和扩容失败的恢复都是向下恢复，即都是恢复到集群节点数更少的状态

扩容失败后恢复

将配置文件 cluster_manager.conf 恢复到扩容前状态，恢复集群：

```
./cluster_manager.sh  --restore
```

缩容失败后恢复

将配置文件 cluster_manager.conf 设置为缩容成功后状态，恢复集群：

```
./cluster_manager.sh  --restore
```

4.3 KingbaseES RAC 运维操作

本章节包含以下内容：

- 集群查看
- 集群启停
- 计划内停机运维

4.3.1 集群查看

1. 执行如下操作，查看集群状态。

```
crm status
```

4.3.2 集群启停

. 选择想要操作的节点，执行如下操作，完成该节点的启停。

（1）启动该节点。

```
./cluster_manager.sh start
```

（2）停止该节点。

```
./cluster_manager.sh stop
```

选择所有节点执行上述操作，则可实现集群的启停。

4.3.3　计划内停机运维

补丁、升级

4.3.3.1　资源补丁、升级

clusterware 提供的资源支持使用在线替换的方式升级，支持范围见下表：

表 4.3.1: 资源补丁、升级

资源	支持在线替换
Kingbase	是
Filesystem	是
Ipaddr2	是
Sg_persist	是
fence_vmware_soap	是 “‘{anchor} clusterware 补丁、升级

4.3.3.2　clusterware 补丁、升级

clusterware 组件的升级可使用以下几种方式：

表 4.3.2: clusterware 补丁、升级

	脱管资源	滚动
版本限制	无	不支持跨版本升级或有通讯协议升级的情况，需要确认。

-续表-

	脱管资源	滚动
升级中服务可用性	服务可用，只有在升级过程中发生故障（包括计划内重启主机）时会造成服务中断。	升级中每个节点会停服务一次，两节点分库方案中会有服务的 3 次中断。
可用于故障演练	否	是

补丁和升级建议的方式：

1. 在充分测试情况下（参见 KingbaseES 高可用概述的搭建测试验证环境一节），尽可能申请停机时间使用脱管资源方式升级。
2. 涉及集群文件系统 gfs2 的使用场景，由于 gfs2 所依赖的 dlm 锁的特性，无法使用脱管资源方式升级，但支持采用滚动方式升级。
3. 若已开启 clusterware 开机自启功能，需要先关闭开机自启功能（开机自启 章节，需要特别注意修改相应配置参数以彻底关闭自启功能），再进行后续升级和补丁操作。

4.3.3.2.1　脱管资源方式

1. 脱管全部资源

```
crm_attribute --name maintenance-mode --update true
```

2. 在集群中每个节点执行
    1. 停止 clusterware
    2. 完成变更
3. 在集群中每个节点执行：
    1. 启动 clusterware
    2. 验证配置确认没有错误和警告
4. 通过 crm_mon 确认全部资源状态被正确识别
5. 重新管控资源

4.3.3.2.2　滚动方式

在集群中一个节点（假设节点名为节点 1）执行：

1. 设置节点为 standby 状态

```
crm_standby --node 节点 1 -v on
```

2. 通过 crm_mon 确认资源都正确转移到其他节点
3. 停止 clusterware

```
/etc/init.d/pacemaker stop
/etc/init.d/corosync-qdevice stop
/etc/init.d/corosync stop
```

4. 完成变更
5. 启动 clusterware

```
/etc/init.d/corosync start
/etc/init.d/corosync-qdevice start
/etc/init.d/pacemaker start
```

6. 验证配置确认没有错误和警告

```
crm_verify --live-check
```

7. 清除节点 standby 状态

```
crm_standby --node 节点 1 -v off
```

如果需要，移动资源到变更后的节点

1. 通过 crm_mon 确认资源当前运行的节点（假设节点名为节点 2）
2. 移动资源（假设名称为资源 1）从节点 2 到变更后的节点 1

```
crm_resource -M 节点 1 -r 资源 1
```

3. 通过 crm_mon 确认资源正确转移
4. 清理节点 2 上的资源移动规则

```
crm_resource -U --node 节点 2 -r 资源 1
```

5. 在剩余节点上重复执行 1、2 中的步骤

4.3.3.3　系统或硬件补丁、升级

如果变更需要重启主机或是停止网络等影响资源运行的操作，选择滚动方式，否则选择脱管资源方式。操作方法见 clusterware 补丁、升级一节。

第5章　其它集群结构

5.1　Clusterware 共享存储集群概述

本部分包含以下内容：

- 方案简介
- 组网配置
- 运行架构

5.1.1　方案简介

KingbaseES Clusterware 用于协调多种资源组成统一的服务，配合 KingbaseES 可以实现以下几种方案：

1. 使用共享存储的高可用方案

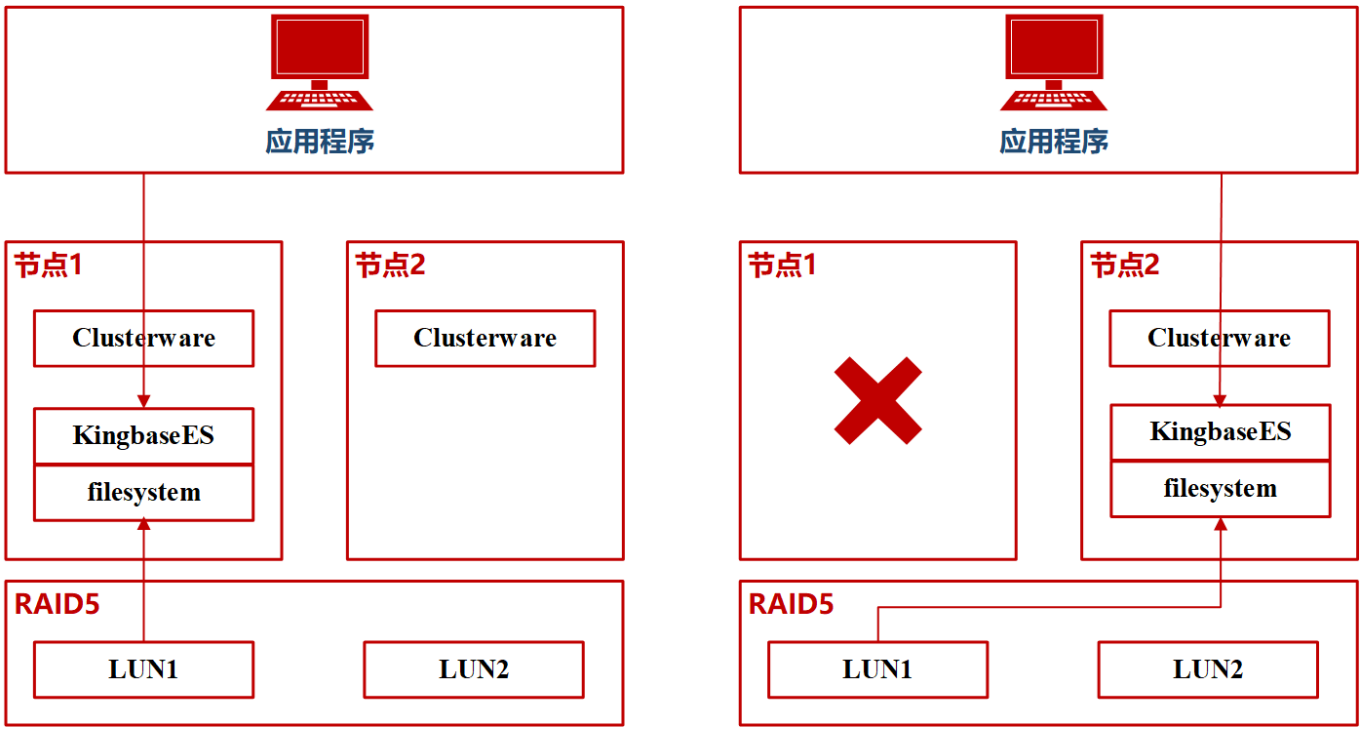

2. 使用共享存储的高可用多活方案，适用于：

   1. 单个应用做了库级的解耦，可以通过分库将压力分散到不同数据库实例。以下是逻辑图示，正常运行情况和单个节点故障的情况：

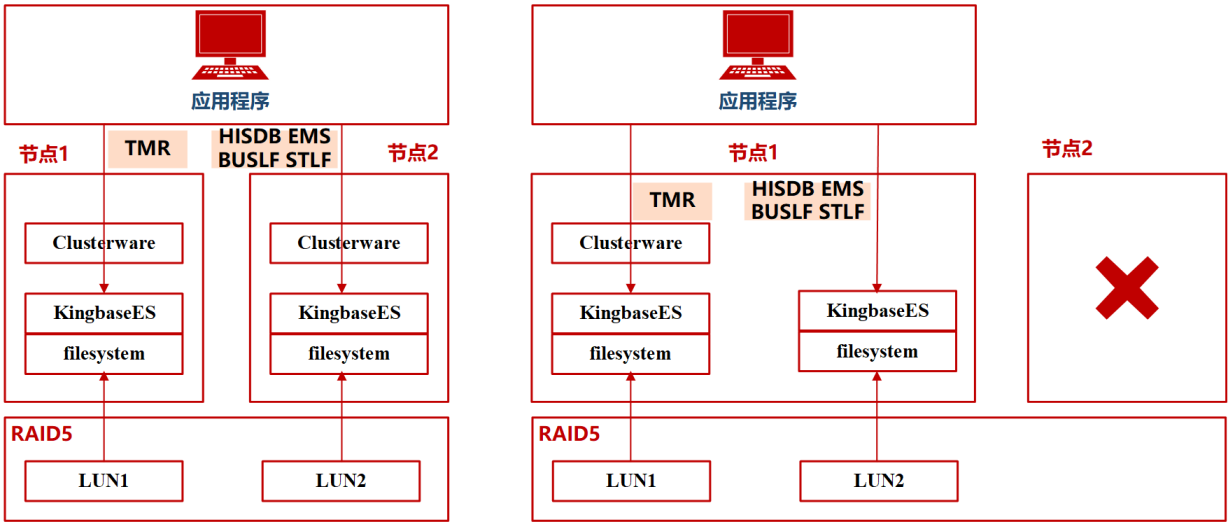

   2. 多个应用的集约化部署，每个应用使用单个数据库实例。以下是逻辑图示，正常运行情况和单个节点故障的情况：

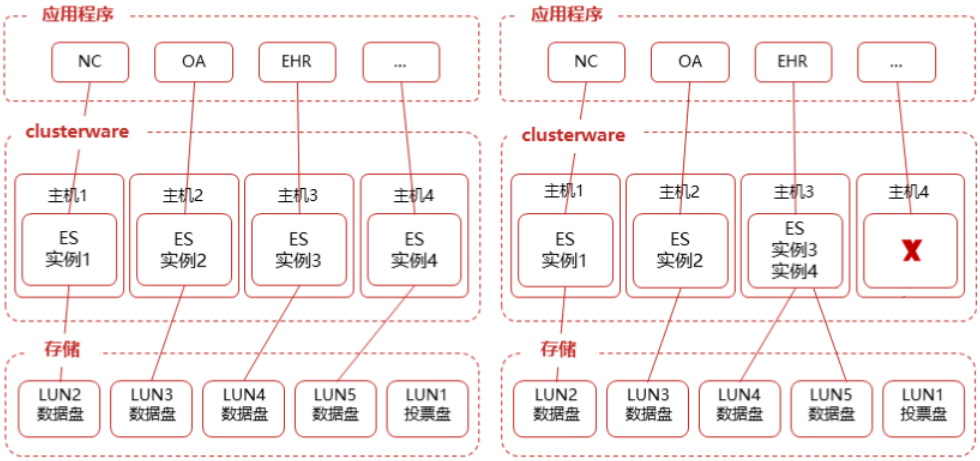

有关高可用方案和读写分离集群方案的选择和比较的更多信息，请参阅《KingbaseES 高可用概述》。

5.1.2　组网配置

组网方式如下图：

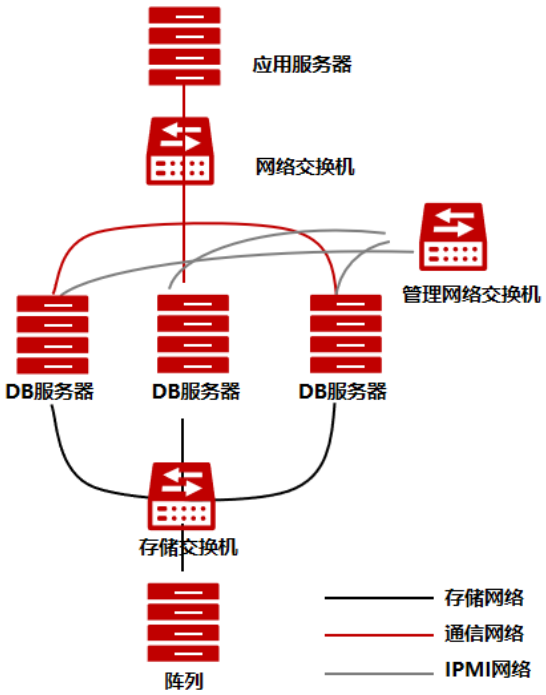

5.1.3　运行架构

组件中 pacemaker、corosync（包含 qdevice）都有 daemon 运行在每个节点上。resource agents、crmsh 没有 daemon 运行，会在执行的节点上运行。

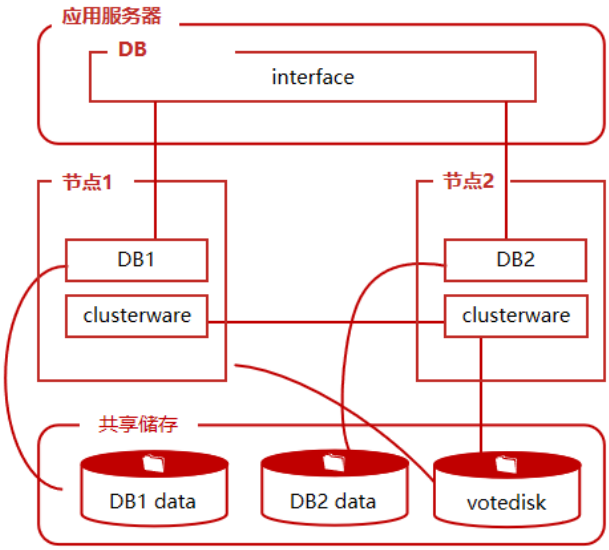

5.2　集群搭建前置操作

搭建集群中各个操作，每个集群节点都需要执行，以 root 用户操作。

搭建 Clusterware 集群，需要一些前置操作，本章主要介绍前置操作。前置操作首先是部署包的处理，主要分为集成化安装包和绿色版安装包；其次需要配置 NTP，实现各节点时间保持一致；最后需要配置共享磁盘，主要分为 iSCSI 设备和多点可见虚拟设备。

本章节包含以下内容：

- 采用安装包部署
- 绿色版安装部署
- 配置 NTP 时间同步
- 配置 terminfo
- hostnamed 服务配置
- 采用 iSCSI 设备作为共享磁盘

- 采用多点可见存储设备作为共享磁盘
- 系统配置检查

5.2.1 采用安装包部署

安装完 KingbaseES 后，进入安装后的数据库 install/script 目录：例如/opt/Kingbase/ES/KingbaseRAC/install/script，执行 rootDeployClusterware.sh 脚本。执行完成后会在/opt 目录下自动生成 KingbaseHA 软件包。

```
sh rootDeployClusterware.sh
```

5.2.2 绿色版安装部署

1. 上传绿色版 KingbaseHA.tar.gz 到安装目录。

   安装目录支持用户自定义路径，推荐使用 `/opt` 目录。

2. 以 `/opt` 目录为例，执行如下命令，解压软件包。

   解压后的目录名为 `KingbaseHA` 。

```
cd /opt
tar -zxvf KingbaseHA.tar.gz
```

注意:

如果安装目录为用户自定义路径，需要将配置文件 cluster_manager.conf 内的 `install_dir` 参数设置为用户自定义的路径。例如：`install_dir=/home/test/KingbaseHA` 。

5.2.3 配置 NTP 时间同步

注意:

- 在配置 NTP 时间同步之前，请确保系统已安装 NTP 服务。
- 配置 NTP 时间同步方法可参考如下步骤，不同操作系统可能有不同设置，以实际环境为准。

5.2.3.1 配置 NTP 时间服务器

环境中没有时间服务器的情况下设置集群中一个节点为 NTP 服务器，其他节点向此服务器同步时间。使用此种方式时要注意在 NTP 服务器节点故障修复后重新加入网络时需要手动检查系统时间，可以设置为比运行节点中时间

最快的更快几秒。

1. 以某个节点为 NTP 服务器，编辑/etc/ntp.conf。

```
vi /etc/ntp.conf
```

加入如下内容，其中 192.168.4.1 为子网 IP，255.255.255.0 为子网掩码。

```
server 127.127.1.0 prefer           # local clock (LCL)
fudge 127.127.1.0 stratum 10        # LCL is unsynchronized
restrict 192.168.4.1 mask 255.255.255.0
```

2. 启动 ntpd 服务。

```
systemctl start ntpd
```

3. 设置开机自启。

编辑/etc/rc.d/rc.local：

```
vi /etc/rc.d/rc.local
```

加入如下内容：

```
systemctl start ntpd
```

5.2.3.2　其他要时间同步的机器

1. 配置 ntp.conf。

```
vi /etc/ntp.conf
```

添加如下内容，其中 192.168.4.134 为 NTP 服务器 IP 地址。

```
server 192.168.4.134 prefer           # local clock (LCL)

fudge 192.168.4.134 stratum 10
```

2. 启动。

```
systemctl start ntpd
```

3. 设置开机自启。

```
vi /etc/rc.d/rc.local
```

添加如下内容：

```
systemctl start ntpd
```

5.2.3.3 验证

可以在客户机器执行如下命令，查看 ntp 同步状态，`offset` 表示两者时间差：毫秒。

```
ntpq -p
remote refid   st t when poll reach  delay  offset  jitter
==========================================================
*node1 LOCAL(0) 11 u 23   64   377   0.162 258.860  84.327
```

注意:

更改 NTP 服务器时间，可以看到客户端时间更改。但同步是个比较慢的过程，可以通过重启 NTP 服务来实现立即时间同步的效果。

5.2.4 配置 terminfo

通过如下命令查看 term 是否在默认路径 (一般为/usr/share/terminfo/x) 下。

```
ls -l /usr/share/terminfo/x/${TERM}
```

如果存在，则无需额外配置。否则需要进行配置，通过如下命令查看 term 位置。

```
find / -name ${TERM}
/lib/terminfo/x/xterm
/usr/bin/xterm
/usr/share/menu/xterm
/usr/share/doc/xterm
/usr/share/icons/DMZ-White/cursors/xterm
/usr/share/icons/DMZ-Black/cursors/xterm
/usr/share/vte/termcap/xterm
```

通过如下命令配置 term。

```
ln -s /lib/terminfo/x/xterm /usr/share/terminfo/x/xterm
```

或者执行如下命令配置 term。

```
export TERMINFO=/lib/terminfo/
```

5.2.5　hostnamed 服务配置

在不依赖 hostnamed 服务情况下，建议将 hostnamed 服务禁用（由于 hostnamed 服务启动失败会影响集群文件系统服务）。可以通过重命名 serviced-hostnamed.service 将其禁用。

```
cd /usr/lib/systemd/system/
mv systemd-hostnamed.service systemd-hostnamed.service.bak
```

5.2.6　采用 iSCSI 设备作为共享磁盘

目前针对分库方案，推荐使用 n+1 个 LUN，其中 n 为要分开的库的数目，还有一个作为投票盘使用。一般要求投票盘的大小不小于 100MB。

如果采用一个 LUN，那么需要将此 LUN 分成 n+1 个分区。但是在某些操作系统下，不支持分区的方式。

5.2.6.1　iSCSI 设备的配置

以下步骤需要在每个节点依次执行

1 发现。

```
iscsiadm --mode discoverydb --type sendtargets --portal 192.168.4.85 --discover
```

2 登录。

第一步可能发现很多 Target，选择管理员分配给我们的 Target 进行登录。

```
iscsiadm -m node -T iqn.2000-01.com.synology:DiskStation.Target-3.1b9e73bebd
-p 192.168.4.85 -l
iscsiadm -m node -T iqn.2000-01.com.synology:DiskStation.Target-33.1b9e73bebd
-p 192.168.4.85 -l
iscsiadm -m node -T iqn.2000-01.com.synology:DiskStation.Target-34.1b9e73bebd
-p 192.168.4.85 -l
```

3 设置开机自动登录。

```
iscsiadm -m node -T iqn.2000-01.com.synology:DiskStation.Target-3.1b9e73bebd
-p 192.168.4.85 --op update -n node.startup -v automatic
iscsiadm -m node -T iqn.2000-01.com.synology:DiskStation.Target-33.1b9e73bebd
-p 192.168.4.85 --op update -n node.startup -v automatic
iscsiadm -m node -T iqn.2000-01.com.synology:DiskStation.Target-34.1b9e73bebd
-p 192.168.4.85 --op update -n node.startup -v automatic
```

4 获取 iSCSI 设备信息。

```
lsscsi

列出所有设备，在所有设备中找到新增的 iSCSI 类型的设备，查找相关信息
输出信息如下：

[0:2:3:0] disk DELL PERC H330 Adp 4.30 /dev/sdd
[14:0:0:0] cd/dvd HL-DT-ST DVD+-RW GU90N A3C1 /dev/sr0
[15:0:0:1] disk SYNOLOGY iSCSI Storage 4.0 /dev/data1

udevadm info --query=all --name='/dev/data1'

查看 ID_PATH 是否为对应的设备，获取对应的 ID_SERIAL
```

5 对共享存储设备设置 udev 规则。

当使用多个 iSCSI 设备时，不同节点的同一设备名对应的可能是不同的 iSCSI 设备。为规避上述情况，对 iSCSI 设备进行 udev 绑定。其中 ID_SERIAL 字段，为 udevadm info 查到的 ID_SERIAL。

```
vi /etc/udev/rules.d/75-persist-iscsi.rules
```

添加如下内容：

```
KERNEL=="sd*",ENV{ID_SERIAL}=="36001405b6e1f506dda2ad4585d827bdb",
NAME:="qdisk%n",MODE:="0644"
KERNEL=="sd*",ENV{ID_SERIAL}=="36001405e60b600fda465d46a4d8c6fd7",
NAME:="data1%n",MODE:="0644"
KERNEL=="sd*",ENV{ID_SERIAL}=="36001405da2879e6dab34d48dfd88c5d5",
NAME:="data2%n",MODE:="0644".
```

一般来说，在设置完规则后需要重启机器。

5.2.6.2　iSCSI 设备的初始化

本节操作只需在一个节点上执行。

用作数据库 data 目录的 iSCSI 设备，需要进行格式化。

1 针对 iSCSI 设备/dev/data1 创建 ext4 文件系统。

```
mkfs.ext4 /dev/data1
```

2 针对 iSCSI 设备/dev/data2 创建 ext4 文件系统。

```
mkfs.ext4 /dev/data2
```

5.2.7　采用多点可见存储设备作为共享磁盘

目前，针对分库方案，如果采用非 iSCSI 方式的多点可见存储设备作为共享磁盘，那么推荐使用 n+1 个存储设备，其中 n 是要分开的库。一般来说，一个存储设备对应一个 KingbaseES 的 data 目录，还有一个作为投票盘使用，一般要求投票盘规格不小于 100MB。

如果采用一个存储设备，那么需要将设备分成 n+1 个分区。在某些操作系统下，不支持采用分区的方式。

该章节的操作只需在一台机器上进行。

5.2.7.1　多点可见存储设备的配置

跨节点使用存储设备，除 iSCSI 设备对应的 SAN 存储方式外，还有虚拟机共享虚拟磁盘的方式。

在虚拟机管理平台，新创建硬盘时，请注意使用以下参数。

表 5.2.1: 建议参数设置

配置名称	推荐配置内容
类型	厚置备，置零
控制器位置	SCSI 控制器 1
磁盘模式	独立-持久

然后在集群的其他节点添加这个现有磁盘即可。

5.2.7.2　多点可见存储设备初始化

1 在存储设备/dev/sdc 创建 ext4 文件系统。

```
mkfs.ext4 /dev/sdc
```

2 在存储设备/dev/sdd 创建 ext4 文件系统。

```
mkfs.ext4 /dev/sdd
```

一般来说，在虚拟机上搭建，别的节点要生效，需要重启机器。

5.2.8　系统配置检查

在部署集群前，需要检查/root/.bashrc 和/etc/hosts 是否存在残留配置。

5.2.8.1　检查环境变量

如果是重新部署 clusterware，部署前需要正确清理 clusterware 环境。

```
./cluster_manager.sh --clean_all
```

如果当前配置的安装目录跟之前的安装目录不相同，则该命令也不能保证环境的完整清理，/root/.bashrc 可能会有上次安装残留的环境变量，建议在安装前手动检查。

```
vi /root/.bashrc
```

以安装目录/opt/KingbaseHA 举例，跟 clusterware 相关的环境变量配置如下所示：

```
export install_dir=/opt/KingbaseHA
export PATH=/opt/KingbaseHA/python2.7/bin:/opt/KingbaseHA/pacemaker/sbin/:$PATH
export PATH=/opt/KingbaseHA/crmsh/bin:/opt/KingbaseHA/pacemaker/libexec/pacemaker/:$PATH
export PATH=/opt/KingbaseHA/corosync/sbin:/opt/KingbaseHA/corosync-qdevice/sbin:$PATH
export PYTHONPATH=/opt/KingbaseHA/python2.7/lib/python2.7/site-packages/:/opt/KingbaseHA/crmsh/lib/python2.
7/site-packages:$PYTHONPATH
export COROSYNC_MAIN_CONFIG_FILE=/opt/KingbaseHA/corosync/etc/corosync/corosync.conf
export CRM_CONFIG_FILE=/opt/KingbaseHA/crmsh/etc/crm/crm.conf
export OCF_ROOT=/opt/KingbaseHA/pacemaker/ocf
export HA_SBIN_DIR=/opt/KingbaseHA/pacemaker/sbin/
export QDEVICE_SBIN_DIR=/opt/KingbaseHA/corosync-qdevice/sbin/
export LD_LIBRARY_PATH=/opt/KingbaseHA/lib64/:$LD_LIBRARY_PATH
export HA_INSTALL_PATH=/opt/KingbaseHA
export PATH=/opt/KingbaseHA/dlm-dlm/sbin:/opt/KingbaseHA/gfs2-utils/sbin:$PATH
export LD_LIBRARY_PATH=/opt/KingbaseHA/corosync/lib/:$LD_LIBRARY_PATH
```

上述每项配置有且仅有一个，如果在安装前发现/root/.bashrc 中有类似的配置，请手动删除相关的配置。

5.2.8.2　检查 hosts

排查环境中 hosts 配置是否有冲突项。

```
vi /etc/hosts
```

检查 hosts 文件，删除冲突项，并确认当前要配置的节点 IP 和节点名是否已存在，如果存在则手动删除。

5.3　集群搭建方案

目前支持两种方式搭建集群：

使用 CLI 或是命令行搭建，推荐使用 CLI 搭建集群:

- 使用 CLI 搭建集群
- 使用命令行搭建集群

5.3.1　使用 CLI 搭建集群

目前提供一个 cluster_manager.sh 脚本来帮助搭建集群与管理集群。

具体功能可以使用如下命令来查看该脚本提供的功能。

```
sh cluster_manager.sh --help
Usage: cluster_manager.sh <options>
<options> may be:
  --help                        show this help, then exit
  -A, --all                     config all and start process
  --start                       start corosync, wait for quorate, start pacemaker and qdevice
  --start_nowait                start corosync, pacemaker and qdevice, do not wait for quorate
  --stop                        stop qdevice pacemaker corosync
  --status                      show corosync pacemaker qdevice status
Cluster options:
  --deploy                      cluster automatic deployment
  --qdisk_init                  init votingdisk, add -y or --silent/silent to skip confirmation,
check votingdisk path before execution!
  --cluster_disk_init           format disk as gfs2, add -y or --silent/silent to skip
confirmation, check sharedate_disk path before execution!
  --init_gfs2                   update gfs2 kernel lib, add -y or --silent/silent to skip
confirmation
  --base_configure_init         init all basic configure
  --corosync_configure_update   update corosync basic configure
  --init_db                     init kingbase database
  --init_rac                    init KingbaseES RAC
  --config_gfs2_resource        crm configure dlm and gfs resource
  --config_nfs_resource         crm configure nfs resource
  --config_resource             crm configure resource
  --config_rac_resource         crm configure DB resource
  --uninstall                   uninstall all components
  --clean_all                   clean all config but not for kingbase data
  --config_keep_cluster_alive   config and start keep cluster alive crond task
  --clean_keep_cluster_alive    stop and clean keep cluster alive crond task
  --add_node                    automatic add nodes
  --add_node_configure          add nodes resource to crm configure
  --delete_node                 automatic delete nodes
  --delete_node_configure       delete nodes resource to crm configure
Corosync options:
  --start_corosync              start corosync
  --stop_corosync               stop corosync
```

```
  --status_corosync            corosync status
Pacemaker options:
  --start_pacemaker            start pacemaker
  --stop_pacemaker             stop pacemaker
  --status_pacemaker           pacemaker status
QDevice options:
  --start_qdevice              start qdevice
  --stop_qdevice               stop qdevice
  --status_qdevice             qdevice status
QDisk Fenced options:
  --start_qdisk_fenced         start qdisk fenced
  --stop_qdisk_fenced          stop qdisk fenced
  --status_qdisk_fenced        qdisk fenced status
other options:
  --add_rac_resource           add other rac data directory
  --delete_rac_resource        delete other rac data directory
  --create_rac_share_dir       create rac share dir
  --config_term                config term
  --init_softdog               init kernel watchdog lib
  --add_dlm_nod                add dlm misc device nod
  --restore                    restore cluster to less node
```

要想使用该脚本，首先需要根据现实环境修改一些初始化变量，这些变量记录在 cluster_manager.conf 中。

```
vim cluster_manager.conf
```

表 5.3.1: 参数默认值和意义

变量名称	默认值	意义
cluster_name	kcluster	集群的名字，用于生成 corosync.conf 中的 cluster_name 以及 devicedisk 模型中的 label，用于基于 label 查找投票盘
node_name	(node1 node2)	节点名称，用于配置 corosync.conf 中的 ring0_addr 以及 hosts 中的节点主机名
node_ip	(192.168.5.1 192.168.5.2)	host 中的节点 IP 地址，一般使用内网 IP 地址
enable_qdisk	1	是否启用 qdisk
votingdisk	/dev/sde	投票盘，需要物理存在，用于 qdevice 共享磁盘心跳
enable_gfs2	1	是否使用 gfs2 文件系统，在本节所述方案中该配置必须为 0
sharedata_disk	/dev/sdb	gfs2 文件系统所使用的共享盘，仅当 enable_gfs2 为 1 时该项配置才有意义

-续表-

变量名称	默认值	意义
enable_nfs	0	是否使用 nfs 文件系统，在本节所述方案中该配置必须为 0
nfs_server	192.168.4.5	nfs 文件系统需要的 nfs 服务器，仅当 enable_nfs 为 1 时该项配置才有意义
nfs_server_dir	/volume1/nfs_server	nfs 文件系统需要的 nfs 服务器的共享目录，仅当 enable_nfs 为 1 时该项配置才有意义
sharedata_dir	/sharedata	共享存储的挂载点，仅当 enable_nfs 或 enable_gfs2 为 1 时该项配置才有意义
init_disk	1	是否初始化投票盘和共享数据盘
enable_initdb	1	是否执行 initdb 初始化数据库
install_dir	/opt/KingbaseHA	KingbaseHA 安装目录, 注意与 kingbase_install_dir 区分
env_bash_file	/root/.bashrc	用于配置环境变量的保存文件
keep_cluster_alive	0	用于配置集群节点开机自启功能
pacemaker _daemon_group	haclient	Pacemaker 的 daemon 用户组名称，由编译 pacemaker 时决定
pacemaker _daemon_user	hacluster	Pacemaker 的 daemon 的用户名称，由编译 pacemaker 时决定
kingbaseowner	kingbase	Kingbase 数据库的属主
kingbasegroup	kingbase	Kingbase 数据库用户所在的用户组
kingbase_install _dir	/opt/KingbaseRAC/ KingbaseRAC/	Kingbase 服务器安装的路径
database	”test”	数据库名
db_user	”system”	数据库用户名
db_port	54321	数据库监听的端口
db_mode	”oracle”	数据库使用的模式
db_auth	”trust”	数据库使用的加密方式
password	”123456”	密码（如果没有密码登录数据库，则无法提供密码项）
initdb_options	”-A trust -U $username”	initdb 指定的参数，不能够有-D 参数

-续表-

变量名称	默认值	意义
enable_fence	1	是否启用故障隔离
enable_esxi	0	是否启用基于 vmware_esxi 的故障隔离
esxi_server	192.168.4.5	用于配置 vmware_soap_fence 中服务器
esxi_user	root	用于配置 vmware_soap_fence 中用户
esxi_passwd	”Kingbase@99”	用于配置 vmware_soap_fence 中的用户密码
enable_ipmi	0	是否启用基于 ipmi 的故障隔离
ipmi_server	(192.168.2.100 192.168.2.101)	用于配置各节点的 fence_ipmilan 中的 ip 地址
ipmi_user	(Administrator Administrator)	用于配置各节点的 fence_ipmilan 中的用户
ipmi_passwd	(”Admin@9000” ” Admin@9000”)	用于配置各节点的 fence_ipmilan 中的用户密码
enable_qdisk_fence	1	是否启用基于 qdisk 的故障隔离
qdisk_watchdog_dev	/dev/watchdog	用于配置 fence_qdisk 的 watchdog 的设备文件，目前仅支持默认值/dev/watchdog，无需修改
qdisk_watchdog _timeout	30	用于配置 fence_qdisk 的 watchdog 的超时时间，单位为秒
enable_vip	0	是否启用虚拟 IP
virtual_ip	(192.168.4.1/24 192.168.4.2/24)	虚拟 IP 地址，其配置数量应小于等于节点个数，配置格式为 IPv4,v6/NETMASK
net_device	(bond0 bond0)	与虚拟 IP 绑定的网卡，其配置数量等于节点个数或只配一个（各个节点网卡一致）
net_device_ip	(10.12.2.125 10.12.2.127)	指定网卡上的实 IP，其配置数量必须等于节点个数
enable_heuristics	1	用于开启启发式扫描功能，网络分区故障时计算仲裁使用。发生网络分区时对所有节点进行启发式扫描判断其是否可用，只有通过扫描的分区才能被选为可用分区，以此来避免选出的分区无法对外提供服务。
heuristics_interval	1000	用于配置启发式扫描的时间间隔，单位为毫秒

-续表-

变量名称	默认值	意义
heuristics_timeout	10000	用于配置单次启发式扫描的超时时间，单位为毫秒
heuristics_ping _gateway	””	用于配置启发式扫描的网关地址，初始值默认为空，需要自行配置。
heuristics_reskey _attempts	1	用于配置启发式扫描的获取资源访问权的重试次数
heuristics_exec	exec_ping: /bin/ping -q -c $heuristics _reskey _attempts$heuristics _ping_gateway	用于配置执行启发式算法的组件。默认算法通过是否能 ping 通网关来判断是否能对外提供服务。
install_ssma	0	是否采用基于共享存储的多活分库方案安装数据库
install_rac	1	是否采用 RAC 方案，在本节所述方案中该配置必须为 0
rac_lms_port	53444	RAC 的 lms 进程所使用的端口，此配置仅在 install_rac 为 1 时才有意义
rac_lms_count	7	RAC 的 lms 进程的数量，此配置仅在 install_rac 为 1 时才有意义
rac_data	data	RAC 的 data 目录的名称，此配置仅在 install_rac 为 1 时才有意义
install_ssma	0	是否采用 SSMA 方案，在本节所述方案中该配置必须为 1
ssma_data_disk	(”-U f0c8f59d-0cc8-473c-970d-d19b30d87f5e” ”-U 7075f361-f3ad-48cf -87cc-ecc3db4a063a”)	在多活分库方案中，用于配置数据盘的 device 名称。此处采用设备的 uuid 形式，是为了避免 linux 重启时，可能导致磁盘名的错乱。如果能确保磁盘名不错乱，也可以配置成物理磁盘名，如/dev/sdx。
ssma_data_dir	(/sharedata/data1// sharedata/data2/)	在多活分库方案中，用于配置数据盘的挂载路径
ssma_port	(36321 36322)	在多活分库方案中，用于配置各节点上数据库端口号
ssma_fstype	ext4	在多活分库方案中，用于配置文件系统类型
connection_timeout	10	用于配置 sshd 或者 scmd 的超时时间，单位为秒
ssh_port	22	sshd 的端口号

-续表-

变量名称	默认值	意义
use_scmd	0	是否使用 scmd 搭建节点间免密，‘1’表示使用 scmd，‘0’表示使用 sshd
scmd_port	8890	scmd 的端口号
scmd_install_dir	/home/kingbase/KingbaseRAC/securecmdd	scmd 安装目录

5.3.1.1 搭建集群

如果安装目录不是 `/opt/KingbaseHA` ，则需要将配置文件 cluster_manager.conf 内的 `install_dir` 参数设置为用户自定义的路径。例如：`install_dir=/home/test/KingbaseHA` 。

推荐的搭建过程：

- **集群免密部署**

a. 节点间免密：

1. 安装数据库成功后，在 $ {install_dir}/ ClientTools/ guitools/ DeployTools/ zip/目录下获取 install.conf、trust_cluster.sh 和 securecmdd.zip；

对于通过 sshd 服务进行 clusterware 集群一键部署：

2. 编辑 install.conf 配置文件，在选项 all_ip 后填写所有节点 ip；
3. 使用 trust_cluster.sh 进行 ssh 免密配置，在配置过程中，由于脚本是交互式的，因此需要用户输入必要信息；

对于启动 sys_securecmdd 工具进行 clusterware 集群一键部署：

2. 将 securecmdd.zip 解压到合适的目录下；
3. 可选择的编辑 share 目录下的 sys_HAscmdd.conf，以更改 securecmdd 的配置；
4. 在每个节点的 securecmdd/bin 目录下执行 sh sys_HAscmdd.sh init 以初始化 securecmdd；
5. 在每个节点的 securecmdd/bin 目录下执行 sh sys_HAscmdd.sh start 以启动 securecmdd。

b. 免密部署：

首先请保证节点间完成免密，随后在集群任一节点上按需配置 cluster_manager.conf，并在该节点上执行如下命令：

```
./cluster_manager.sh --deploy
```

最后在运行终端执行以下命令使环境变量生效：

```
source /root/.bashrc
```

- **集群非免密部署**

1. 根据真实环境，配置好脚本的相关变量。
2. 选择一个节点执行 qdisk_init 操作（以下命令支持免交互执行，详见 - help 中的帮助说明）。

```
sh cluster_manager.sh --qdisk_init
```

3. 每个节点执行如下命令。

   该命令能够完成除了初始化数据库 data 目录和配置资源外的所有操作。

```
sh cluster_manager.sh --base_configure_init
```

4. 选择一个节点执行如下命令。

   该命令完成数据库初始化并配置资源，为环境变量配置参数。

```
source /root/.bashrc
sh cluster_manager.sh --config_resource
```

5. 使用如下命令，查看集群启动过程。

```
crm_mon
```

至此，整个集群搭建完毕。

如果要一键清除已完成的配置，每个节点执行如下命令。

```
sh cluster_manager.sh --clean_all
```

如果要一键卸载安装的程序，每个节点执行如下命令。

```
sh cluster_manager.sh --uninstall
```

注意:

执行 clean_all 命令将会删除集群的已修改的配置，包括集群软件和系统上的配置文件、环境变量、集群资源配置等，将集群还原到配置前的初始状态。而执行 uninstall 命令，将会删除整个集群安装的目录，即 install_dir 变量指定的路径。该两条命令均不会清除已经初始化的 kingbase 的 data 目录，如果需要清除数据目录，需要手动挂载目录并清除。

5.3.1.2　管理进程

下面的操作，仅对执行节点有效。

1) 使用如下命令，查看集群进程。

```
sh cluster_manager.sh --status
```

2) 使用如下命令，启动集群进程。

```
sh cluster_manager.sh --start
```

3) 使用如下命令，停止集群进程。

```
sh cluster_manager.sh --stop
```

5.3.1.3　开机自启

Clusterware 提供了开机自启功能，即集群节点故障后，重新启动时可以自动地加入集群并继续提供服务。

下面的操作，仅对执行节点有效。

1) 功能开启需确保 cluster_manager.conf 中的 keep_cluster_alive 参数被配置为 1，该参数默认为 0 关闭。

   如果执行搭建集群前开启了 keep_cluster_alive 参数，则该功能会随着部署命令 base_configure_init 自动配置，无需手动执行 config_keep_cluster_alive 进行配置。

2) 使用如下命令，手动开启开机自启功能。

注意:

需要保证第一步 keep_cluster_alive 参数为 1 开启，否则命令执行不成功。

```
sh cluster_manager.sh --config_keep_cluster_alive
```

---

3) 使用如下命令，手动关闭开机自启功能。

注意:

彻底关闭开机自启功能需要保证第一步 keep_cluster_alive 参数为 0 关闭，否则调用“sh cluster_manager.sh --start”手动拉起集群会恢复开机自启功能。

```
sh cluster_manager.sh --clean_keep_cluster_alive
```

注意:

1) 开机自启功能依赖于操作系统的 crontab service 服务，使用前请确认系统 crontab service 服务是否正常运行。
2) 开机自启功能开启后，不支持停单一组件的命令（包含 stop_corosync、stop_pacemaker、stop_qdevice）。
3) 节点集群组件整体停止命令“sh cluster_manager.sh －stop”会自动关闭开机自启功能，同样地，彻底关闭开机自启功能仍需要保证 keep_cluster_alive 参数为 0 关闭。“‘{anchor} 手工搭建集群

5.3.2 使用命令行搭建集群

以下操作需要在集群中每个节点执行：

5.3.2.1 配置主机名称

1) 编辑/etc/hostname。

```
vi /etc/hostname
```

添加主机名 node1。

```
node1
```

2) 执行如下命令，修改 hostname。

```
hostname node1
```

3) 修改/etc/hosts 文件，将主机名与 IP 地址对应。

格式为先 IP，然后空格，最后是主机名，示例如下：

```
192.168.5.1 node1
```

5.3.2.2 配置投票盘

1) 执行 fdisk -l 命令查看，我们将/dev/sde 作为共享磁盘投票盘。

```
fdisk -l

Disk /dev/sda: 21.5 GB, 21474836480 bytes, 41943040 sectors
```

```
Units = sectors of 1 * 512 = 512 bytes
Sector size (logical/physical): 512 bytes / 512 bytes
I/O size (minimum/optimal): 512 bytes / 512 bytes
Disk label type: dos
Disk identifier: 0x000be610

    Device Boot      Start         End      Blocks   Id  System
/dev/sda1   *        2048     2099199     1048576   83  Linux
/dev/sda2         2099200    41943039    19921920   8e  Linux LVM

Disk /dev/sdb: 33.3 GB, 33285996544 bytes, 65011712 sectors
Units = sectors of 1 * 512 = 512 bytes
Sector size (logical/physical): 512 bytes / 512 bytes
I/O size (minimum/optimal): 512 bytes / 512 bytes
Disk label type: dos
Disk identifier: 0xfc8de79d

    Device Boot      Start         End      Blocks   Id  System

Disk /dev/mapper/centos-root: 18.2 GB, 18249416704 bytes, 35643392 sectors
Units = sectors of 1 * 512 = 512 bytes
Sector size (logical/physical): 512 bytes / 512 bytes
I/O size (minimum/optimal): 512 bytes / 512 bytes


Disk /dev/mapper/centos-swap: 2147 MB, 2147483648 bytes, 4194304 sectors
Units = sectors of 1 * 512 = 512 bytes
Sector size (logical/physical): 512 bytes / 512 bytes
I/O size (minimum/optimal): 512 bytes / 512 bytes


Disk /dev/sdc: 53.7 GB, 53687091200 bytes, 104857600 sectors
Units = sectors of 1 * 512 = 512 bytes
Sector size (logical/physical): 512 bytes / 512 bytes
I/O size (minimum/optimal): 512 bytes / 512 bytes


Disk /dev/sdd: 53.7 GB, 53687091200 bytes, 104857600 sectors
Units = sectors of 1 * 512 = 512 bytes
Sector size (logical/physical): 512 bytes / 512 bytes
I/O size (minimum/optimal): 512 bytes / 512 bytes


Disk /dev/sde: 10.7 GB, 10737418240 bytes, 20971520 sectors
Units = sectors of 1 * 512 = 512 bytes
```

```
Sector size (logical/physical): 512 bytes / 512 bytes
I/O size (minimum/optimal): 512 bytes / 512 bytes
```

2) 使用 mkqdisk 工具进行投票盘初始化。

```
cd /opt/KingbaseHA/corosync-qdevice/sbin/
./mkqdisk -c /dev/sde -l kcluster
```

3) 通过如下命令，可以查看共享磁盘状态。

```
./mkqdisk -f kcluster -d

/dev/block/8:64:
/dev/disk/by-id/scsi-36000c2900dc5b0faf12188476a673a3f:
/dev/disk/by-id/wwn-0x6000c2900dc5b0faf12188476a673a3f:
/dev/disk/by-path/pci-0000:13:00.0-scsi-0:0:2:0:
/dev/sde:
     Magic:                eb7a62c2
     Label:                kcluster
     Created:              Mon Mar  1 12:01:00 2021
     Host:                 node3
     Kernel Sector Size:   512
     Recorded Sector Size: 512
```

5.3.2.3　配置并启动 corosync

1) 执行如下命令，配置 corosync.conf。

```
cd /opt/KingbaseHA/corosync/etc/corosync
vi corosync.conf
```

添加如下内容：

```
totem {
  version: 2
  cluster_name: kcluster
  token: 12000
  token_retransmits_before_loss_const: 12
  join: 10000
  crypto_hash: none
  crypto_cipher: none
  interface {
    knet_ping_interval: 1500
    knet_ping_timeout: 6000
```

```
  }
}

nodelist {
  node {
   ring0_addr: node1
    nodeid: 1
  }

  node {
    ring0_addr: node2
    nodeid: 2
  }
}

quorum {
  provider: corosync_votequorum
  expected_votes: 3
  hold_quorum: 1
  device {
      timeout: 60000
      sync_timeout: 70000
      master_wins: 1
      votes: 1
      model: disk
      disk {
        debug: 0
        interval: 1000
        tko: 30
        tko_up: 2
        upgrade_wait: 1
        master_wait: 3
        label: kcluster
        io_timeout: 1
        fence_timeout: 50000
        enable_qdisk_fence: 1
        qdisk_watchdog_dev: /dev/watchdog
        qdisk_watchdog_timeout: 30
      }
      heuristics {
        mode: on
        interval: 1000
        timeout: 10000
        exec_ping: /bin/ping -q -c 1 192.168.4.1
      }
```

```
  }
}

logging {
  debug: off
  to_logfile: yes
  logfile: /opt/KingbaseHA/corosync/var/log/cluster/corosync.log
  logger_subsys {
      subsys: QDEVICE
      debug: off
  }
}
```

其中 nodelist 是配置集群节点信息，每个节点只需提供 name,nodeid,ring0_addr。其中，name 通常指定节点名称，一般用 hostname。nodeid 指集群节点号，需从 1 开始。ring0_addr 指定节点通信接口，一般用 hostname，corosync 将会自动寻找 hostname 对应的 ip，然后使用该 ip 对应的接口名称。

需要配置多个节点时，只需往该文件中加 node{}。

Quorum 配置集群的投票信息，针对 device，一般配置 votes，该 votes 要求不小于集群节点数 - 1，disk 中的 label 指明共享投票盘的位置，需要和使用 mkqdisk 工具初始化的-l 对应。

2) 执行如下命令将启动脚本拷贝到系统初始化脚本目录。

```
cp /opt/KingbaseHA/corosync/corosync /etc/init.d/
```

3) 执行如下命令，创建 lock 目录。

```
mkdir -p /opt/KingbaseHA/corosync/var/lock/subsys
mkdir /opt/KingbaseHA/corosync/var/run
```

4) 执行如下命令，配置 corosync 的 logrotate。

```
cp /opt/KingbaseHA/corosync/etc/logrotate.d/corosync /etc/logrotate.d/
```

5) 执行如下命令启动 corosync。

```
/etc/init.d/corosync start
```

6) 执行如下命令，查看 corosync 启动状态。

```
tail -f /opt/KingbaseHA/corosync/var/log/cluster/corosync.log

Jul 17 10:09:10 [12256] node1 corosync notice [TOTEM ] A new membership
(1.14) was formed. Members joined: 1
Jul 17 10:09:10 [12256] node1 corosync notice [QUORUM] Members[1]: 1
```

```
Jul 17 10:09:10 [12256] node1 corosync notice [MAIN ] Completed service
synchronization, ready to provide service.
```

5.3.2.4 配置并启动 pacemaker

1) 执行如下命令，创建 pacemaker 管理用户。

```
groupadd haclient
useradd hacluster -g haclient
```

2) 执行如下命令，添加环境变量。

```
vi /root/.bashrc
```

添加如下内容：

```
export
PATH=/opt/KingbaseHA/python2.7/bin:/opt/KingbaseHA/pacemaker/sbin/:$PATH
export
PATH=/opt/KingbaseHA/crmsh/bin:/opt/KingbaseHA/pacemaker/libexec/pacemaker/:
$PATH
export
PATH=/opt/KingbaseHA/corosync/sbin:/opt/KingbaseHA/corosync-qdevice/sbin:
$PATH
export
PYTHONPATH=/opt/KingbaseHA/python2.7/lib/python2.7/site-packages/:
/opt/KingbaseHA/crmsh/lib/python2.7/site-packages:$PYTHONPATH
export
COROSYNC_MAIN_CONFIG_FILE=/opt/KingbaseHA/corosync/etc/corosync/corosync.conf
export CRM_CONFIG_FILE=/opt/KingbaseHA/crmsh/etc/crm/crm.conf
export OCF_ROOT=/opt/KingbaseHA/pacemaker/ocf/
export HA_SBIN_DIR=/opt/KingbaseHA/pacemaker/sbin/
```

3) 执行如下命令，让环境变量生效。

```
source /root/.bashrc
```

4) 执行如下命令，拷贝启动脚本到系统初始化脚本位置。

```
cp /opt/KingbaseHA/pacemaker/pacemaker /etc/init.d/
```

5) 执行如下命令，配置 pacemaker logrotate。

```
cp /opt/KingbaseHA/pacemaker/etc/logrotate.d/pacemaker /etc/logrotate.d/
```

6) 执行如下命令，创建 lock 目录。

```
mkdir -p /opt/KingbaseHA/pacemaker/var/lock/subsys
```

7) 执行如下命令，确保 pacemaker 的各个守护进程有权限操作对应目录。

```
chown -R hacluster:haclient /opt/KingbaseHA/pacemaker
```

8) 执行如下命令，启动 pacemaker。

```
/etc/init.d/pacemaker start
```

9) 执行如下命令，查看 pacemaker 日志，观察启动情况。

```
tail -f /opt/KingbaseHA/pacemaker/var/log/pacemaker/pacemaker.log
```

5.3.2.5　启动 corosync-qdevice

1) 执行如下命令，拷贝 qdevie 启动脚本到系统存放初始化脚本的位置。

```
cp /opt/KingbaseHA/corosync-qdevice/corosync-qdevice /etc/init.d/
```

2) 执行如下命令，创建 lock 目录。

```
mkdir -p /opt/KingbaseHA/corosync-qdevice/var/lock/subsys
```

3) 执行如下命令，启动 corosync-qdevice。

```
/etc/init.d/corosync-qdevice start
```

4) 查看启动的日志，该日志一般放在系统 syslog 里面，搜索关键字 corosync-qdevice。

```
2020-07-20T11:26:25.744754+08:00 localhost corosync-qdevice[5849]: m_arg = 16
2020-07-20T11:26:25.744784+08:00 localhost corosync-qdevice[5849]: m_seq = 16
2020-07-20T11:26:25.744814+08:00 localhost corosync-qdevice[5849]: }
2020-07-20T11:26:25.744845+08:00 localhost corosync-qdevice[5849]:
ni_state = 0x00000000 (None)
2020-07-20T11:26:25.744876+08:00 localhost corosync-qdevice[5849]:
ni_status.ps_ringid = 16,16
2020-07-20T11:26:25.744907+08:00 localhost corosync-qdevice[5849]:
ni_status.ps_member_count = 16
2020-07-20T11:26:25.744937+08:00 localhost corosync-qdevice[5849]: }
```

5) 执行如下命令，查看 qdevice 状态。

```
/opt/KingbaseHA/corosync-qdevice/sbin/corosync-qdevice-tool -sv -p
/opt/KingbaseHA/corosync-qdevice/var/run/corosync-qdevice/
corosync-qdevice.sock
```

5.3.2.6　配置 crmsh

crmsh 用于部署和运维过程中的资源配置、资源操作和存储查看，支持的相关子命令为：configure、resource、storage。其他子命令不在支持范围，可以使用 crm_ 系列命令、corosync_ 系列命令替代。

1) 配置 crm.conf，路径为/opt/KingbaseHA/crmsh/etc/crm/crm.conf，修改其中配置项的值如下。

```
[core]
pager = less -R

[path]
sharedir = /opt/KingbaseHA/crmsh/share/crmsh
crm_daemon_usr = hacluster
ocf_root = /opt/KingbaseHA/pacemaker/ocf
crm_dtd_dir = /opt/KingbaseHA/pacemaker/share/pacemaker
```

2) 配置 crm_dsn.conf，以两节点各一个 kingbase 资源为例，节点 1 kingbase 资源名为 Kingbase reourse name1，节点 2 kingbase 资源名为 Kingbase reourse name2，依此类推，路径为/opt/KingbaseHA/crmsh/etc/crm/crm_dsn.conf，其中的 password 为 base64 编码，可通过 echo -n ‘123456’ | base64 得到编码后的密码。

```
# 注意配置需要项格
[Kingbase reourse name1]        /* kingbase 资源名 */
port=36321                      /* KingbaseES 资源监听端口号 */
database=test /* 数据库名，一般使用系统自带的 test 数据库即可 */
username=system                 /* 数据库管理员 */
password=MTIzNDU2               /* 数据库管理员密码 */

[Kingbase reourse name2]        /* kingbase 资源名 */
port=36322
database=test
username=system
password=MTIzNDU2
```

5.3.2.7　crm 配置资源

该操作只需在某一台机器上执行。

资源：

- 两个 VIP 资源
- 两个 filesystem 资源
- 两个 KingbaseES 数据库资源
- fence 资源

1) 执行如下命令，配置 fence。

针对 VMWARE ESXi 环境、IPMI 环境以及不带远程电源控制的环境，给出三种不同的配置。

下面是针对 VMWARE ESXi 配置 fence：

1. 使用 fence_vmware_soap 验证可以 fence 的机器，注意机器的主机名需要与下面命令查出的主机名对应。

```
fence_vmware_soap -a 192.168.4.5 -z -l root -p 'Kingbase@99'
--ssl-insecure -o list
--
R0cky_4.225,564db803-649a-98f3-4d63-d4988bcc8d67
centos7-node5_4.230,564d6e77-6ca0-25b3-b48d-4e80c27dc1f6
rocky_227,564d351d-d9d4-9c29-f570-4aead1476b1f
centos7-node6_4.231,564da140-cedc-7958-e477-966f08c1c21a
rocky_226,564dba52-7f8d-af92-9187-a75d3a74cebf
centos7-node4_4.225,564d9efe-8044-ba39-a946-b913730c6aeb
centos7-node3_4.224,564d22af-fbcc-2399-b67e-27a793933c54
rocky_228,564d9951-8830-1aec-f067-7673bf9e4053
centos7-node7_4.232,564dec1b-fb7b-1cb7-f961-c468df1ebb46
centos7-node1_4.222,564d8fed-770a-ca7d-8481-13270d38cf6f
Kylin-4.0.2-server-sp1-TEST2_4.39,564dfcb9-169a-d2fc-a8f2-bc4e56dd3755
DeepinTest1_4.42,564d4a66-cdf4-56c9-2b8e-ed5d595181c2
centos7-node2_4.223,564d7c7c-6f32-eedb-13a9-7577dc4d7c73
centos7-node8_4.229,564d7c7c-6f32-eedb-13a9-7577dc4d7c73
Kylin-4.0.2-server-sp1-TEST1_4.37,564dd89f-81dd-f515-e8a5-5eb844dd5240
vpn,564d87fa-9ce1-23c8-298d-fd3864265ceb
win7_215,564d359e-7c7b-54ef-7d68-724461456ef8
neokylin7-TEST1,564d1661-a21c-e4b8-9300-a168b2e58684
```

2. 配置 fence。

```
crm configure primitive esxi_fence stonith:fence_vmware_soap \
   params ipaddr=192.168.4.5 login=root passwd='Kingbase@99'
pcmk_host_check=none ssl=1 ssl_insecure=1 \
   op monitor interval=60s \
   meta failure-timeout=5min
```

3. 可以使用如下命令，测试 fence，下面命令是给 centos7-node4_4.225 发送 reboot 命令。

```
fence_vmware_soap -a 192.168.4.5 -l root -p 'Kingbase@99' -z --ssl-insecure -o reboot -n
centos7-node4_4.225
```

4. 看节点是否重启。

下面是针对 ipmi 环境配置 fence：

1. 针对 ipmilan 环境配置 fence，需要注意 IPMI 设备一般为各个节点独占，因此需要为各个节点配置单独的 fence 资源。

   针对 node1 设置 fence：

```
crm configure primitive fence_node1_ipmi stonith:fence_ipmilan \
     params ipaddr=192.168.2.100 login=Administrator
passwd="Admin@9000" pcmk_host_list=node1
lanplus=true ipmitool_path=/opt/KingbaseHA/ipmi_tool/bin/ipmitool \
     op monitor interval=60s \
     meta failure-timeout=5min
```

   针对 node2 设置 fence：

```
crm configure primitive fence_node2_ipmi stonith:fence_ipmilan \
     params ipaddr=192.168.2.101 login=Administrator
passwd="Admin@9000" pcmk_host_list=node2
lanplus=true ipmitool_path=/opt/KingbaseHA/ipmi_tool/bin/ipmitool \
     op monitor interval=60s \
     meta failure-timeout=5min
```

2. 执行如下命令，添加 fence_node1_ipmi 和 fence_node2_ipmi 的 location 约束。为了保证 fence_node1_ipmi 资源尽量不在节点 node1，fence_node2_ipmi 资源尽量不在节点 node2，从而减少 fence 自己的概率，又由于资源在各个节点的默认分数为 0，因此需要保证 fence_node1_ipmi 资源在 node2 的分数、fence_node2_ipmi 在 node1 的分数均大于 rsc_defaults resource-stickiness 的分数。

```
crm configure location fence_node1_ipmi-on-node2 fence_node1_ipmi 1000: node2
crm configure location fence_node2_ipmi-on-node1 fence_node2_ipmi 1000: node1
```

3. 可以使用如下命令，测试 fence，下面命令是向 192.168.2.100 发送 reboot 命令。

```
fence_ipmilan -a 192.168.2.100 -l Administrator -p 'Admin@9000' -P --ipmitool-path=/opt/
KingbaseHA/ipmi_tool/bin/ipmitool -o reboot
```

4. 看节点是否重启。

下面是针对无远程电源控制的环境配置 fence_qdisk：

1. 针对无远程电源控制的环境配置 fence，需要注意 fence_qdisk 设备一般为各个节点独占，因此需要为各个节点配置单独的 fence 资源。

针对 node1 设置 fence：

```
crm configure primitive fence_node1_qdisk stonith:fence_qdisk \
     params qdisk_path=/dev/sde qdisk_fence_tool=/opt/KingbaseHA/corosync-qdevice/sbin/
qdisk-fence-tool pcmk_host_list=node1 \
     op monitor interval=60s \
     meta failure-timeout=5min
```

针对 node2 设置 fence：

```
crm configure primitive fence_node2_qdisk stonith:fence_qdisk \
     params qdisk_path=/dev/sde qdisk_fence_tool=/opt/KingbaseHA/corosync-qdevice/sbin/
qdisk-fence-tool pcmk_host_list=node2 \
     op monitor interval=60s \
     meta failure-timeout=5min
```

2. 执行如下命令，添加 fence_node1_qdisk 和 fence_node2_qdisk 的 location 约束。同 IPMI 的方式，为了保证 fence_node1_qdisk 资源尽量不在节点 node1，fence_node2_qdisk 资源尽量不在节点 node2，从而减少 fence 自己的概率，又由于资源在各个节点的默认分数为 0，因此需要保证 fence_node1_qdisk 资源在 node2 的分数、fence_node2_qdisk 在 node1 的分数均大于 rsc_defaults resource-stickiness 的分数。

```
crm configure location fence_node1_qdisk-on-node2 fence_node1_qdisk 1000: node2
crm configure location fence_node2_qdisk-on-node1 fence_node2_qdisk 1000: node1
```

3. 可以使用如下命令，测试 fence，下面命令是向 node1 发送 reboot 命令。

```
fence_qdisk --qdisk-fence-tool=/opt/KingbaseHA/corosync-qdevice/sbin/qdisk-fence-tool --
qdisk-path=/dev/sde --action=reboot --plug=node1
```

4. 看节点是否重启。

2) 执行如下命令添加 FIP1 资源，其中 cidr_netmask 最好与 bond0 接口所在的非浮动 IP 的 netmask 保持一致，保证在集群中各节点都具有此同名网卡接口，可以使用 ip addr 查看。

```
crm configure primitive FIP1 ocf:heartbeat:IPaddr2 \
  params ip="192.168.4.135" cidr_netmask="24" nic="bond0" \
  arp_sender="iputils_arping" \
  op monitor interval="30s" timeout="60s" \
  op start interval="0" timeout="60s" \
  op stop interval="0" timeout="60s" \
  meta failure-timeout=5min
```

3) 执行如下命令，添加 VIP1 location 约束，多个节点最好分数不一样。

```
crm configure location FIP1-on-node1 FIP1 1000: node1
```

4) 执行如下命令。

   添加 FIP2 资源，cidr_netmask 最好与 bond0 接口原有非浮动 IP 的 netmask 保持一致，保证在集群中各节点都具有此同名网卡接口，可以使用 ip addr 查看。

```
crm configure primitive FIP2 ocf:heartbeat:IPaddr2 \
  params ip="192.168.4.136" cidr_netmask="24" nic="bond0" \
  arp_sender="iputils_arping" \
  op monitor interval="30s" timeout="60s" \
  op start interval="0" timeout="60s" \
  op stop interval="0" timeout="60s" \
  meta failure-timeout=5min
```

5) 执行如下命令，添加 FILESYSTEM1 资源，需确保每个节点/sharedata/data1 目录存在，sharedata 属主是 root，data1 属主改成数据库用户。使用如下命令查看存储设备/dev/sdc 对应的 uuid。

```
blkid /dev/sdc
/dev/sdc: UUID="d8f017f4-6c0a-4cd2-aee3-1a5c522f3cd8" TYPE="ext4"
```

6) 添加 FILESYSTEM1 资源。

```
crm configure primitive FILESYSTEM1 ocf:heartbeat:Filesystem \
     params device="-U d8f017f4-6c0a-4cd2-aee3-1a5c522f3cd8" \
     directory="/sharedata/data1" fstype="ext4" \
     op start interval="0" timeout="60" \
     op stop interval="0" timeout="60" \
     op monitor interval="30s" timeout="60" OCF_CHECK_LEVEL="20" \
     meta failure-timeout=5min
```

7) 执行如下命令，添加 FILESYSTEM2，需确保每个节点/sharedata/data2 目录存在，sharedata 属主是 root，data2 属主改成数据库用户。

   查看 uuid：

```
blkid /dev/sdd
/dev/sdd: UUID="e56c1f6f-b791-4f0e-8780-5b3aeaef94d5" TYPE="ext4"
```

```
crm configure primitive FILESYSTEM2 ocf:heartbeat:Filesystem \
     params device="-U e56c1f6f-b791-4f0e-8780-5b3aeaef94d5" \
     directory="/sharedata/data2" fstype="ext4" \
     op start interval="0" timeout="60" \
     op stop interval="0" timeout="60" \
     op monitor interval="30s" timeout="60" OCF_CHECK_LEVEL="20" \
     meta failure-timeout=5min
```

8) 执行如下命令，添加一个分库资源，注意/ sharedata/ data1/ data 目录下的 kingbase.conf 需要手动配置 port=36321，需要手动创建/home/kingbase/KingbaseRAC/Server/log 目录。

```
crm configure primitive DB1 ocf:kingbase:kingbase \
    params sys_ctl="/home/kingbase/KingbaseRAC/Server/bin/sys_ctl" \
    ksql="/home/kingbase/KingbaseRAC/Server/bin/ksql" \
    sys_isready="/home/kingbase/KingbaseRAC/Server/bin/sys_isready" \
    kb_data="/sharedata/data1/data" \
    kb_dba="kingbase" kb_host="0.0.0.0" \
    kb_user="system" \
    kb_port="36321" \
    kb_libs="/home/kingbase/KingbaseRAC/Server/lib" \
    kb_db="template1" \
    logfile="/home/kingbase/KingbaseRAC/Server/log/kingbase1.log" \
    op start interval="0" timeout="120" \
    op stop interval="0" timeout="120" \
    op monitor interval="9s" timeout="30" \
    meta failure-timeout=5min
```

9) 执行如下命令，添加另一个分库资源，需要修改相应的/ sharedata/ data2/ data/ kingbase.conf 中的 port 为 36322。

```
crm configure primitive DB2 ocf:kingbase:kingbase \
    params sys_ctl="/home/kingbase/KingbaseRAC/Server/bin/sys_ctl" \
    ksql="/home/kingbase/KingbaseRAC/Server/bin/ksql" \
    sys_isready="/home/kingbase/KingbaseRAC/Server/bin/sys_isready" \
    kb_data="/sharedata/data2/data" \
    kb_dba="kingbase" kb_host="0.0.0.0" \
    kb_user="system" \
    kb_port="36322" \
    kb_libs="/home/kingbase/KingbaseRAC/Server/lib" \
    kb_db="template1" \
    logfile="/home/kingbase/KingbaseRAC/Server/log/kingbase2.log" \
    op start interval="0" timeout="120" \
    op stop interval="0" timeout="120" \
    op monitor interval="9s" timeout="30" \
    meta failure-timeout=5min
```

10) 执行如下命令，创建 DB1 组资源。

```
crm configure group DB1_GROUP FIP1 FILESYSTEM1 DB1
```

11) 执行如下命令，创建 DB2 组资源。

```
crm configure group DB2_GROUP FIP2 FILESYSTEM2 DB2
```

12) 添加 DB1 location 约束，多个节点最好分数不一样。

```
crm configure location DB1-on-node1 DB1_GROUP 1000: node1
crm configure location DB1-on-node2 DB1_GROUP 800: node2
```

13) 添加 DB2 location 约束，为了达到负载均衡，DB2 资源在各个节点的分数要和 DB1 正好相反。

```
crm configure location DB2-on-node1 DB2_GROUP 800: node1
crm configure location DB2-on-node2 DB2_GROUP 1000: node2
```

14) 设置资源保留在原节点的分数，如果考虑高可用性，即重启节点不产生资源迁移，需确保 location 约束的分数 + 该分数都大于最大的 location 得到的分数。如果考虑性能，即资源负载问题，那么需要将该值设置的越小越好。

```
crm configure rsc_defaults resource-stickiness=500
```

5.4 应急预案

本章节包含以下内容：

- 故障处理行为
- 从计划外停机中恢复

5.4.1 故障处理行为

本章节介绍部分常见的故障，对于故障的恢复请参考“从计划外停机中恢复”一节的内容。

5.4.1.1 网络类故障

表 5.4.1: 网络类故障

故障类型	故障处理行为		业务影响
	数据库端口占用	故障节点会尝试重启数据库资源，达到 timeout（120s）后转移资源至另外节点。	1. 数据库端口被占用后业务中断 2. 资源转移成功后业务恢复正常

网络类

故障

-续表-

故障类型	故障处理行为			业务影响
	网络中断		1. 对于节点整个网络中断（不包含 ipmi），节点会在检测网络中断 30s 后重启服务器，重启后该节点资源会转移至可用节点； 2. 对于心跳线网络中断，此时主节点会 fence 备机节点并转移资源至可用节点。	1. 网络中断后业务中断 2. 资源转移成功后业务恢复正常
	网络丢包	10%	服务正常，未触发资源故障。	业务正常，有一定延迟。
		>10%	服务正常，未触发资源故障。	业务延迟较大，出现超时报错。
	网络延迟	0.5s-5s	服务正常，未触发资源故障。	业务延迟较大，出现超时报错。
	网络单次分区	1:1	1. 选取 qdevice 的 master 所在集群为可用节点 (2 节点集群，id 小的节点会升级为 master)。 2.Fence 其他节点 3. 转移资源至可用节点	1. 节点被 fence 后数据库业务中断 2. 数据库资源转移成功后恢复正常
		1:2	1. 节点数量为 2 的集群获得 quorum，节点数量为 1 的节点失去 quorum 2.Fence 失去 quorum 节点 3. 转移资源至可用节点	1. 被 fence 节点数据库业务中断 2. 数据库资源转移成功后恢复正常
		1:1:1	1. 网络分区后，节点 id 小的节点获得 quorum 2. 获得 quorum 的节点 fence 其它节点 3. 转移资源到获得 quorum 的节点	1. 被 fence 节点数据库业务中断 2. 数据库资源转移成功后恢复正常
	网关失联		节点会在检测网络中断 30s 后重启服务器，重启后该节点资源会转移至可用节点。	1. 资源开始转移后数据库业务中断 2. 数据库资源转移成功后恢复正常

5.4.1.2　状态变化类故障

注意:

目前资源的 stop 操作 on-fail 设置是 fence，意味着如果因为进程的 hang 住导致 clusterware 对资源的 stop 操作无法完成，会最终使得节点被 fence，即使此时集群中已经没有其他可用节点。

表 5.4.2: 状态变化类故障

故障类型	故障处理行为			业务影响
状态变化类故障	关机		1.Fence 故障节点（关机后的节点会因 fence 操作重启） 2. 转移故障节点资源到可用节点	1. 数据库节点关机后业务中断 2. 数据库资源转移成功后恢复正常
	掉电（IPMI 电源保持）		1.Fence 故障节点 2. 转移故障节点资源到可用节点 3. 若节点长期掉电或因硬件损坏导致无法启动，会因 fence 失败导致资源无法正确转移。	1. 数据库节点关机后业务中断 2. 数据库资源转移成功后恢复正常
	重启		1.Fence 故障节点（reboot 的节点可能会在 reboot 过程中再次被 fence 触发 reboot） 2. 转移故障节点资源到可用节点	1. 数据库节点关机后业务中断 2. 数据库资源转移成功后恢复正常
	数据库意外关闭		pacemaker 在检测到数据库 down 掉后自动重启数据库	1. 数据库停止后业务中断 2. 数据库重启成功后恢复正常
	进程异常终止	pacemaker（DC）	1. 可用节点会当选为 DC 节点 2. 转移故障节点资源到可用节点	无影响
		pacemaker（非 DC）	转移故障节点资源到可用节点	无影响
		pacemaker-controld	Pacemaker 主进程会在检测到 pacemaker-controld 意外退出后重新生成 pacemaker-controld 进程	无影响
		pacemaker-based	1.Fence 故障节点 2. 转移故障节点资源到可用节点	1. 数据库节点关机后业务中断 2. 数据库资源转移成功后恢复正常
		pacemaker-fenced	Pacemaker 主进程会在检测到 pacemaker-fenced 意外退出后重新生成 pacemaker-fenced 进程	无影响
		pacemaker-execd	Pacemaker 主进程会在检测到 pacemaker-execd 意外退出后重新生成 pacemaker-execd 进程	无影响

-续表-

故障类型	故障处理行为			业务影响
		pacemaker-attrd	Pacemaker 主进程会在检测到 pacemaker-attrd 意外退出后重新生成 pacemaker-attrd 进程	无影响
		pacemaker-schedulerd	Pacemaker 主进程会在检测到 pacemaker-schedulerd 意外退出后重新生成 pacemaker-schedulerd 进程	无影响
		corosync	1.Fence 故障节点 2. 转移故障节点资源到可用节点	1. 故障节点数据库被 fence 后业务中断 2. 数据库资源转移成功后恢复正常 3. 恢复时长：fence 成功时间 + 资源转移成功时间，总时间大于 35s。
		corosync-qdevice (master)	1.Fence 故障节点 2. 转移故障节点资源到可用节点	1. 故障节点数据库被 fence 后业务中断 2. 数据库资源转移成功后恢复正常 3. 恢复时长：fence 成功时间 + 资源转移成功时间，总时间大于 65s。
状态变化类故障		corosync-qdevice (slave)	1.Fence 故障节点 2. 转移故障节点资源到可用节点	1. 故障节点数据库被 fence 后业务中断 2. 数据库资源转移成功后恢复正常 3. 恢复时长：fence 成功时间 + 资源转移成功时间，总时间大于 60s。
		kingbase	pacemaker 在检测到数据库进程故障后自动重启数据库	数据库进程故障后业务中断，数据库重启成功后恢复正常。
	进程 hang	pacemaker(DC)	1.hang 住节点的 crm_mon 无法查看集群状态 2. 资源保持当前状态不变 3. 此时集群发生故障无法进行故障转移—集群失去高可用 4. 恢复 hang 住的 pacemaker 后该节点资源会重启	1.Pacemaker 进程 hang 住后业务可正常运行 2.hang 住的 pacemaker 恢复后资源会重启
		pacemaker(非 DC)	1.hang 住节点的 crm_mon 无法查看集群状态 2. 资源保持当前状态不变 3. 此时集群发生故障无法进行故障转移—集群失去高可用	1. 不影响，期间该节点会失去高可用。

-续表-

故障类型	故障处理行为			业务影响
		corosync	1.Fence 故障节点 2. 转移故障节点资源到可用节点	1. 故障节点数据库被 fence 后业务中断 2. 数据库资源转移成功后恢复正常
		corosync-qdevice(master)	1.Fence 故障节点 2. 转移故障节点资源到可用节点	1. 故障节点数据库被 fence 后业务中断 2. 数据库资源转移成功后恢复正常
		corosync-qdevice(slave)	1.Fence 故障节点 2. 转移故障节点资源到可用节点	1. 故障节点数据库被 fence 后业务中断 2. 数据库资源转移成功后恢复正常
		kingbase	暂不支持处理该故障	暂不支持处理该故障
	系统崩溃		1.Fence 故障节点 2. 转移故障节点资源到可用节点	1. 数据库节点系统崩溃后业务中断 2. 数据库资源转移成功后恢复正常
	系统时间跳变		1. 集群状态正常，业务正常运行。 2. 一段时间后 ntpd 自动正确同步时间。	无影响

5.4.1.3　资源耗尽类故障

表 5.4.3: 资源耗尽类故障

故障类型		故障处理行为	业务影响
资源耗尽类故障	磁盘满（数据盘）	资源状态未发生变化，各资源未发生故障。	1. 数据库业务执行失败，日志报错 could not write to log file: No space left on device 。 2. 磁盘空间充足后，可自动恢复正常。

-续表-

故障类型		故障处理行为	业务影响
	磁盘 IO 高(数据盘)	1. 资源状态未发生变化，各资源未发生故障。 2. 可能导致文件系统资源故障重启	1. 无影响。 2. 若文件系统资源故障重启，则在资源故障后到资源恢复前业务执行失败。
	投票盘 IO 高	1. 资源状态未发生变化，各资源未发生故障。 2. 可能导致文件系统资源故障重启	1. 无影响。 2. 若文件系统资源故障重启，则在资源故障后到资源恢复前业务执行失败。
	内存使用率高	1. 资源状态未发生变化，各资源未发生故障。 2. 可能导致资源故障重启	1. 无影响。 2. 若资源故障重启，则在资源故障后到资源恢复前业务执行失败。
	cpu 利用率高	1. 资源状态未发生变化，各资源未发生故障。 2. 可能导致资源故障重启	1. 无影响。 2. 若资源故障重启，则在资源故障后到资源恢复前业务执行失败。

5.4.2 从计划外停机中恢复

5.4.2.1 实例故障、主机/网络故障但存储可用

在发生实例、主机、网络故障时，clusterware 会自动将资源运行到正常的节点，并重启故障或是在网络分区时被认为应离开集群的节点。

在修复故障后可以通过重启 clusterware 将节点加入集群，在推荐配置中没有设置资源的节点偏好，启动 clusterware 后需要手动移动资源到加入的节点。如果有设置资源的节点偏好，重新加入节点会造成资源的迁移导致服务短暂中断。

1. 启动 clusterware

```
./cluster_manager.sh start
```

2. 移动资源到重加入的节点
    1. 通过 crm_mon 确认资源当前运行的节点（假设节点名为节点 2）
    2. 移动资源（假设名称为资源 1）从节点 2 到重加入的节点 1
    3. 通过 crm_mon 确认资源正确转移
    4. 清理节点 2 上的资源移动规则

5.4.2.2 存储故障/数据损坏的恢复

clusterware 本身不提供存储支持或数据冗余，故障后 clusterware 需要从备份恢复配置。

5.4.2.3 集群故障或站点故障的恢复

clusterware 本身不提供跨站点或集群的冗余，故障后 clusterware 需要从备份恢复配置。

5.4.2.4 FENCE 设备故障的恢复

FENCE 设备是保障集群共享资源被正确操作的基础，集群中节点的 FENCE 设备损坏时该节点再发生其他故障将导致集群试图 FENCE 该节点而停止其他服务。

恢复方式：

1. 手动处理故障
    1. 手动通过电源开关关闭 FENCE 设备损坏的节点
    2. 在正常节点上执行 stonith_admin -C 故障节点
2. 修复故障的 IPMI 设备

3. 按照主机故障的恢复方式恢复节点

5.4.2.5 clusterware 备份和恢复方式

1. 备份
    1. 成员管理：复制 corosync.conf 配置文件
    2. 资源管理：crm configure save 备份文件
2. 恢复
    1. 恢复软件环境：重新配置系统参数，安装 clusterware
    2. 恢复配置：
        1. 成员管理：复制 corosync.conf 到配置文件位置
        2. 资源管理：crm configure load replace 备份文件

第6章　附录

6.1　Kingbase Clusterware 集群管理脚本

本章节包含以下内容：

- cluster_manager.sh 脚本
- cluster_manager.conf 配置项

6.1.1　cluster_manager.sh 脚本

安装完 KingbaseES 后，进入安装后的数据库 install/script 目录：例如/opt/Kingbase/ES/KingbaseRAC/install/script，执行 rootDeployClusterware.sh 脚本。执行完成后会在/opt 目录下自动生成 KingbaseHA 软件包。

进入该软件包目录：

```
cd /opt/KingbaseHA
```

在该目录下，存在两个重要的文件，cluster_manager.sh 及 cluster_manager.conf。

其中 cluster_manager.sh 脚本提供了集群部署及集群运维等功能，cluster_manager.conf 配置文件提供了可自定义的集群配置参数，cluster_manager.sh 脚本可以通过 cluster_manager.conf 配置文件中配置好的参数个性化安装 KingbaseES RAC 集群。

6.1.1.1　cluster_manager.sh 脚本的功能

进入到 KingbaseHA 软件包目录下，执行以下命令查看 cluster_manager.sh 脚本的所有功能：

```
sh cluster_manager.sh --help
Usage: cluster_manager.sh <options>
<options> may be:
  --help                        show this help, then exit
  -A, --all                     config all and start process
```

```
  --start                      start corosync, wait for quorate, start pacemaker and qdevice
  --start_nowait               start corosync, pacemaker and qdevice, do not wait for quorate
  --stop                       stop qdevice pacemaker corosync
  --status                     show corosync pacemaker qdevice status
Cluster options:
  --deploy                     cluster automatic deployment
  --qdisk_init                 init votingdisk, add -y or --silent/silent to skip confirmation,
check votingdisk path before execution!
  --cluster_disk_init          format disk as gfs2, add -y or --silent/silent to skip
confirmation, check sharedate_disk path before execution!
  --init_gfs2                  update gfs2 kernel lib, add -y or --silent/silent to skip
confirmation
  --base_configure_init        init all basic configure
  --corosync_configure_update  update corosync basic configure
  --init_db                    init kingbase database
  --init_rac                   init KingbaseES RAC
  --config_gfs2_resource       crm configure dlm and gfs resource
  --config_nfs_resource        crm configure nfs resource
  --config_resource            crm configure resource
  --config_rac_resource        crm configure DB resource
  --uninstall                  uninstall all components
  --clean_all                  clean all config but not for kingbase data
  --config_keep_cluster_alive  config and start keep cluster alive crond task
  --clean_keep_cluster_alive   stop and clean keep cluster alive crond task
  --add_node                   automatic add nodes
  --add_node_configure         add nodes resource to crm configure
  --delete_node                automatic delete nodes
  --delete_node_configure      delete nodes resource to crm configure
Corosync options:
  --start_corosync             start corosync
  --stop_corosync              stop corosync
  --status_corosync            corosync status
Pacemaker options:
  --start_pacemaker            start pacemaker
  --stop_pacemaker             stop pacemaker
  --status_pacemaker           pacemaker status
QDevice options:
  --start_qdevice              start qdevice
  --stop_qdevice               stop qdevice
  --status_qdevice             qdevice status
QDisk Fenced options:
  --start_qdisk_fenced         start qdisk fenced
  --stop_qdisk_fenced          stop qdisk fenced
  --status_qdisk_fenced        qdisk fenced status
other options:
```

```
--add_rac_resource          add other rac data directory
--delete_rac_resource       delete other rac data directory
--create_rac_share_dir      create rac share dir
--config_term               config term
--init_softdog              init kernel watchdog lib
--add_dlm_nod               add dlm misc device nod
--restore                   restore cluster to less node
```

要想使用该脚本，首先需要根据现实环境修改一些初始化变量，这些变量记录在 cluster_manager.conf 中。

6.1.2　cluster_manager.conf 配置项

```
vim cluster_manager.conf
```

表 6.1.1: 参数默认值和意义

变量名称	默认值	意义
cluster_name	kcluster	集群的名字，用于生成 corosync.conf 中的 cluster_name 以及 devicedisk 模型中的 label，用于基于 label 查找投票盘
node_name	(node1 node2)	节点名称，用于配置 corosync.conf 中的 ring0_addr 以及 hosts 中的节点主机名
node_ip	(192.168.5.1 192.168.5.2)	host 中的节点 IP 地址，一般使用内网 IP 地址
enable_qdisk	1	是否启用 qdisk
votingdisk	/dev/sdc	投票盘，需要物理存在，用于 qdevice 共享磁盘心跳
enable_gfs2	1	是否启用 gfs2 集群文件系统
sharedata_dir	/sharedata	集群文件系统挂载目录
sharedata_disk	/dev/sdb	共享数据盘
enable_nfs	0	是否启用 nfs 文件系统
nfs_server	192.168.4.5	用于配置 nfs 服务端 IP 地址
nfs_server_dir	/volume1/nfs_server	nfs 服务端的共享目录
init_disk	1	是否初始化投票盘和共享数据盘
enable_initdb	1	是否执行 initdb 初始化数据库

-续表-

变量名称	默认值	意义
install_dir	/opt/KingbaseHA	KingbaseHA 安装目录, 注意与 kingbase_install_dir 区分
env_bash_file	/root/.bashrc	用于配置环境变量的保存文件
keep_cluster_alive	0	用于配置集群节点开机自启功能
pacemaker _daemon_group	haclient	Pacemaker 的 daemon 用户组名称，由编译 pacemaker 时决定
pacemaker _daemon_user	hacluster	Pacemaker 的 daemon 的用户名称，由编译 pacemaker 时决定
kingbaseowner	kingbase	Kingbase 数据库的属主
kingbasegroup	kingbase	Kingbase 数据库用户所在的用户组
kingbase_install _dir	/home/kingbase/ KingbaseRAC/Server	Kingbase 服务器安装的路径
database	”test”	数据库名
db_user	”system”	数据库用户名
db_mode	”oralce”	指定数据库模式
db_auth	”scram-sha-256”	数据库的加密方式
password	”123456”	密码（如果没有密码登录数据库，则无法提供密码项）
initdb_options	”-A $db_auth -U $db _user”	initdb 指定的参数，不能够有-D 参数
enable_fence	1	是否启用故障隔离
enable_esxi	0	是否启用基于 vmware_esxi 的故障隔离
esxi_server	192.168.4.5	用于配置 vmware_soap_fence 中服务器
esxi_user	root	用于配置 vmware_soap_fence 中用户
esxi_passwd	”Kingbase@99”	用于配置 vmware_soap_fence 中的用户密码
enable_ipmi	0	是否启用基于 ipmi 的故障隔离
ipmi_server	(192.168.2.100 192.168.2.101)	用于配置各节点的 fence_ipmilan 中的 ip 地址

-续表-

变量名称	默认值	意义
ipmi_user	(Administrator Administrator)	用于配置各节点的 fence_ipmilan 中的用户
ipmi_passwd	(”Admin@9000” ” Admin@9000”)	用于配置各节点的 fence_ipmilan 中的用户密码
enable_qdisk_fence	1	是否启用基于 qdisk 的故障隔离
qdisk_watchdog_dev	/dev/watchdog	用于配置 fence_qdisk 的 watchdog 的设备文件，目前仅支持默认值/dev/watchdog，无需修改
qdisk_watchdog _timeout	30	用于配置 fence_qdisk 的 watchdog 的超时时间，单位为秒
enable_vip	0	是否启用虚拟 IP
virtual_ip	(192.168.4.1/24 192.168.4.2/24)	虚拟 IP 地址，其配置数量应小于等于节点个数，配置格式为 IPv4,v6/NETMASK
net_device	(bond0 bond0)	与虚拟 IP 绑定的网卡，其配置数量等于节点个数或只配一个（各个节点网卡一致）
net_device_ip	(10.12.2.125 10.12.2.127)	指定网卡上的实 IP，其配置数量必须等于节点个数
enable_heuristics	1	用于开启启发式扫描功能，网络分区故障时计算仲裁使用。发生网络分区时对所有节点进行启发式扫描判断其是否可用，只有通过扫描的分区才能被选为可用分区，以此来避免选出的分区无法对外提供服务。
heuristics_interval	1000	用于配置启发式扫描的时间间隔，单位为毫秒
heuristics_timeout	10000	用于配置单次启发式扫描的超时时间，单位为毫秒
heuristics_ping _gateway	””	用于配置启发式扫描的网关地址，初始值默认为空，需要自行配置。
heuristics_reskey _attempts	1	用于配置启发式扫描的获取资源访问权的重试次数
heuristics_exec	exec_ping: /bin/ping -q -c $heuristics _reskey _attempts$heuristics _ping_gateway	用于配置执行启发式算法的组件。默认算法通过是否能 ping 通网关来判断是否能对外提供服务。

-续表-

变量名称	默认值	意义
install_rac	1	是否采用 KingbaseES RAC 方案安装数据库
db_port	54321	KingbaseES RAC 数据库端口号
rac_lms_port	53444	KingbaseES RAC lms 端口号的起始位置，其后 rac_lms_count 个端口需空闲
rac_lms_count	7	KingbaseES RAC 数据库启动时 lms 进程的数量，默认为 7 个
rac_data	data	KingbaseES RAC 数据库的数据集簇
install_ssma	0	是否采用基于共享存储的多活分库方案安装数据库
ssma_data_disk	(”-U f0c8f59d-0cc8-473c-970d-d19b30d87f5e” ”-U 7075f361-f3ad-48cf-87cc-ecc3db4a063a”)	在多活分库方案中，用于配置数据盘的 device 名称。此处采用设备的 uuid 形式，是为了避免 linux 重启时，可能导致磁盘名的错乱。如果能确保磁盘名不错乱，也可以配置成物理磁盘名，如/dev/sdx。
ssma_data_dir	(/sharedata/data1//sharedata/data2/)	在多活分库方案中，用于配置数据盘的挂载路径
ssma_port	(36321 36322)	在多活分库方案中，用于配置各节点上数据库端口号
ssma_fstype	ext4	在多活分库方案中，用于配置文件系统类型
connection_timeout	10	用于配置 sshd 或者 scmd 的超时时间，单位为秒
ssh_port	22	sshd 的端口号
use_scmd	0	是否使用 scmd 搭建节点间免密，‘1’表示使用 scmd，‘0’表示使用 sshd
scmd_port	8890	scmd 的端口号
scmd_install_dir	/home/kingbase/KingbaseRAC/securecmdd	scmd 安装目录

6.2 Kingbase Clusterware Corosync 配置

本章节包含以下内容：

- 投票盘（qdevice-disk）配置
- 成员管理（corosync）配置

6.2.1 投票盘（qdevice-disk）配置

1. 按以下命令初始化投票盘

```
mkqdisk -c /dev/设备 -l 自定义名称
```

2. 查看初始化信息

```
mkqdisk -f 自定义名称 -d -m
```

6.2.2 成员管理（corosync）配置

6.2.2.1 说明

以下配置无特别说明：

1. 不包括不使用的段
2. 不包括默认的配置值

6.2.2.2 totem 段

表 6.2.1: totem 段

配置项	推荐配置和说明
version	固定值 2
cluster_name	集群内统一命名即可
Token	单位毫秒，节点的网络心跳超时时间，超时未收到节点的心跳会认为节点故障。
join	单位毫秒，集群成员协议中做一致性同步时的超时时间，超时将会延迟成员稳定的时间。
crypto_hash	加密相关配置，默认关闭但不配置会去系统的配置中获取导致报错。

-续表-

配置项	推荐配置和说明
crypto_cipher	加密相关配置，默认关闭但不配置会去系统的配置中获取导致报错。

6.2.2.3　totem.interface 段

表 6.2.2: totem.interface 段

配置项	推荐配置和说明
knet_ping_interval	单位毫秒，knet 的心跳间隔。
knet_ping_timeout	单位毫秒，在 timeout 时间内没有收到 ping 会认为 knet 连接断开，和 token 相似。

6.2.2.4　nodelist 段

表 6.2.3: nodelist 段

配置项	推荐配置和说明
ring0_addr	按推荐不使用 redundant ring 协议，只有 ring0 _addr。
name	节点名，使用 hostname。
nodeid	各节点从 1 开始顺序增加。

6.2.2.5　quorum & quorum.device 段

表 6.2.4: quorum & quorum.device 段

配置项	推荐配置和说明
provider	固定值 corosync_votequorum
expected_votes	集群中期望投票数。节点数为 1 时，值为 3；否则为（2 * 节点数 - 1）
device.timeout	单位毫秒，timeout 是 corosync 等待 qdevice vote 的超时，超过超时会导致集群失去 quorum 停止。
device.sync_timeout	Sync 阶段使用，其他和 timeout 相同。
device.master_wins	固定值 1，目前 qdisk 投票方式为 master 投票。
device.votes	qdisk 的票数，固定值节点数-1（每个节点 1vote，qdisk 节点数-1）votes 用于实现只有 1 节点 +qdisk 就可以达到 quorum 要求。
device.model	固定值 disk

6.2.2.6　quorum.device.disk 段

表 6.2.5: quorum.device.disk 段

配置项	推荐配置和说明
device.disk.debug	为了方便现场 debug 时直接修改配置所以特别保留
interval	单位毫秒，磁盘心跳间隔。
tko	磁盘心跳超时次数，磁盘心跳丢失超过此次数节点会被认为故障。
tko_up	新启动的集群磁盘心跳被识别超过此次数后会被认为启动成功。
upgrade_wait	集群启动后开始发起选举至少等待的心跳数。
master_wait	获得满足 master 投票，成为 master 前至少等待心跳的次数。
label	使用初始化的 label 去查，该字段为了防止 linux 内核重启，导致 device 指定的名字发生改变。设置 label，就不用 device 字段指定投票盘，该值由 mkqdisk -l 指定。
io_timeout	固定值 1，qdisk 进程的 I/O 操作超过 tko*interval 后会自动重启。
fence_timeout	单位毫秒，对丢失心跳的节点做 fence 时的超时时间。

-续表-

配置项	推荐配置和说明
enable_qdisk_fence	基于 qdisk 的 fence 功能开关设置值为 1 时开启 qdisk_fence 功能，0 为关闭。
watchdog_dev	配置 fence 相关功能使用的看门狗设备路径。
watchdog_timeout	watchdog_dev 对应的看门狗设备的超时时间。

6.2.2.7　quorum.device.heuristics 段

表 6.2.6: quorum.device.heuristics 段

配置项	推荐配置和说明
mode	启发式模式选项。开启 heuristics 为 on，否则为 off。发生网络分区时对所有节点进行启发式扫描判断其是否可用，只有通过扫描的分区才能被选为可用分区，以此来避免选出的分区无法对外提供服务。多节点集群且存在网络故障场景建议配置为开启。
interval	检查集群状态的时间间隔。
timeout	检查集群状态的超时时间。
exec_ping	指定用于检查集群状态的指令。默认为 ping 命令。

6.2.2.8　logging 段

表 6.2.7: logging 段

配置项	推荐配置和说明
to_logfile	除 syslog 外是否输出 log 到文件
logfile	文件路径，支持 logrotate 配置。
debug	默认值为 off，为了方便现场 debug 时直接修改配置所以特别保留。

-续表-

配置项	推荐配置和说明
logger_subsys	定义日志子系统。subsys 即指定子系统名，目前默认为 QDEVICE，debug 指定是否开启调试信息，默认不开启。

6.2.2.9　配置间关系

1. 两节点集群中不考虑 qdisk 的多次故障造成的投票时间增加，单次投票在 master io 故障情况下到新 master 选举投票的时间最大为：

```
interval * (tko + master_wait + upgrade_wait) + fence_timeout
```

如果是 qdisk-fence 的 fence 方式，计算方式如下：

```
interval * (tko + master_wait + upgrade_wait) + watchdog_timeout
```

2. fence_timeout 应小于 tko * interval，避免因 fence 导致心跳更新不及时。
3. 考虑 bid 过程 (等待投票的过程) 中有新节点的恢复，master_wait 要比 tko_up 大。
4. qdevice 的 timeout 应该大于 qdisk 单次投票的最大时长，避免正常投票过程超时。
5. qdevice 的 sync_timeout 应该大于 timeout。
6. corosync 的 totem(corosync 环重组的过程) 应该大于 qdisk 单次投票的最大时长，避免投票过程中的节点变更。

6.2.2.10　两节点推荐配置

配置见 corosync_2nodes.conf

```
totem {
        version: 2
        token: 12000
        join: 10000
        cluster_name: 2nodes
        token_retransmits_before_loss_const: 12
        crypto_hash: none
        crypto_cipher: none
        interface {
                knet_ping_interval: 1500
                knet_ping_timeout: 6000
```

```
        }
}
quorum {
        provider: corosync_votequorum
        expected_votes: 3
        hold_quorum: 1
        device {
                timeout: 60000
                sync_timeout: 70000
                master_wins: 1
                votes: 1
                model: disk
                disk {
                        debug: 0
                        interval: 1000
                        tko: 30
                        tko_up: 2
                        upgrade_wait: 1
                        master_wait: 3
                        label: 2nodes
                        io_timeout: 1
                        fence_timeout: 50000
                        enable_qdisk_fence: 1
                        watchdog_dev: /dev/watchdog
                        watchdog_timeout: 30
                }
                heuristics {
                        mode: 1
                        interval: 1000
                        timeout: 10000
                        exec_ping: /bin/ping -q -c 1 192.168.4.1
                }
        }
}
logging {
        debug: off
        to_logfile: yes
        logfile: /opt/KingbaseHA/corosync/var/log/cluster/corosync.log
        logger_subsys {
                subsys: QDEVICE
                debug: off
        }
}
nodelist {
        node {
```

```
                ring0_addr:node229
                nodeid:1
        }
        node {
                ring0_addr:node233
                nodeid:2
        }
}
```

6.2.2.11 配置调整

1. 在推荐配置基础上修改集群节点数、集群名。
2. 在满足配置间关系的情况下，根据现场 RTO 需求和网络状况调整各个超时参数，实现更小的 RTO 或是减少异常干扰。
3. 在专用机环境根据策略调整存储位置。

6.3 Kingbase Clusterware Pacemarker 配置

本章节包含以下内容：

- 说明
- 集群选项
- 资源 operation 配置
- 资源 meta 配置
- 资源配置
- 资源约束配置
- 资源迁移分数配置
- Group 资源与 CLONE 资源
- 两节点双库推荐配置
- 配置调整

6.3.1 说明

以下配置无特别说明：

1. 不包括默认的配置值。

2. 描述格式使用 crm configure 形式。

6.3.2 集群选项

表 6.3.1: 集群级别的配置参数

参数名称	默认值	建议
maintenance-node	false	集群是否处于维护状态，一般正常状态建议为 false。当处于维护状态时，设置为 true，表示资源处于不可控状态。
stonith-enabled	true	失败的节点与资源停止不掉的节点是否进行 fence。一般有 fence 设备的，需要开启该参数。没有 fence 设备的，需要关闭该参数，否则，资源将不会启动。
stonith-action	reboot	可选值有 off 与 reboot，指定执行 fence 的动作，reboot 表示重启，off 表示关机，一般来说建议选默认值。
stonith-timeout	60s	针对 fence 的超时设置，一般建议默认值，不过根据 fence 设备情况，可以适当增加。
cluster-delay	60s	DC 指示远程节点执行操作命令，等待操作返回的超时设置。一般超过该超时，DC 没有得到回应，认为执行失败，该值需要考虑网络负载情况，网络速度不足时需要加大该值。
dc-deadtime	20s	节点启动时连接 DC 的超时设置，一般在网络速度不足时需要加大该值。
cluster_recheck_interval	15min	Pacemaker 一般是事件触发，当集群发生某件事情的时候，会触发一次 schedule 调用，看要采取什么行动。设置该值代表没有事件发生时，每隔多长时间触发一次，0 表示禁用。

6.3.3 资源 operation 配置

Pacemaker 的资源代理脚本基本上需要支持 stop、start、monitor 三种操作，每个操作有如下属性可以配置。

表 6.3.2: 资源 operation 配置

属性名称	默认值	意义
id		唯一性的名称
name		操作的名称，如 monitor、start、stop。
interval	0	操作的频率，0 表示在需要的时候调用，start 和 stop 操作一般设置为 0，monitor 需要调整该参数。
timeout		超时设置，超过该时间操作没有反应，默认为失败。
on-fail	restart(如果设置了 fence，那么 stop 默认的是 fence，如果没有 fence，那么 stop 默认的是 block)	可以配置的值有： ignore：假装没有失败 block：不会继续操作 stop：停资源且不启动 restart：先停后重启 fence：fence 失败节点 standby：转移资源
enabled	true	用 false 表示忽略该操作。
record-pending	true	是否记录操作，以至于 GUI 和 CLI 工具可以标记该操作正在进行。
role		节点以何种角色运行该操作，一般有 stopped 和 started，Slave 和 Master，目前仅对多个 monitor 操作有效。

6.3.4 资源 meta 配置

设置资源的全局属性，无关资源以何种属性运行

表 6.3.3: 资源 meta 配置

属性名称	默认值	意义
priority	0	优先级，当不能确保所有资源都能运行的情况下，优先确保高优先级的资源活着。
target-role	Started	集群确保该资源应该处于什么状态： Stopped：停止 Started：运行 Slave：备模式 Master：主模式

-续表-

属性名称	默认值	意义
is-managed	true	资源是否处于管理模式，置 false 则集群不管理资源的启动和停止，但会持续监测资源状态。
maintenance	false	资源是否处于维护模式，针对单个资源，集群不管理资源的启动、停止、状态监测。 true：维护模式 false：非维护模式
resource-stickiness	1 clone 资源 0 其他资源	资源保留在当前运行节点的分数。
requires	fencing：stonith-enabled 为 true unfencing：unfencing 处于激活状态 quorum：其他	资源能运行的必要条件 nothing：始终能运行 quorum：需获得 quorumfencing：大部分节点活着，其他失败或 unknow 节点被 fence 掉 unfencing：大部分节点活着，其他节点都被 fence 掉
migration-threshold	INFINITY	资源在一个节点失败多少次后迁移到另一个节点，0 表示禁止迁移。
failure-timeout	0	节点失败次数失效，0 表示禁用该功能。
multiple-active	stop_start	当集群发现资源在多个节点活着，采取的动作 block：标记该资源托管 stop _only：停掉所有资源 stop_start：停掉所有资源，然后在一个节点启动。
allow-migrate	ocf:pacemaker:remote 资源是 true，其他是 false	是否允许资源迁移
container-attribute-target		指定 docker 资源运行的节点
remote-node		Pacemaker 远程资源所在节点的主机名
remote-port	3121	Pacemaker 远程资源所在节点的通信端口
remote-addr	value of remote-node	配置远程资源节点的 IP 地址
remote -connect-timeout	60s	remote node 连接超时

为了自动清理资源失败的 failcount，可以设置资源的 Failure-timeout 为一个特定的时间：5min，具体见资源配置章节。

6.3.5　资源配置

目前仅以分库方案来看，需要用的资源有 fence、Filesystem、Stoarge lock、VIP、KingbaseES，故本章专门介绍这些资源的配置。

1）. fence

VMWare ESXi 环境

```
primitive esxi_fence stonith:fence_vmware_soap \
params ipaddr=192.168.4.5 login=root passwd="Kingbase@99"
pcmk_host_check=none ssl=1 ssl_insecure=1 \
op monitor interval=60s \
meta failure-timeout=5min
```

表 6.3.4: VMWare ESXi 环境资源配置

参数名称	默认值	说明
stonith	”fence_vmware_soap”	表示 fence agent 类型
ipaddr	””	此 vmware_soap 设备 IP 地址
login、passwd	””、””	登录用户名、密码
pcmk_host_list	”none”	Pacemaker 默认的主机检查机制。通常情况下，Pacemaker 会在执行 fencing 操作前确认节点是否确实 offline，以避免不必要的断电操作。
ssl	”1”	启用 SSL 加密通信，确保与 VMware ESXi 主机之间的连接是安全的。
ssl_insecure	”1”	在 SSL 连接中忽略证书验证错误。
其他		默认 fence action 是 reboot，60s 超时，过程中会重试 2 次。

IPMI 环境

```
primitive fence_node1_ipmi stonith:fence_ipmilan \
params ipaddr=192.168.2.100 login=Administrator passwd="Admin@9000"
pcmk_host_list=node1 lanplus=true
ipmitool_path=/opt/KingbaseHA/ipmi_tool/bin/ipmitool \
op monitor interval=60s \
meta failure-timeout=5min
```

表 6.3.5: IPMI 环境资源配置

参数名称	默认值	说明
stonith:fence_ipmilan	””	表示 fence agent 类型
ipaddr	””	此 IPMI 设备 IP 地址
login、passwd	””、””	登录用户名、密码
pcmk_host_list	””	此 IPMI 设备控制的节点 uname 列表。由于 IPMI 设备一般为各节点独占，因此这里一般仅为一个 uname。多节点集群，一般需要配置多个 fence_ipmilan 资源，分别支持各节点的 fence。
lanplus	0	此 agent 需要的参数，使用 IPMI LAN(RMCP+) 协议，如服务器支持 IPMILAN(RMCP) 协议，也可不配置此参数。
ipmitool_path	”/usr/bin/ipmitool”	IPMI 客户端二进制 ipmitool 路径，如不配置，则会在环境变量中查找。
其他		默认 fence action 是 reboot，60s 超时，过程中会重试 2 次。

Qdisk Fence 环境

```
primitive fence_node1_qdisk stonith:fence_qdisk \
params cluster_label="clusterHA" qdisk_fence_tool="/opt/KingbaseHA/corosync-qdevice/sbin/qdisk-fence-tool"
pcmk_host_list=node1 \
op monitor interval=60s \
meta failure-timeout=5min
```

表 6.3.6: Qdisk Fence 环境资源配置

参数名称	默认值	说明
stonith:fence_qdisk	””	表示 fence agent 类型
cluster_label	””	配置 qdisk 使用的存储设备标签
qdisk_fence_tool	””	qdisk_fence 方式所依赖的 qdisk _fence_tool 二进制程序路径。默认在 clusterware 安装路径下 corosync-qdevice 目录的子目录 sbin 下
pcmk_host_list	””	qdisk-fence 程序控制的节点 uname 列表。由于 qdisk-fence 程序运行在各个节点上，因此这里一般仅为一个 uname。多节点集群一般需要配置多个 fence_qdisk 资源，分别支持各节点的 fence。
其他		默认 fence action 是 reboot，60s 超时，过程中会重试 2 次。

2）. Filesystem & Storage lock

Filesystem

Filesystem 资源是一种 pacemaker 支持的 OCF 资源，其资源 agent 脚本位于 $OCF_ROOT/resource.d/heartbeat/Filesystem，主要用于管控文件系统资源，自动将文件系统挂载指定的目录，该脚本提供如下参数：

表 6.3.7: Filesystem 脚本参数

参数名称	默认值	说明
device	””	块设备路径，mount 的-U -L 指定的设备，或者是 nfs mount 的源路径。
directory	””	挂载点，文件系统挂载点路径。
fstype	””	文件系统类型
options	””	指定 mount 的-o 属性
statusfile_prefix	.Filesystem_status/	监控状态文件存放位置，一般按默认处理。

-续表-

参数名称	默认值	说明
run_fsck	auto	是否执行 fsck。auto 表示由 fstype 决定，force 表示强行执行，no 表示从不执行。该命令用来修复损坏的文件系统，一般按默认设置。
fast_stop	yes	期望在没有用户操作时，文件系统快速停掉。如果不能控制文件系统的用户，设置成 no。一般按默认设置。
Force_clones	false	一般来说，使用 clone 手段建立本地文件系统是被禁止的。开启该参数，将会以 clone 手段 mount 一个文件系统。一般按默认设置。
force_unmount	true	值为 true 表示在 umount 的时候，kill 掉正在访问 mount 的路径的进程；safe，以一种安全的手段 kill 掉正在访问 mount 路径的进程，该安全手段避免在发现进程时导致 block 状态；false 表示不 kill 掉正在访问的进程。一般建议用默认值。

另外该脚本还支持在监控时，进行深度操作，即 OCF_CHECK_LEVEL 值的设置，目前支持两个值：

20：往磁盘中可读可写，只有可读可写，文件系统才算正常

10：往磁盘中可读，只要可读，文件系统就算正常。

配置实例：将/dev/sdc 的 ext4 文件系统挂载到/sharedata/data1 目录下，需要确保/sharedata/data1 目录优先存在。

由于在 linux 中/dev/sdx 是由内核加载硬盘顺序决定的，存在着不确定性，故建议使用 UUID 挂载磁盘。

1. 使用如下命令查看/dev/sdc 的 uuid

```
blkid /dev/sdc
/dev/sdc: UUID="c2db7022-444f-4cbe-b452-0301c2387ffc" TYPE="ext4"
```

2. crm 配置资源

```
crm configure primitive FILESYSTEM1 ocf:heartbeat:Filesystem \
params device="-U c2db7022-444f-4cbe-b452-0301c2387ffc"
directory="/sharedata/data1" fstype="ext4" \
op start interval="0" timeout="60" \
op stop interval="0" timeout="60" \
op monitor interval="30s" timeout="60" OCF_CHECK_LEVEL="20" \
meta failure-timeout=5min
```

Storage lock

Storage lock 是一种 ocf 资源，其 agent 脚本为 sg_persist，位于 $OCF_ROOT/resource.d/heartbeat/sg_persist 目录下，该资源是为保护共享磁盘只被一个 node 访问。

该脚本提供的参数如下：

表 6.3.8: Storage lock 参数

参数名称	默认值	意义
binary	sg_persist	管理资源的二进制程序，按默认值。
devs	””	管理的磁盘设备
required_devs_nof	1	管理磁盘的最小数目，按默认值。
reservation_type	1	配置 reservation type ，保护模式使用独占模式。
master_score_base	0	配置 master 基础分数，设置越高，该节点越容易成为 master，一般按默认值。
master_score_dev_factor	100	对 master_score 计算的 device 因子，一般按默认值。
master_score_delay	30	主备减少或增加其 master_score 之前的延时时间，以 s 为单位，一般按默认处理。

配置实例如下，在 mount 文件系统前先独占存储的 LUN，防止双挂。

```
primitive sg sg_persist \
params devs="/dev/sdc" reservation_type=3 \
op monitor interval=30 timeout=60 \
meta failure-timeout=5min
ms disk_reserve sg \
meta master-max=1 notify=true target-role=Master
order storage-order Mandatory: disk_reserve:promote FILESYSTEM1:start
colocation storage-colocation inf: DB1_GROUP disk_reserve:Master
```

3）. VIP

VIP 是一种 ocf 类型的资源，其代理脚本在 $OCF_ROOT/resource.d/heartbeat/IPaddr2，该资源能提供虚拟 IP 地址服务。Agent 提供的参数如下：

表 6.3.9: VIP 参数

参数名称	默认值	意义
ip	””	IPv4 或 IPv6 的地址
nic	””	IP 地址绑定的接口名称
cidr_netmask	””	CIDR netmask，如 24
broadcast	””	广播地址，一般按默认。
iflabel	””	Interfacelabel，该 label 会加到接口名称的后面，一般按默认。
lvs_support	false	针对 IPv4 有效，是否支持 LVS Direct Routing 配置，当该 IP 地址 down 掉时，将其移送到 loopback 接口上，一般按默认。
lvs_ipv6_addrlabel	false	开启 IPv6 的 LVS Direct Routing 配置
lvs_ipv6_addrlabel_value	99	启动 IPv6 address label
clusterip_hash	” sourceip-sourceport”	配置 cluster IP 的哈希算法
mac	””	IP 的 MaC 地址，若为空，将会自动选择。
unique_clone_address	False	是否 clone 一个 address
arp_interval	200	发送 ARP 包的时间间隔，单位为毫秒
arp_count	5	ARP 包的个数
arp_count_refresh	0	配置 monitoring 节点发送 ARP 包的个数
arp_bg	true	是否以后台进程发送 ARP 包
arp_sender	send_arp	发送 ARP 包方式：send_arp，使用 heartbeat 自带的 send_arp 程序；ipoibarping infiniband 接口的默认方式；iptuils_arping 使用 iputils 包的方式；libnet_arping 使用 libnet 方式。
send_arp_opts	””	配置 arp_sender 程序的 options
flush_routes	”false”	stop 时是否刷路由表

-续表-

参数名称	默认值	意义
run_arping	false	是否在 IPv4 collision detection check 中使用 arping
noprefixroute	”false”	使用 noprefixroute 标识
preferred_lft	”forever”	针对 IPv6，设置其 lifetime
network_namespace	””	指定 network namespace

配置实例如下：

```
crm configure primitive FIP1 ocf:heartbeat:IPaddr2 \
params ip="192.168.4.135" cidr_netmask="32" nic="bond0" \
arp_sender="iputils_arping" \
op monitor interval="30s" timeout="60s" \
op start interval="0" timeout="60s" \
op stop interval="0" timeout="60s" \
meta failure-timeout=5min
```

4）. KingbaseES

该资源是针对 KingbaseES，agent 脚本为 $OCF_ROO/resource.d/kingbase/kingbase，该脚本提供参数如下：

表 6.3.10: kingbase 参数

参数名称	默认值	意义
sys_ctl	/opt/Kingbase/ES/KingbaseRAC/Server/bin/sys_ctl	指定 sys_ctl 命令位置，用于控制数据库启停。
ksql	/opt/Kingbase/ES/KingbaseRAC/Server/bin/ksql	ksql 的位置，用来判断 KingbaseES 服务是否安装。
sys_isready	/opt/Kingbase/ES/KingbaseRAC/Server/bin/sys_isready	指定 sys_isready 位置，用于 monitor。
kb_data	/opt/Kingbase/ES/KingbaseRAC/data	指定 KingbaseES 的 data 目录位置
kb_dba	kingbase	指定 KingbaseES 的 OS 属主
kb_user	system	指定监听连接的数据库用户名

-续表-

参数名称	默认值	意义
kb_host	”localhost”	指定 KingbaseES 监听的 IP 地址，0.0.0.0 表示监听本机上所有 IP 地址。
kb_port	54321	指定 KingbaseES 监听的端口
kb_libs	/opt/Kingbase/ES/KingbaseRAC/Server/lib	指定 KingbaseES 的 lib 目录
start_opt	””	使用 sys_ctl 启动时的参数，一般指-o 。
ctl_opt	””	配置 sys_ctl 的参数，一般指-w 或-W 类。
config	kb_data/kingbase.conf	指定 kingbase.conf 位置
kb_db	template1	监控连接的 database 名称
logfile	/dev/null	指定日志的位置
socketdir	””	指定 unix_socket 的位置，在 kingbase.conf 中设置了 unix_socket _directories，则需要指定该值。
stop_escalate	90	在使用-m immediate 停止之前，需要等待使用-m fast 停止的超时时间，单位为秒。
check_wal_receiver	”false”	是否监控 walreceiver 进程
monitor_times	10	在 monitor 阶段，执行 sys_isready 命令的最大次数。
monitor_interval	1	在 monitor 阶段，上一次 sys_isready 执行失败后，间隔多久进行下一次执行，单位为秒。

实例配置：

```
crm configure primitive DB2 ocf:kingbase:kingbase \
params sys_ctl="/home/kingbase/KingbaseRAC/Server/bin/sys_ctl" \
ksql="/home/kingbase/KingbaseRAC/Server/bin/ksql" \
sys_isready="/home/kingbase/KingbaseRAC/Server/bin/sys_isready" \
kb_data="/sharedata/data2/data" \
kb_dba="kingbase" kb_host="0.0.0.0" \
```

```
kb_user="system" \
kb_port="36322" \
kb_libs="/home/kingbase/KingbaseRAC/Server/lib" \
kb_db="template1" \
logfile="/home/kingbase/KingbaseRAC/Server/log/kingbase2.log" \
op start interval="0" timeout="120" \
op stop interval="0" timeout="120" \
op monitor interval="9s" timeout="30" \
meta failure-timeout=5min
```

5）. 时间同步

clusterware 本身不受系统时间同步的影响，节点间的时间同步会影响应用的时间戳记录和发生问题时排查日志的效率。配置方式参见操作系统配置一节。但为了防止时间倒退对数据库和业务造成影响，请为集群各个节点配置同一个 NTP 服务器。

6.3.6　资源约束配置

Pacemaker 一般可以配置资源的约束。目前来说，比较流行的有 location 约束、order 约束、colocation 约束等。

- Location 约束配置资源偏好在哪个节点启动；
- Order 约束配置各个资源启动的先后顺序；
- Colocation 约束配置资源的结合性。

每个资源约束有个分数，pacemaker 会根据分数来进行操作，pacemaker 会计算每个资源和节点的分数。一般来说，资源在某个节点的分数为负数，则该节点不允许运行该资源，而 pacemaker 会选择在资源得分最高的节点上运行该资源。

Location 约束有如下属性：

表 6.3.11: Location 约束属性

属性名称	默认值	意义
id		全局唯一名称
rsc		约束的资源名称，和 rsc-pattern 必须提供一个。
rsc-pattern		POSIX 类的正则表达式，模糊匹配约束资源的名称，和 rsc 必须提供一个。
node		约束指定的节点名称
score		该约束的分数

-续表-

属性名称	默认值	意义
resource-discovery	always	是否检测该资源已经运行，有如下值： always：总是检测资源在各节点状态 never：从不检测 exclusive：总是检测资源的本地状态

配置实例如下：

配置 FIP1 在 node1 上运行的分数为 1000。

```
crm configure location FIP1-on-node1 FIP1 1000: node1
```

Order 约束能够配置资源启动的顺序，资源不一定在一个节点上启动，其主要有如下属性：

表 6.3.12: Order 约束属性

属性名称	默认值	意义
id		一个约束的唯一名称
firist		then 资源依赖资源的名称
then		依赖资源名称
first-action	start	配置 firsit 资源优先的操作，合理值有 start、stop、promote、demote。
then-action	start	配置 firist 资源的 first-action 完成后，then 资源的操作，合理值有 start、stop、promote、demote。
kind	mandatory	约束具体实现的方式： mandatory: 只有 first-action 成功执行后，then-action 才会执行，硬依赖 optional: 在同一个操作事务中维持该约束 serialize: 确保涉及的操作不并行，first-actin 和 then-actin 能够以不同的顺序运行，但一定要一个完成后另一个才能完成。
symmetrical	false	如果为 true，那么相反操作适用相反的顺序，如 B start 在 A start 之后，那么 B stop 在 A stop 之前。

配置实例如下：

clone-dlm 资源必须在 clone-gfs2 资源启动之前启动，而 clone-dlm 资源关闭需在 clone-gfs2 停止后。

```
crm configure order cluster-order1 clone-dlm clone-gfs2
```

Colocation 约束能够配置资源的结合性，其属性如下：

表 6.3.13: Colocation 约束属性

属性名称	默认值	意义
id		该约束的唯一名称
rsc		需要与 with-rsc 放在一块的资源名称
with-rsc		配置 colocatoin 约束的目标资源名称，一般来说，clusterware 会先决定哪个节点运行该资源，然后决定 rsc 资源放在哪运行。
node-attribute	#uname	运行 rsc 和 with-rsc 资源的该值必须一致
score		该约束的分数，+INFINITY 表示两个资源永远在一块运行，-INFINITY 表示两个资源永远不在一块运行。

配置实例：

```
crm configure colocation cluster-colo1 inf: clone-gfs2 clone-dlm
```

6.3.7　资源迁移分数配置

Pacemaker 可以设置资源迁移的分数，通过合理设置资源保留当前节点运行的分数，能够达到高可用与负载均衡的平衡点。

如果考虑高可用性，即重启节点不产生资源迁移，需确保 location 约束的分数 + 该分数都大于最大的 location 得到的分数。如果考虑性能，即资源负载问题，那么需要将该值设置的越小越好。

配置实例：将资源迁移分数配置为 500。

```
crm configure rsc_defaults resource-stickiness=500
```

6.3.8　Group 资源与 CLONE 资源 {#group-resource}

1）. Group 资源

通常来说，集群可能存在一系列资源，这些资源需要运行在一起，启动顺序有严格要求，停止有相反的顺序，可以通过 location、order、colocation 约束达到该要求，但配置起来较麻烦。为了简化配置，pacemaker 提供 group 资源的概念。

表 6.3.14: Group 资源的属性

属性名称	默认值	意义
id		唯一的组名称

配置实例：

将 FIP1 FILESYSTEM1 DB1 三个资源作为一个组资源:

```
crm configure group DB1_GROUP FIP1 FILESYSTEM1 DB1
```

上述组中的资源有如下行为特性：

- Colocation 约束，FIP1 FILESYSTEM1 DB1 需要在一块运行;
- Order 约束：启动顺序：FIP1->FILESYSTEM1->DB1, 停止顺序：DB1->FILESYSTTEM1->FIP1;
- FIP1 的启动情况影响 FILESYTEM1 和 DB1，同理 FILESYTEM1 的启动情况影响 DB1，意思是排在前面的服务没有运行，后面的服务永远不会运行，而排在后面的服务不会对排在前面的服务造成影响;
- 对资源迁移参数 resource-stickiness 的影响：如果该值为 100，那么如果组资源有 5 个活动资源，那么该组资源留在本节点的分数就是 500。

2）. Clone **资源**

Clone 资源是在同一时刻存在多个副本运行，可以在每个节点都运行该资源，可以 clone 一个 primitive（普通的资源）和一个 group 资源。Clone 资源分为 anonymous 和 globally unique。anonymous 比较简单，每个节点运行同样的一份，而 globally unique 每个节点运行有其特殊性。

表 6.3.15: clone 资源的属性

属性名称	默认值	意义
id		唯一的名称

配置实例如下：

将 dlm 资源打造成 clone 资源

```
crm configure clone clone-dlm dlm
```

6.3.9　两节点双库推荐配置

1）. 手动配置

使用 Clusterware 自带的 crm 工具，手工配置两节点双库。

1. 添加 fence 资源

1.1 支持 VMWARE ESXi 环境的配置，参数 ipaddr、login、passwd 取值根据需要调整。需要特别注意的是各个机器的主机名要与 VMWARE ESXi 上的名称一致。

```
crm configure primitive esxi_fence stonith:fence_vmware_soap \
params ipaddr=192.168.4.5 login=root passwd="Kingbase@99"
pcmk_host_check=none ssl=1 ssl_insecure=1 \
op monitor interval=60s \
meta failure-timeout=5min
```

1.2 支持 IPMI 环境的配置，参数 ipaddr、login、passwd 取值根据需要调整。需要注意的是，由于 IPMI 设备一般为各节点独占，因此需要配置两个 fence 资源，分别支持 node1 和 node2 的 fence。

```
crm configure primitive fence_node1_ipmi stonith:fence_ipmilan \
params ipaddr=192.168.2.100 login=Administrator passwd="Admin@9000"
pcmk_host_list=node1 lanplus=true
ipmitool_path=/opt/KingbaseHA/ipmi_tool/bin/ipmitool \
op monitor interval=60s \
meta failure-timeout=5min
```

```
crm configure primitive fence_node2_ipmi stonith:fence_ipmilan \
params ipaddr=192.168.2.101 login=Administrator passwd="Admin@9000"
pcmk_host_list=node2 lanplus=true
ipmitool_path=/opt/KingbaseHA/ipmi_tool/bin/ipmitool \
op monitor interval=60s \
meta failure-timeout=5min
```

执行如下命令，对 fence_node1_ipmi 和 fence_node2_ipmi 添加 location 约束。为了保证 fence_node1_ipmi 资源尽量不在节点 node1，fence_node2_ipmi 资源尽量不在节点 node2，从而减少 fence 自己的概率，又由于资源在各个节点的默认分数为 0，因此需要保证 fence_node1_ipmi 资源在 node2 的分数、fence_node2_ipmi 在 node1 的分数均大于 rsc_defaults resource-stickiness 的分数。

```
crm configure location fence_node1_ipmi-on-node2 fence_node1_ipmi 1000: node2
crm configure location fence_node2_ipmi-on-node1 fence_node2_ipmi 1000: node1
```

1.3 支持无远程电源控制环境的 fence_qdisk 配置，参数 cluster_label、qdisk_fence_tool 取值根据需要调整。类似于 IPMI 设备，由于 qdisk 依赖的 qdisk-fenced 程序运行在各节点上，因此需要配置两个 fence 资源，分别支持 node1 和 node2 的 fence。

```
crm configure primitive fence_node1_qdisk stonith:fence_qdisk \
params cluster_label=clusterHA qdisk_fence_tool=/opt/KingbaseHA/corosync-qdevice/sbin/qdisk-fence-tool
pcmk_host_list=node1 \
op monitor interval=60s \
meta failure-timeout=5min
```

```
crm configure primitive fence_node2_qdisk stonith:fence_qdisk \
params cluster_label=clusterHA qdisk_fence_tool=/opt/KingbaseHA/corosync-qdevice/sbin/qdisk-fence-tool
pcmk_host_list=node2 \
op monitor interval=60s \
meta failure-timeout=5min
```

执行如下命令，对 fence_node1_qdisk 和 fence_node2_qdisk 添加 location 约束。为了保证 fence_node1_qdisk 资源尽量不在节点 node1，fence_node2_qdisk 资源尽量不在节点 node2，从而减少 fence 自己的概率，又由于资源在各个节点的默认分数为 0，因此需要保证 fence_node1_qdisk 资源在 node2 的分数、fence_node2_qdisk 在 node1 的分数均大于 rsc_defaults resource-stickiness 的分数。

```
crm configure location fence_node1_qdisk-on-node2 fence_node1_qdisk 1000: node2
crm configure location fence_node2_qdisk-on-node1 fence_node2_qdisk 1000: node1
```

2. 执行如下命令，添加 FIP1 资源，cidr_netmask 与原有接口的 ip 地址的 netmask 保持一致，集群中各节点都具有此同名网卡接口，可以用 ip addr 命令查看。

```
crm configure primitive FIP1 ocf:heartbeat:IPaddr2 \
params ip="192.168.4.135" cidr_netmask="24" nic="bond0" \
arp_sender="iputils_arping" \
op monitor interval="30s" timeout="60s" \
op start interval="0" timeout="60s" \
op stop interval="0" timeout="60s" \
meta failure-timeout=5min
```

3. 执行如下命令，添加 FIP2 资源，cidr_netmask 与接口原有的 ip 地址的 netmask 保持一致，集群中各节点都具有此同名网卡接口，可以用 ip addr 命令查看。

```
crm configure primitive FIP2 ocf:heartbeat:IPaddr2 \
params ip="192.168.4.136" cidr_netmask="24" nic="bond0" \
arp_sender="iputils_arping" \
op monitor interval="30s" timeout="60s" \
op start interval="0" timeout="60s" \
op stop interval="0" timeout="60s" \
meta failure-timeout=5min
```

4. 执行如下命令，添加 FILESYSTEM1 资源，需确保每个节点/sharedata/data1 目录存在，sharedata 属主是 root，在 mount 后将 data1 属主改成数据库用户。c2db7022-444f-4cbe-b452-0301c2387ffc 为磁盘的 uuid，可以用 blkid 去查。

```
crm configure primitive FILESYSTEM1 ocf:heartbeat:Filesystem \
params device=" U c2db7022-444f-4cbe-b452-0301c2387ffc"
directory="/sharedata/data1" fstype="ext4" \
op start interval="0" timeout="60" \
op stop interval="0" timeout="60" \
op monitor interval="30s" timeout="60" OCF_CHECK_LEVEL="20" \
meta failure-timeout=5min
```

5. 执行如下命令，添加防止 FILESYSTEM1 双挂服务。

```
crm configure
primitive SG1 ocf:heartbeat:sg_persist \
params devs="/dev/sdc" reservation_type=3 \
op monitor interval=30 timeout=60 \
meta failure-timeout=5min
ms disk_reserve1 SG1 \
meta master-max=1 notify=true target-role=Master
order storage-order Mandatory: disk_reserve1:promote FILESYSTEM1:start
colocation storage-colocation inf: DB1_GROUP disk_reserve1:Master
```

6. 执行如下命令，添加 FILESYSTEM2，需确保每个节点/sharedata/data2 目录存在，sharedata 属主是 root，在 mount 后将 data2 属主改成数据库用户。xxxxuid 为另一磁盘的 uuid，可以用 blkid 命令去查。

```
crm configure primitive FILESYSTEM2 ocf:heartbeat:Filesystem \
params device="-U xxxxuid" directory="/sharedata/data2" fstype="ext4" \
op start interval="0" timeout="60" \
op stop interval="0" timeout="60" \
op monitor interval="30s" timeout="60" OCF_CHECK_LEVEL="20" \
meta failure-timeout=5min
```

7. 执行如下命令，添加防止 FILESYSTEM2 双挂服务。

```
crm configure
primitive SG2 ocf:heartbeat:sg_persist \
params devs="/dev/sdd" reservation_type=3 \
op monitor interval=30 timeout=60 \
meta failure-timeout=5min
ms disk_reserve2 SG2 \
meta master-max=1 notify=true target-role=Master
order storage-order Mandatory: disk_reserve2:promote FILESYSTEM1:start
colocation storage-colocation inf: DB2_GROUP disk_reserve2:Master
```

8. 执行如下命令，添加一个分库资源，注意/ sharedata/ data1/ data 目录下的 kingbase.conf 需要手动配置 port=36321，需要手动创建/home/kingbase/KingbaseRAC/Server/log 目录。

```
crm configure primitive DB1 ocf:kingbase:kingbase \
params sys_ctl="/home/kingbase/KingbaseRAC/Server/bin/sys_ctl" \
ksql="/home/kingbase/KingbaseRAC/Server/bin/ksql" \
sys_isready="/home/kingbase/KingbaseRAC/Server/bin/sys_isready" \
kb_data="/sharedata/data1/data" \
kb_dba="kingbase" kb_host="0.0.0.0" \
kb_port="36321" \
kb_user="system" \
kb_libs="/home/kingbase/KingbaseRAC/Server/lib" \
kb_db="template1" \
logfile="/home/kingbase/KingbaseRAC/Server/log/kingbase1.log" \
op start interval="0" timeout="120" \
op stop interval="0" timeout="120" \
op monitor interval="9s" timeout="30" \
meta failure-timeout=5min
```

9. 执行如下命令，添加另一个分库资源，需要修改相应的/ sharedata/ data2/ data/ kingbase.conf 中的 port 为 36322。

```
crm configure primitive DB2 ocf:kingbase:kingbase \
params sys_ctl="/home/kingbase/KingbaseRAC/Server/bin/sys_ctl" \
ksql="/home/kingbase/KingbaseRAC/Server/bin/ksql" \
sys_isready="/home/kingbase/KingbaseRAC/Server/bin/sys_isready" \
kb_data="/sharedata/data2/data" \
kb_dba="kingbase" kb_host="0.0.0.0" \
kb_user="system" \
kb_port="36322" \
kb_libs="/home/kingbase/KingbaseRAC/Server/lib" \
kb_db="template1" \
logfile="/home/kingbase/KingbaseRAC/Server/log/kingbase2.log" \
op start interval="0" timeout="120" \
op stop interval="0" timeout="120" \
op monitor interval="9s" timeout="30" \
meta failure-timeout=5min
```

10. 执行如下命令，创建 DB1 组资源。

```
crm configure group DB1_GROUP FIP1 FILESYSTEM1 DB1
```

11. 执行如下命令，创建 DB2 组资源。

```
crm configure group DB2_GROUP FIP2 FILESYSTEM2 DB2
```

12. 添加 DB1 location 约束，多个节点分数最好不一样。

```
crm configure location DB1-on-node1 DB1_GROUP 1000: node1
crm configure location DB1-on-node2 DB1_GROUP 800: node2
```

13. 添加 DB2 location 约束。为了达到负载均衡，DB2 资源的在各个节点的分数要和 DB1 正好相反。

```
crm configure location DB2-on-node1 DB2_GROUP 800: node1
crm configure location DB2-on-node2 DB2_GROUP 1000: node2
```

14. 设置资源保留在原节点的分数。如果考虑高可用性，即重启节点不产生资源迁移，需确保 location 约束的分数 + 该分数都大于最大的 location 得到的分数。如果考虑性能，即资源负载问题，那么需要将该值设置的越小越好。

```
crm configure rsc_defaults resource-stickiness=500
```

2）. **配置文件**

配置见 crm_2nodes.txt

```
node 1: daidewei-4.134
node 2: daidewei-4.137
primitive DB0 ocf:kingbase:kingbase \
params sys_ctl="/home/kingbase/KingbaseRAC/Server/bin/sys_ctl" ksql="/home/kingbase/KingbaseRAC/
Server/bin/ksql" sys_isready="/home/kingbase/KingbaseRAC/Server/bin/sys_isready" kb_data="/
sharedata/data3//data" kb_dba=kingbase kb_host=0.0.0.0 kb_user=system kb_port=36321 kb_libs="/
home/kingbase/KingbaseRAC/Server/lib" kb_db=template1 logfile="/home/kingbase/KingbaseRAC/Server/
log/kingbase0.log" \
op start interval=0 timeout=120 \
op stop interval=0 timeout=120 \
op monitor interval=9s timeout=30 \
meta failure-timeout=5min
primitive DB1 ocf:kingbase:kingbase \
params sys_ctl="/home/kingbase/KingbaseRAC/Server/bin/sys_ctl" ksql="/home/kingbase/KingbaseRAC/
Server/bin/ksql" sys_isready="/home/kingbase/KingbaseRAC/Server/bin/sys_isready" kb_data="/
sharedata/data2//data" kb_dba=kingbase kb_host=0.0.0.0 kb_user=system kb_port=36322 kb_libs="/
home/kingbase/KingbaseRAC/Server/lib" kb_db=template1 logfile="/home/kingbase/KingbaseRAC/Server/
log/kingbase1.log" \
op start interval=0 timeout=120 \
op stop interval=0 timeout=120 \
op monitor interval=9s timeout=30 \
meta failure-timeout=5min
primitive FILESYSTEM0 Filesystem \
params device="-U f0c8f59d-0cc8-473c-970d-d19b30d87f5e" directory="/sharedata/data3/" fstype=ext4
\
op start interval=0 timeout=60 \
op stop interval=0 timeout=60 \
```

```
op monitor interval=30s timeout=60 OCF_CHECK_LEVEL=20 \
meta failure-timeout=5min
primitive FILESYSTEM1 Filesystem \
params device="-U 7075f361-f3ad-48cf-87cc-ecc3db4a063a" directory="/sharedata/data2/" fstype=ext4
\
op start interval=0 timeout=60 \
op stop interval=0 timeout=60 \
op monitor interval=30s timeout=60 OCF_CHECK_LEVEL=20 \
meta failure-timeout=5min
primitive FIP0 IPaddr2 \
params ip=192.168.4.139 cidr_netmask=24 nic=bond0 arp_sender=iputils_arping \
op monitor interval=30s timeout=60s \
op start interval=0 timeout=60s \
op stop interval=0 timeout=60s \
meta failure-timeout=5min
primitive FIP1 IPaddr2 \
params ip=192.168.4.140 cidr_netmask=24 nic=bond0 arp_sender=iputils_arping \
op monitor interval=30s timeout=60s \
op start interval=0 timeout=60s \
op stop interval=0 timeout=60s \
meta failure-timeout=5min
primitive esxi_fence stonith:fence_vmware_soap \
params ipaddr=192.168.4.5 login=root passwd="Kingbase2021!" pcmk_host_check=none ssl=1 ssl_
insecure=1 \
op monitor interval=60s \
meta failure-timeout=5min
group DB0_GROUP FIP0 FILESYSTEM0 DB0
group DB1_GROUP FIP1 FILESYSTEM1 DB1
location DB0-on-daidewei-4.134 DB0_GROUP 1000: daidewei-4.134
location DB0-on-daidewei-4.137 DB0_GROUP 800: daidewei-4.137
location DB1-on-daidewei-4.134 DB1_GROUP 800: daidewei-4.134
location DB1-on-daidewei-4.137 DB1_GROUP 1000: daidewei-4.137
property cib-bootstrap-options: \
have-watchdog=false \
dc-version=2.0.3-4b1f869f0f \
cluster-infrastructure=corosync \
cluster-name=2nodes
rsc_defaults rsc-options: \
resource-stickiness=500
```

6.3.10　配置调整

1. 根据现场环境，调整上述环境参数的值，主要需考虑具体环境的算力、网络、存储等因素。

2. 根据现场环境，调整各个资源的 timeout 参数。

- 当一台物理宿主机上搭建过多的虚拟机时，会导致虚拟机各方面的性能下降明显。
- 建议调高 Filesystem 的监控超时时间，也就是 monitor 操作的 tiemout 时间设置大一些，也可调整磁盘调度。
- 建议调高数据库的监测次数，也就是 monitor_times 设置大一些。
- 建议增加环境变量 HA_stonith_rhcs_get_metadata_timeout。这个环境变量是控制获取 fence 资源 metadata 的超时时间。开机后，执行 time fence_vmware_soap -o metadata，如果执行时间超过 5s，那么建议将环境变量 HA_stonith_rhcs_get_metadata_timeout 设置为上述执行时间的两倍。

3. 根据高可用性，调整资源迁移分数来达到高可用与负载均衡的平衡。

版权声明

中电科金仓（北京）科技股份有限公司（简称：电科金仓）版权所有，并保留对本手册及本声明的一切权利。

未得到电科金仓的书面许可，任何人不得以任何方式或形式对本手册内的任何部分进行复制、摘录、备份、修改、传播、翻译成其他语言、将其全部或部分用于商业用途。

免责声明

本手册内容依据现有信息制作，由于产品版本升级或其他原因，其内容有可能变更。电科金仓保留在没有任何通知或者提示的情况下对手册内容进行修改的权利。

本手册仅作为使用指导，电科金仓在编写本手册时已尽力保证其内容准确可靠，但并不确保手册内容完全没有错误或遗漏，本手册中的所有信息也不构成任何明示或暗示的担保。

技术支持

- 电科金仓官方网站：http://www.kingbase.com.cn/
- 电科金仓文档中心：http://help.kingbase.com.cn/
- 全国服务热线：400-601-1188
- 电科金仓技术支持与反馈信箱：support@kingbase.com.cn

服务周期承诺

由于市场需求在不断变化，技术创新和发展的进程不断加剧，产品的版本更迭不可避免。电科金仓对于产品版本生命周期的有效管理，有助于您提前规划项目，更好地从产品服务终止上过渡。

表 16: KingbaseES 产品生命周期里程碑

关键里程碑点	定义
产品发布日期	产品正式发布版本，即 GA（general availability）版本的发布日期。
停止销售日期	正式停止销售的日期，版本停止接受订单日。该日之后，产品将不再销售。
停止功能升级日期	在该日期之后，不再提供新特性和新硬件支持。但依旧提供错误修复、安全修复、功能维护等服务。
停止功能维护日期	在该日期之后，不再维护功能，修复问题。但依旧提供安全修复等服务
停止安全维护日期	在该日期之后，不再发布补丁版本修复中高风险漏洞，仅提供有限的支持。
产品服务终止日期	停止提供产品服务和支持的日期。包括软件维护版本，缺陷修复，以及针对该产品的所有服务支持（包括服务热线和远程/现场支持）。

服务周期策略

金仓数据库管理系统 KingbaseES 产品确保以下的服务周期：

1）产品自发布之日起至产品停止功能升级（包含新特性、新硬件支持）之日止不少于 5 年。

2）产品停止功能升级之日起至产品停止功能维护（主要包括问题修复）之日止不少于 4 年。

3）产品功能维护停止之日起至产品停止安全维护（包括中高风险漏洞修复）之日止不少于 2 年。

针对金仓数据库管理系统 KingbaseES V9 产品（发布日期：2022 年 7 月 15 日），其具体服务周期安排如下：

- 产品销售日期：以产品销售合同所约定日期为准。
- 停止升级日期：自产品销售日期起计算，满 5 年之日止。
- 服务终止日期：自产品销售日期起计算，满 11 年之日止。

服务终止策略

金仓数据库管理系统 KingbaseES 产品确保在销售后，至少提供 6 年的服务支持。

备注:

电科金仓将会综合各方因素来确定产品服务终止日期。并将在实际产品服务终止日期之前至少 90 天，通过公开方式宣布产品服务终止日期。